

中国传媒大学作业报告

面向 RadioML2016.10A 的固定划分
多视图融合调制识别

机器学习课程作业报告

姓名：申奥

学号：202520081000092

日期：2026 年 5 月

摘 要

低信噪比下的自动调制识别中，多视图时频融合是否真正有效尚需实证检验。本文以 RadioML2016.10A 固定划分 `stratified_by_mod_snr_seed42` 与三个训练种子建立 9 模型 $\times$ 3 种子 = 27 运行单元的协议化主实验，并以独立证据标签登记多类扩展实验与一个提案模型。主实验中 CLDNN 取得最高整体准确率 0.6129、宏平均 F1 0.6332；静态 I/Q-STFT 融合接近 CLDNN 但有整体损失；标量门控融合低于静态融合，构成负结果；MCLDNN 两个训练种子单类塌陷被保留登记。提案模型 `fusion_cldnn_stft` 把 fusion 的 I/Q 分支升级为 CLDNN 风格编码器，叠加保标签的相位旋转加循环时移信号域增强（仅训练）；在同一固定划分与三训练种子下取得平均整体准确率 0.6284 ($\sigma = 0.0011$)，相对 CLDNN 基线提升 1.55 个百分点，且整体、低、中、高信噪比四项指标同时正向。然而，同硬件 CLDNN + 信号域增强对照实验（整体 0.6272，+1.27 pp）揭示了决定性结论：增强收益完全独立于融合架构，融合机制本身未贡献任何可检测的独立增益（Proposed vs CLDNN+aug: -0.08 pp, McNemar 不显著，CI 跨零）。门控融合诊断实验则发现门控权重呈 SNR 单调递减（方向正确），但该方向性未转化为分类增益，且跨种子稳定性差。提案模型与 2024 年代复值多流 / Transformer 混合基线量级一致，与 LENet-M (0.6463) 和 SigFormer (0.6371) 仍有 1-2 个百分点差距。本研究的核心实证发现是：在当前框架下，信号域增强（而非融合架构）是性能提升的唯一可检测驱动因素。

关键词：自动调制识别；RadioML2016.10A；时频特征；多视图融合；CLDNN；信号域增强；配对统计检验

目录

摘 要	I
第一章 绪论	1
1.1 研究背景	1
1.2 研究问题	1
1.3 本文工作与贡献	2
1.4 全文结构	3
第二章 数据集、实验协议与评价指标	4
2.1 数据集与任务定义	4
2.2 固定划分与训练种子	5
2.3 模型矩阵	5
2.4 特征与训练设置	5
2.5 评价指标与信噪比分组	6
2.6 配对统计检验协议	6
2.7 协议边界说明	7
2.8 扩展实验设计概述	7
第三章 模型方法与融合结构	8
3.1 输入表示	8
3.2 实验模型矩阵	8
3.3 I/Q 一维卷积基线	9
3.4 I/Q 残差卷积: <code>resnet1d</code>	9
3.5 卷积-循环混合模型: <code>cldnn</code> 与 <code>mcldnn</code>	9
3.5.1 <code>cldnn</code>	10
3.5.2 <code>mcldnn</code>	10
3.6 轻量深度可分离卷积: <code>lwamcnet</code>	11
3.7 STFT 单视图模型: <code>tfcnn_stft</code>	11
3.8 参数匹配 I/Q 控制: <code>iq_param_matched</code>	12
3.9 静态 I/Q-STFT 融合: <code>fusion_iq_stft</code>	12

3.10	标量门控融合: <code>gated_fusion_iq_stft</code>	12
3.11	提案模型与训练侧干预	13
3.11.1	架构动机	13
3.11.2	信号域增强	13
3.11.3	标签平滑	14
3.11.4	三项干预的不平等贡献	15
3.12	实现细节与比较纪律	15
第四章	实验结果与统计检验	17
4.1	主实验整体结果	17
4.2	整体性能的配对检验	19
4.3	低信噪比下的融合权衡	20
4.3.1	低信噪比混淆边界推移的物理分析	21
4.4	门控融合负结果	24
4.5	复杂度与受控 CUDA 前向延迟	25
4.6	MCLDNN 异常与负结果保留	26
4.7	扩展实验与提案模型	28
4.7.1	扩展实验摘要	28
4.7.2	文献校准与可比 SOTA	29
4.7.3	提案模型 <code>fusion_cldnn_stft</code> + 增强 (跨硬件三种子均值比较)	30
4.7.4	提案模型单干预消融与配对统计检验	32
4.7.5	CLDNN + 信号域增强对照实验与融合贡献归零	35
第五章	讨论、局限性与可复现性	37
5.1	固定协议下结果的含义	37
5.2	STFT 融合的低信噪比权衡	37
5.3	融合失败原因诊断	37
5.4	复杂度与运行时证据限制	38
5.5	提案模型整体准确率高于基线的解释边界	38
5.6	协议局限与后续处理	39
5.7	可复现性与证据边界	39
第六章	总结	42

6.1	工作总结	42
6.2	主要结论	42
6.3	不足与后续工作	43
	参考文献	45
	附录 A 证据包、环境与补充图表	49
A.1	证据包与环境摘要	49
A.2	图表证据源映射	49
A.3	补充超参、训练曲线与混淆矩阵	50
	附录 B 完整训练超参表	55

第一章 绪论

1.1 研究背景

无线电自动调制识别 (Automatic Modulation Classification, AMC) 是在未知调制方式条件下, 根据接收信号自动判别调制类别的任务。它是频谱感知、认知无线电、通信监测和非合作通信分析中的基础环节。RadioML 系列数据集和基于卷积神经网络的端到端识别方法推动了深度学习在 AMC 任务中的应用^[1-3]。与人工统计特征方法相比, 深度模型能够直接从原始 I/Q 序列或派生时频表示中学习判别特征, 但其结果也更依赖数据划分、训练随机性和评价协议。

传统 AMC 研究长期关注似然方法、高阶累积量和人工特征分类器^[4-7], 深度学习方法则把特征提取和分类器学习合并到端到端训练流程中。低信噪比条件是 AMC 任务中的主要困难之一。噪声会削弱 I/Q 序列中的相位、幅度和瞬时频率线索, 使不同调制类别在观测空间中更加接近。短时傅里叶变换 (Short-Time Fourier Transform, STFT) 将信号局部频率结构显式展开^[8-12], 理论上可能为低信噪比样本提供与原始 I/Q 序列互补的判别信息。

然而, 现有深度 AMC 研究在实验协议上存在若干不一致: 数据划分方式和训练随机性因文献而异, 使不同工作的结论难以直接对比; 多视图融合方法通常在未控制参数规模的条件下报告性能改善, 难以区分视图融合收益与参数增量; 低信噪比分组性能的改善常缺乏配对统计检验支撑。这些局限表明, 需要在固定数据划分、统一模型矩阵和配对统计检验下对多视图融合方法进行系统评估。

1.2 研究问题

本文研究 RadioML2016.10A 上的 11 类调制分类问题。给定长度为 128 的双通道 I/Q 样本, 模型输出对应的调制类别。任务范围聚焦于调制分类性能, 信噪比估计、信道识别、频谱占用检测和端到端部署系统优化不纳入本报告评估。

围绕这一任务, 本文关注三个问题: 第一, 在同一固定划分和相同训练种子集合下, I/Q 序列模型、STFT 时频模型和 I/Q-STFT 融合模型的整体表现如何; 第二, STFT 视图是否在低信噪比样本上提供统计显著的局部补充信息; 第三, 门控融合和参数匹配控制是否能为融合收益提供可信的消融解释。

1.3 本文工作与贡献

本文在 RadioML2016.10A 上建立了一套协议化的多视图融合 AMC 实验框架，并在此基础上提出提案模型 `fusion_cldnn_stft`。实验矩阵包含 `cnn1d`、`resnet1d`、`tf_cnn_stft`、`fusion_iq_stft`、`cldnn`、`mcl_dnn`、`lwamcnet`、`iq_param_matched` 和 `gated_fusion_iq_stft` 共 9 个模型行，每个模型使用 3 个训练种子，因此主实验包含 27 个运行单元。模型类型覆盖原始 I/Q 卷积基线、STFT 时频分支、静态多视图融合、门控多视图融合、卷积-循环混合模型、轻量模型和参数匹配 I/Q 控制模型。

本文的主要贡献如下：

1. 建立了固定划分、三训练种子和 9 个模型行的协议化实验框架，通过参数匹配 I/Q 控制模型区分视图融合收益与参数规模增量，并完整保留门控融合和 MCLDNN 异常种子等负结果，确保比较结论不依赖结果筛选。
2. 使用同一测试样本上的配对预测结果进行自助法置信区间估计和 McNemar 检验^[13-14]，区分统计显著的发现与点估计差异，避免仅凭均值做外推结论。
3. 通过四项独立扩展实验（延长训练预算、低信噪比加权交叉熵、扩展复杂度与单线程 CPU 延迟测量、低信噪比类别混淆后处理）依次排除主实验结果的常见替代解释，确认主要结论不是欠训练或损失函数设计不当造成的。
4. 在文献校准基础上提出提案模型 `fusion_cldnn_stft`：以 CLDNN 风格 I/Q 编码器替换静态融合中的轻量 I/Q 分支，并结合相位旋转加循环时移信号域增强与标签平滑 0.1。在同一固定划分和三训练种子下，提案模型整体准确率超越主实验 `cldnn` 基线 1.35 个百分点，并在整体、低、中、高信噪比四项指标上同时正向。

本文实验范围限于 RadioML2016.10A 数据集、固定划分 `stratified_by_mod_snr_seed42` 和 3 个训练种子 42, 2025, 3407；其他数据集、真实外场信道与端到端部署效率的泛化性留作后续工作。




图 1.1 实验证据链示意图。

1.4 全文结构

第 2 章描述数据集、实验协议与评价方法。第 3 章介绍各模型结构、输入视图设计与提案模型。第 4 章报告主实验结果、扩展实验与统计检验。第 5 章讨论结论的解释范围与局限性。第 6 章总结全文并指出后续工作方向。

第二章 数据集、实验协议与评价指标

2.1 数据集与任务定义

本文主实验使用 RadioML2016.10A (RadioML 2016.10a) 数据集^[1]。与同系列的 RadioML 2016.10b 相比, 10a 版本的信道效应完全由模拟器生成, 而 10b 包含部分真实信道捕获片段; 两版本在调制类别数和总样本量上也存在差异, 本文全程使用 10a 版本, 以下不再赘述版本区分。该数据集共包含 220,000 个样本, 覆盖 11 类调制方式 (8PSK、AM-DSB、AM-SSB、BPSK、CPFSK、GFSK、PAM4、QAM16、QAM64、QPSK、WBFM) 和 20 个离散信噪比取值, 信噪比范围为 -20 dB 至 18 dB, 步长为 2 dB; 每个“调制方式-信噪比”组合包含 1,000 个样本。单个样本的输入形状为 2×128 , 其中第 0 维 (行索引 0) 为同相分量 (I), 第 1 维 (行索引 1) 为正交分量 (Q), 数据类型为 float32, 该维度顺序与原始 RML2016.10a.tar.bz2 解包后 pickle 文件中的存储顺序一致。

调制识别任务的形式化定义如下: 给定输入 $x \in \mathbb{R}^{2 \times 128}$, 目标是学习映射

$$f: \mathbb{R}^{2 \times 128} \rightarrow \{c_1, c_2, \dots, c_{11}\}, \quad (2.1)$$

其中 c_i 为 11 类调制方式之一。主实验仅以调制类别为分类目标, 不涉及信噪比估计、信道识别或部署系统优化。

表 2.1 主实验数据集与固定划分摘要

项目	设置
数据集	RadioML2016.10A; 220,000 个样本, 11 类调制方式, 20 个信噪比取值。
样本形状	2×128 I/Q 序列。
信噪比范围	$-20, -18, \dots, 18$ dB; 每个调制方式-信噪比组合 1,000 个样本。
固定划分	stratified_by_mod_snr_seed42; 按调制方式与信噪比分层。
训练/验证/测试	154,000 / 22,000 / 44,000, 对应 70% / 10% / 20%。
主实验规模	9 个模型行, 3 个训练种子 42, 2025, 3407, 共 27 个运行单元。
低信噪比分组	$\text{SNR} \leq -6$ dB; 测试集中每个训练种子对应 17,600 个低信噪比样本。

本文同时使用原始 I/Q 视图和 STFT 时频视图; 两种视图的特征提取参数 (包括 STFT 的窗函数选择、输出维度与归一化方式) 在本章「特征与训练设置」节中定义。主表中的模型身份由模型标识与输入视图共同决定, 后续结果均按这一身份汇总。

2.2 固定划分与训练种子

为降低采样随机性对模型比较的影响，本文采用固定划分 `stratified_by_mod_snr_seed42`（文件路径：`data/splits/rml2016a/stratified_by_mod_snr_seed42.npz`）。该划分以调制方式与信噪比的笛卡尔积（共 $11 \times 20 = 220$ 个组合）为分层键，使用随机种子 42 执行分层随机划分（等价于 `sklearn.model_selection.StratifiedShuffleSplit`），确保训练、验证和测试集在调制类别与信噪比的联合分布上保持一致。所有主实验模型行均使用同一划分，不为不同模型或不同训练种子重新生成测试集。

每个模型行使用 3 个训练种子 42, 2025, 3407。因此，表格中的均值和标准差表示在这 3 个训练种子上的协议内汇总。固定划分提高了模型行之间的可比性；多数据集、多划分和真实信道条件验证将在第 5 章作为协议局限讨论。

MCLDNN 行同样遵循该三种子协议。种子 2025 和 3407 出现训练崩溃：模型退化为对全部测试样本预测同一类别，整体准确率约为 0.091，接近 11 类均匀随机猜测基准 ($1/11 \approx 0.090$)。按照完整协议，相关运行仍计入三种子均值，导致主表中 MCLDNN 行的整体准确率均值和标准差均明显偏离其余行；读者在解释 MCLDNN 行性能时应结合附录 B 中的训练曲线（图 A.1）单独判断，而非将其视作同等有效的收敛结果。该异常已于第 4 章结果讨论中单独说明。

2.3 模型矩阵

主实验包含九个模型行，覆盖 I/Q 基线、时频单视图、卷积-循环混合、轻量结构、参数匹配控制和双视图融合六类。各模型的网络架构细节、输入视图选择与方法角色在第三章（表 3.1）中详细说明；本节仅列出模型标识符以备协议参照（各模型架构详见第三章表 3.1）：`cnn1d`、`resnet1d`（I/Q 基线）；`tfcnn_stft`（时频单视图）；`fusion_iq_stft`、`gated_fusion_iq_stft`（双视图融合）；`cldnn`、`mclldnn`（卷积-循环混合）；`lwamcnet`、`iq_param_matched`（轻量与参数控制）。所有模型行均在同一固定划分、相同训练超参和相同三训练种子下评估，模型身份由“模型标识 + 输入视图”共同决定。

2.4 特征与训练设置

STFT 视图使用汉宁（Hann）窗、窗口长度 32、跳跃步长（hop length）16（即重叠长度 16）的短时傅里叶变换配置。对长度为 128 的单通道 I/Q 序列，该参数设置生成的复数谱每通道输出形状为 $N_f \times N_t$ ，其中

$$N_f = \lfloor 32/2 \rfloor + 1 = 17 \quad (\text{频率 bin 数}), \quad N_t = \left\lfloor \frac{128 - 32}{16} \right\rfloor + 1 = 7 \quad (\text{时间帧数}).$$

STFT 分支取复数幅度 ($|X(\tau, k)|$; $X(\tau, k)$ 的数学定义见第三章式 (3.1)) 而不保留相位信息, 并对幅度谱按训练集统计量 (均值和标准差) 做逐特征归一化后输入卷积网络。STFT 在报告中作为可对比输入视图之一, 用于比较” 仅 I/Q” ” 仅 STFT” 和” I/Q+STFT” 三类模型; 受控延迟表中的前向耗时未计入完整的 STFT 预处理成本。

训练配置在主实验中保持一致: 优化器为 AdamW^[15] ($\beta_1=0.9, \beta_2=0.999, \epsilon=10^{-8}$ ^[16]), 学习率 10^{-3} , 权重衰减 10^{-4} , 批量大小为 256, 学习率调度为恒定 (无退火), 最大训练轮数为 30, 早停耐心值为 8 (依据验证集准确率)。上述设置沿用该领域已有文献^[2,17]的常用基准配置, 并通过附录 B 中的训练曲线验证收敛。报告中的训练随机性只通过 3 个训练种子的均值和标准差体现, 不额外引入未登记的训练轮次或子集实验。

2.5 评价指标与信噪比分组

本文报告整体准确率、低/中/高信噪比分组准确率、宏平均 F1 和均衡准确率。整体准确率反映固定测试集上的总体分类正确率; 宏平均 F1 对各调制类别等权平均, 能补充说明类别层面的均衡性; 均衡准确率 (Balanced Accuracy, 即各类别召回率的算术均值) 在类别样本量均衡的数据集 (如本数据集) 中等价于宏平均召回率, 引入该指标的目的在于量化各类别召回率之间的差异程度, 而非修正样本量不均衡对准确率的影响。

信噪比分组参照 RadioML 调制识别研究的常用划分惯例^[1]: 低信噪比定义为 $\text{SNR} \leq -6 \text{ dB}$ (即 $-20, -18, \dots, -6 \text{ dB}$, 共 8 个取值); 中等信噪比覆盖 -4 dB 至 6 dB (共 6 个取值); 高信噪比覆盖 8 dB 至 18 dB (共 6 个取值)。三组合计覆盖全部 20 个离散信噪比取值, 无遗漏亦无重叠。低信噪比结果在后文单独讨论, 因为这是本文判断 STFT 视图是否具有局部补充价值的关键范围。

2.6 配对统计检验协议

除三种子聚合指标外, 本文使用配对自助法和 McNemar 检验支撑主要模型对比较^[13-14], 并遵循多分类器比较中的多重检验写作规范^[18]。两类检验均基于主实验测试集预测结果, 匹配键为固定划分标识、训练种子和测试样本标识, 因而比较的是同一测试样本上两个模型的正确性差异。二者的适用场景不同: 配对自助法用于估计准确率差值 Δ_{acc} 的 95% 置信区间, 反映差值在重采样分布下的稳健性; McNemar 检验基于两模型在同一样本上的“正确/错误”二元列联表, 检验两个预测方向的不一致率是否存在系统性差异 (双侧 p 值)。所有比较均为协议内预先登记的比较对, 未对全量模型对实施系统性假设检验, 因而不采用 Bonferroni 校正。

本文采用 10,000 次重采样 (随机种子 42) 对准确率差值

$$\Delta_{\text{acc}} = \text{Acc}(m_a) - \text{Acc}(m_b) \quad (2.2)$$

构造 95% 置信区间，其中 m_a 、 m_b 为已登记比较对中的两个模型；置信区间不包含 0 时，认为该差值在重采样分布下具有稳健性。McNemar 检验则以 χ^2 统计量（双侧）计算两个模型预测差异的 p 值， $p < 0.05$ 认为差异显著。

统计检验覆盖已登记的整体准确率和低信噪比准确率比较。

2.7 协议边界说明

本章所述实验协议支撑以下结论：(1) 在固定划分 `stratified_by_mod_snr_seed42` 下，各模型行三种子均值与标准差的相互比较；(2) 相同测试集上的样本级配对统计检验；(3) 受控单线程前向耗时的大小关系比较。协议不支持的外推包括：跨数据集泛化（本实验仅在 RadioML2016.10A 上评估）、动态信道条件下的部署性能、以及基于超参搜索的最优性声明。Mock 运行、子集实验、筛查或诊断性运行不进入主表，仅作为工程记录保留。各证据包的路径、同步状态、环境差异和权重归档状态见附录 A；各图表数据来源详见附录 A 表 A.2。

2.8 扩展实验设计概述

为在不修改主表数值的前提下评估若干候选改进，本文额外设计了四类扩展实验，各自使用独立的输出目录与证据标签：

- 延长训练预算（`EXTENDED_BUDGET_3090`）；
- 分组 SNR 加权损失（`LOW_SNR_WEIGHTED_CE_3090`）；
- 提案融合模型协议化评估（`FUSION_CLDNN_STFT_AUG_LS_3090`）；
- 受控前向延迟补全（`CONTROLLED_LATENCY_EXTENDED`）。

所有扩展实验均与主实验共用固定划分 `stratified_by_mod_snr_seed42` 和三训练种子集合 42, 2025, 3407，但训练硬件为 NVIDIA RTX 3090（Ampere 架构），与主实验所用 RTX 4070（Ada 架构）不同。由于不同 GPU 架构下 cuDNN 选择的卷积算法不同，浮点运算顺序存在微小差异，跨标签的样本级配对统计检验无效；三种子均值层面的方向性比较仍受支持，但不做精确数值等价声明。任一扩展标签的结果均不改写主表数值。各扩展实验的超参细节见附录 B，结果分析见第 4.7 节。

第三章 模型方法与融合结构

3.1 输入表示

本文使用两类输入表示：原始 I/Q 序列与 STFT 时频图。

I/Q 序列。基带采样信号记为 $x_{\text{IQ}} \in \mathbb{R}^{2 \times 128}$ ，两行分别为同相分量 $I[n]$ 和正交分量 $Q[n]$ ， $n = 0, \dots, 127$ 。该表示直接保留时间采样结构，是大多数 AMC 文献的标准输入^[2,17,19]。

STFT 时频图。以复数形式拼合 $x_c[n] = I[n] + jQ[n]$ ，对 x_c 施加窗函数 $w[n]$ 后做短时傅里叶变换：

$$X(\tau, k) = \sum_{n=0}^{N-1} x_c[n] w[n - \tau] \exp(-j2\pi kn/N), \quad (3.1)$$

其中 τ 为帧起点， k 为频率箱索引， N 为 FFT 点数。实验中选取 Hann 窗，窗长 32 点、跳步 16 点，FFT 大小 32，输出幅度谱形状为 $\mathbb{R}^{1 \times 32 \times 7}$ （频率箱 $\times$ 时间帧）。时频图以线性幅度馈入 2D-CNN，不取对数，以避免引入与信号幅度标定相关的额外超参。

3.2 实验模型矩阵

表 3.1 汇总本文实现的全部模型、输入视图、方法角色和参数量，对应第 4.1 节主实验的 9 个模型行及提案模型。

表 3.1 实验模型矩阵：输入视图、方法角色与参数量

模型	输入视图	方法角色	参数量
cnn1d ^[2]	I/Q	三层 Conv1d I/Q 基线，复现早期 CNN-AMC 思路	37,131
resnet1d ^[20]	I/Q	残差连接深度卷积，提供更强 I/Q 对照	111,755
tfcnn_stft	STFT	单独检验 STFT 视图的判别容量	24,123
cldnn ^[3,19]	I/Q	三层 Conv1d + 单层 LSTM 卷积-循环混合	241,675
mcldnn ^[17]	I/Q	多分支 2D/1D 卷积 + 2 层 LSTM 多通道时空结构	406,199
lwamcnet ^[21]	I/Q	深度可分离残差卷积，参数量最低参考点	20,395
iq_param_matched	I/Q	参数量对齐融合模型的纯 I/Q 控制	136,395
fusion_iq_stft	I/Q+STFT	静态拼接双视图，检验时域-时频互补性	98,299
gated_fusion_iq_stft	I/Q+STFT	标量门控自适应加权双视图	134,780
fusion_cldnn_stft（提案）	I/Q+STFT	I/Q 分支升级为 CLDNN 风格，叠加信号域增强与标签平滑	286,000

3.3 I/Q 一维卷积基线

`cnn1d` 以三层一维卷积堆叠从原始 I/Q 序列提取局部时间特征^[2]。卷积核尺寸依次为 7、5、3，逐层扩大通道数（32-64-128）；第三层后接全局平均池化，消除对序列长度的依赖，最后以单层线性分类头输出 11 类 logits。表 3.2 给出逐层结构。

表 3.2 `cnn1d` 逐层结构（输入 [2, 128]，batch 维省略）

层	操作	输出形状	参数量
Conv1d-1	kernel 7, padding 3, 32ch, BN, ReLU	[32, 128]	480
MaxPool1d	kernel 2	[32, 64]	—
Conv1d-2	kernel 5, padding 2, 64ch, BN, ReLU	[64, 64]	10,304
MaxPool1d	kernel 2	[64, 32]	—
Conv1d-3	kernel 3, padding 1, 128ch, BN, ReLU	[128, 32]	24,832
AvgPool	AdaptiveAvgPool1d(1)	[128]	—
Linear	128 → 11	[11]	1,419

3.4 I/Q 残差卷积：resnet1d

`resnet1d` 在一维卷积堆叠中引入残差连接^[20]，允许堆叠更深特征层。主干由一个 stem 卷积层和三个残差块组成，Block2、Block3 以 stride=2 完成下采样；各残差块在通道数或步长不匹配时用 1×1 卷积对齐快捷路径，否则退化为恒等映射。全局平均池化后接线性分类头，共 111,755 个参数（表 3.3）。

表 3.3 `resnet1d` 逐层结构（输入 [2, 128]，batch 维省略）

层	操作	输出形状	说明
Stem	Conv1d(2→32, k=7, p=3), BN, ReLU	[32, 128]	—
Block1	ResBlock(32→32, stride=1)	[32, 128]	恒等快捷
Block2	ResBlock(32→64, stride=2)	[64, 64]	1×1 快捷
Block3	ResBlock(64→128, stride=2)	[128, 32]	1×1 快捷
AvgPool	AdaptiveAvgPool1d(1), flatten	[128]	—
Linear	128 → 11	[11]	—

各 ResBlock 由两层 Conv1d(k=3, p=1)+BN 构成，中间接 ReLU，快捷路径在块输出处求和后再经 ReLU。

3.5 卷积-循环混合模型：cldnn 与 mclnn

卷积-循环堆叠（CLDNN）最早在语音识别中系统描述^[19]：先以卷积层压缩局部变化并提取空间特征，再以 LSTM^[22] 建模帧间时序依赖，最后以全连接层分类。该思路被引入 AMC 比较研究^[3]，与纯卷积基线形成结构对照。

3.5.1 cldnn

本文 cldnn 为单流单层 LSTM 结构（表 3.4）。I/Q 序列经三层 Conv1d 提取局部特征，前两层后接 MaxPool1d 各做 2 倍下采样；第三层无池化，将特征序列转置为 LSTM 输入 $[B, 32, 128]$ ；单层 LSTM 取末时刻隐状态 $h_T \in \mathbb{R}^{128}$ ，送入两层 MLP 分类器（Dropout 0.5）。

表 3.4 cldnn 逐层结构（输入 $[2, 128]$ ，batch 维省略）

层	操作	输出形状	说明
Conv1d-1	kernel 7, padding 3, 64ch, BN, ReLU	$[64, 128]$	—
MaxPool1d	kernel 2	$[64, 64]$	—
Conv1d-2	kernel 5, padding 2, 128ch, BN, ReLU	$[128, 64]$	—
MaxPool1d	kernel 2	$[128, 32]$	—
Conv1d-3	kernel 3, padding 1, 128ch, BN, ReLU	$[128, 32]$	—
转置	transpose(1,2)	$[32, 128]$	LSTM 输入
LSTM	hidden=128, 1 层, batch_first, 取 h_T	$[128]$	—
Linear-1	$128 \rightarrow 128$, ReLU, Dropout(0.5)	$[128]$	—
Linear-2	$128 \rightarrow 11$	$[11]$	—

3.5.2 mclldnn

MCLDNN 引入多分支 I/Q 空间特征提取^[17]：以 $(2, 8)$ 核对联合 I/Q 矩阵做 2D 卷积提取联合特征，同时对 I、Q 各做因果 1D 卷积后经 $(1, 8)$ 核做空间融合；两路拼接后经 $(2, 5)$ 融合卷积压缩至时间序列，馈入 2 层 LSTM（hidden=128）；分类器为三层线性-SELU-Dropout 结构（Dropout 0.5）。表 3.5 给出逐层结构。

表 3.5 mclldnn 逐层结构（输入 $[2, 128]$ ，展开为 $[1, 2, 128]$ 馈入 2D 分支，batch 维省略）

分支 / 层	操作	输出形状	说明
联合空间分支			
Conv2d-joint	SamePad($1 \rightarrow 50$, $k=(2,8)$), ReLU	$[50, 1, 128]$	联合 I/Q 2D
独立分支 (I、Q 各一路)			
CausalConv-I	CausalConv($1 \rightarrow 50$, $k=8$), ReLU	$[50, 128]$	I 单通道
CausalConv-Q	CausalConv($1 \rightarrow 50$, $k=8$), ReLU	$[50, 128]$	Q 单通道
Stack I/Q	stack(I,Q, dim=2)	$[50, 2, 128]$	—
Conv2d-indep	SamePad($50 \rightarrow 50$, $k=(1,8)$), ReLU	$[50, 2, 128]$	—
融合阶段			
Concat	联合 + 独立, dim=1	$[100, 2, 128]$	—
Conv2d-fuse	$(100 \rightarrow 100, k=(2,5))$, ReLU	$[100, 1, 124]$	—
Squeeze+ 转置	squeeze(2), transpose(1,2)	$[124, 100]$	LSTM 输入
LSTM	hidden=128, 2 层, 取 h_T	$[128]$	—
Linear-1	$128 \rightarrow 128$, SELU, Dropout(0.5)	$[128]$	—
Linear-2	$128 \rightarrow 128$, SELU, Dropout(0.5)	$[128]$	—
Linear-3	$128 \rightarrow 11$	$[11]$	—

MCLDNN 训练异常说明。本实验中 mclldnn 三个训练种子表现出双峰分布：种子 42

接近正常，种子 2025 与 3407 退化至接近随机水平，导致整体准确率均值与标准差均不稳定（见第 4.6 节）。该异常作为负面证据完整保留，不从结果表中剔除。

3.6 轻量深度可分离卷积：lwamcnet

lwamcnet 对应文献^[21] 的 2016.10A 缩放方案：以 (2,5) 核提取初始 I/Q 空间特征，经三级深度可分离残差（DSC-Residual）栈精炼，每级含两个 DSC 残差单元和 (1,2) MaxPool；最后以分组深度卷积（GDWConv, k=(1,16)）重建特征，接单层线性分类器。深度可分离卷积将标准 2D 卷积分解为逐通道卷积（depthwise）和逐点卷积（pointwise），在保持感受野的同时大幅降低参数量，本文 20,395 个参数是所有模型中最少的（表 3.6）。

表 3.6 lwamcnet 逐层结构（输入 [2,128]，以 [1,2,128] 馈入首层，batch 维省略）

层	操作	输出形状	说明
Conv2d-0	(1→64, k=(2,5), p=(0,2)), ReLU	[64, 1, 128]	初始特征
DSC-Stack-1	64→32: ChannelFusion+2×DSCUnit+MaxPool(1,2)	[32, 1, 64]	—
DSC-Stack-2	32→32: ChannelFusion+2×DSCUnit+MaxPool(1,2)	[32, 1, 32]	—
DSC-Stack-3	32→32: ChannelFusion+2×DSCUnit+MaxPool(1,2)	[32, 1, 16]	—
GDWConv	groups=32, k=(1,16), ReLU, flatten	[32]	—
Linear	32 → 11	[11]	—

各 DSCUnit 含两个深度可分离 Conv2d (k=(1,5), p=(0,2)) 串联作残差路径，等效于对时间维做深度序列卷积。

3.7 STFT 单视图模型：tfcnn_stft

tfcnn_stft 仅以 STFT 幅度谱 $x_{\text{STFT}} \in \mathbb{R}^{1 \times 32 \times 7}$ 为输入，通过三层 2D-CNN 提取时频局部模式，经全局平均池化后以线性分类头输出预测。该模型单独度量 STFT 视图的判别容量，为解释双视图融合效果提供孤立视图参照（表 3.7）。

表 3.7 tfcnn_stft 逐层结构（输入 [1,32,7]，batch 维省略）

层	操作	输出形状	说明
Conv2d-1	kernel 3, padding 1, 16ch, BN, ReLU	[16, 32, 7]	—
MaxPool2d	kernel 2	[16, 16, 3]	—
Conv2d-2	kernel 3, padding 1, 32ch, BN, ReLU	[32, 16, 3]	—
MaxPool2d	kernel 2	[32, 8, 1]	—
Conv2d-3	kernel 3, padding 1, 64ch, BN, ReLU	[64, 8, 1]	—
AvgPool	AdaptiveAvgPool2d(1), flatten	[64]	—
Linear	64 → 11	[11]	—

3.8 参数匹配 I/Q 控制: `iq_param_matched`

双视图融合相比纯 I/Q 模型不仅引入额外视图，还增加 STFT 分支参数。为区分“额外参数”与“新增视图信息”的贡献，本文引入 `iq_param_matched`: 仅以 I/Q 为输入，通过四层 Conv1d(通道数 64-96-128-128)使参数量(136,395)与 `gated_fusion_iq_stft` (134,780) 基本对齐。当 `fusion_iq_stft` 在低信噪比区间相对该控制有小幅正差、整体区间为负差时，可将差异解释为视图信息而非参数规模的效果(表 3.8)。

表 3.8 `iq_param_matched` 逐层结构(输入 [2,128], batch 维省略)

层	操作	输出形状	说明
Conv1d-1	kernel 7, padding 3, 64ch, BN, ReLU	[64, 128]	—
MaxPool1d	kernel 2	[64, 64]	—
Conv1d-2	kernel 5, padding 2, 96ch, BN, ReLU	[96, 64]	—
MaxPool1d	kernel 2	[96, 32]	—
Conv1d-3	kernel 3, padding 1, 128ch, BN, ReLU	[128, 32]	—
Conv1d-4	kernel 3, padding 1, 128ch, BN, ReLU	[128, 32]	—
AvgPool	AdaptiveAvgPool1d(1), flatten	[128]	—
Linear-1	128 $\rightarrow$ 128, ReLU, Dropout(0.1)	[128]	—
Linear-2	128 $\rightarrow$ 11	[11]	—

3.9 静态 I/Q-STFT 融合: `fusion_iq_stft`

`fusion_iq_stft` 包含一个 I/Q 分支(IQBranch1D, 三层 Conv1d, 结构与 `cnn1d` 相同, 输出 128 维嵌入)和一个 STFT 分支(TimeFrequencyBranch2D, 三层 Conv2d, 结构与 `tfcnn_stft` 相同, 输出 64 维嵌入), 两分支独立提取特征后拼接经 MLP 分类:

$$z = [h_{IQ} \parallel h_{STFT}] \in \mathbb{R}^{192}, \quad \hat{y} = \text{MLP}_2(z), \quad (3.2)$$

MLP 分类头结构为 $192 \rightarrow 192$ (ReLU, Dropout 0.1) $\rightarrow 11$ 。该设计检验 STFT 时频特征与 I/Q 时域特征能否形成互补; 第 4.7 节的乘加量分析(I/Q 分支 2.0 M MACs vs. `resnet1d` 4.9 M)表明, I/Q 分支表征容量是限制融合性能的主要瓶颈。

3.10 标量门控融合: `gated_fusion_iq_stft`

`gated_fusion_iq_stft` 在双分支基础上增加可学习标量门控。两分支嵌入经投影层映射至公共维度 $d = 128$ ($W_{IQ} \in \mathbb{R}^{128 \times 128}$, $W_{STFT} \in \mathbb{R}^{128 \times 64}$), 拼接绝对差与逐元素乘积构成门控输入, 经小型 MLP 输出标量权重 $g \in (0, 1)$:

$$r = [z_{IQ} \parallel z_{STFT} \parallel |z_{IQ} - z_{STFT}| \parallel z_{IQ} \odot z_{STFT}] \in \mathbb{R}^{512}, \quad (3.3)$$

$$g = \sigma(W_2 \text{ReLU}(W_1 r)), \quad h = (1 - g) z_{\text{IQ}} + g z_{\text{STFT}} \in \mathbb{R}^{128}, \quad (3.4)$$

其中 $W_1 \in \mathbb{R}^{64 \times 512}$, $W_2 \in \mathbb{R}^{1 \times 64}$, ReLU 后施加 Dropout(0.1), σ 为 sigmoid。融合向量 h 经 $128 \rightarrow 128 \rightarrow 11$ 分类头输出 logits。门控输入加入绝对差与逐元素乘积, 使 MLP 能感知两视图间的差异幅度与方向, 从而做出样本级视图加权; 该门控不接受显式信噪比输入, 是自适应加权的可检验候选。




图 3.1 静态 I/Q-STFT 融合与标量门控融合结构对比。静态融合直接拼接两分支嵌入 ($\mathbb{R}^{128+64}$); 门控融合先投影至公共维度 ($\mathbb{R}^{128}$), 再以样本级标量权重组合。

3.11 提案模型与训练侧干预

3.11.1 架构动机

第 4.7 节乘加量分析显示, `fusion_iq_stft` 的 I/Q 分支 MACs 仅 2.0 M, 而 `resnet1d` 为 4.9 M; 换言之, “融合输给 CLDNN” 更可能源于 I/Q 表征容量不足, 而非多视图结构本身的局限。基于此, 提案模型 `fusion_cldnn_stft` 将 I/Q 分支替换为 `CLDNNIQBranch`——与 `cldnn` 共享卷积特征栈 (Conv1d 64-128-128ch) 加单层 LSTM^[19,22], 取末时刻隐状态 h_T 为分支嵌入; STFT 分支沿用 `TimeFrequencyBranch2D` (与 `tfcnn_stft` 结构相同^[23]), 分类头为小型 MLP^[24]:

$$h_{\text{IQ}} = \text{LSTM}(f_{1\text{D}}(x_{\text{IQ}}))_T, \quad h_{\text{STFT}} = f_{2\text{D}}(x_{\text{STFT}}), \quad \hat{y} = \text{MLP}_2([h_{\text{IQ}} \parallel h_{\text{STFT}}]). \quad (3.5)$$

模型总参数量 286 k (介于 `cldnn` 的 241.7 k 与 `mcldnn` 的 406.2 k 之间), 逐层结构见表 3.9。

3.11.2 信号域增强

信号域增强仅在训练集启用, 以保留 I/Q 物理可解释性。本文采用两种变换:

表 3.9 提案模型 fusion_cldnn_stft 逐层结构 (batch=1, 形状按各分支独立标记)

分支 / 层	操作	输出形状	说明
<i>I/Q 分支 (CLDNNIQBranch)</i>			
Conv1d-1	kernel 7, padding 3, 64ch, BN, ReLU	[64, 128]	—
MaxPool1d	kernel 2	[64, 64]	—
Conv1d-2	kernel 5, padding 2, 128ch, BN, ReLU	[128, 64]	—
MaxPool1d	kernel 2	[128, 32]	—
Conv1d-3	kernel 3, padding 1, 128ch, BN, ReLU	[128, 32]	—
LSTM	hidden=128, 1 层, 取 h_T	[128]	batch_first
<i>STFT 分支 (TimeFrequencyBranch2D)</i>			
Conv2d-1	kernel 3, padding 1, 16ch, BN, ReLU	[16, 32, 7]	—
MaxPool2d	kernel 2	[16, 16, 3]	—
Conv2d-2	kernel 3, padding 1, 32ch, BN, ReLU	[32, 16, 3]	—
MaxPool2d	kernel 2	[32, 8, 1]	—
Conv2d-3	kernel 3, padding 1, 64ch, BN, ReLU	[64, 8, 1]	—
AvgPool	AdaptiveAvgPool2d(1), flatten	[64]	—
融合分类头			
Concat	[128] [64]	[192]	—
Linear-1	192 → 192, ReLU, Dropout(0.1)	[192]	—
Linear-2	192 → 11	[11]	—

随机相位旋转。以概率 0.5 对每个训练样本施加角度 $\theta \sim \mathcal{U}[0, 2\pi)$ 的相位旋转:

$$\begin{bmatrix} I'[n] \\ Q'[n] \end{bmatrix} = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \begin{bmatrix} I[n] \\ Q[n] \end{bmatrix}, \quad n = 0, \dots, 127. \quad (3.6)$$

相位旋转保持各调制信号的星座图结构, 不改变有效 SNR, 分类标签不变。

随机循环时移。以概率 0.5 对样本施加随机整数时移 $k \sim \mathcal{U}\{-32, \dots, +32\}$:

$$I'[n] = I[(n - k) \bmod 128], \quad Q'[n] = Q[(n - k) \bmod 128]. \quad (3.7)$$

循环时移扩充序列对齐多样性, 不影响频域特征分布, 有效 SNR 与分类标签不变。

幅度缩放与加性高斯噪声因改变有效 SNR 而不予采用; 图像式 mixup 因对 I/Q 线性插值缺乏物理可解释性^[25-26]也不采用。图 3.2 给出四种情形的波形可视化对比。

3.11.3 标签平滑

标签平滑 $\epsilon = 0.1$ ^[27] 将 one-hot 目标 $\mathbf{1}_y$ 替换为软目标分布:

$$q_k = \begin{cases} 1 - \epsilon + \epsilon/K & k = y, \\ \epsilon/K & k \neq y, \end{cases} \quad K = 11. \quad (3.8)$$

该操作抑制过度自信，是分类任务的常见正则化手段，在本实验中由 `train.loss` 字段配置。

3.11.4 三项干预的不平等贡献

三项干预对整体准确率的贡献并不对等：消融实验（第 4.7.4 节）显示，架构升级本身对整体准确率的增益约 0 pp（相对 `cln` 仅 -0.13 pp，在种子噪声范围内）；信号域增强是主要贡献项，净增益约 $+1.55$ pp（`arch+aug` vs. `arch_only`，McNemar $p \approx 6 \times 10^{-78}$ ）；标签平滑则略有负效（ -0.19 pp，95% CI $[-0.0033, -0.0006]$ ， $p = 0.0155$ ）。因此，提案模型的实质贡献应理解为“验证信号域增强在卷积-循环融合架构上的有效性”，架构升级与标签平滑均非主要来源。




图 3.2 信号域增强示例（QPSK @ +6 dB 单样本）。(a) 原始；(b) 相位旋转 $\theta = \pi/3$ ；(c) 循环时移 $k = +8$ ；(d) 两者叠加。I/Q 通道线型见图例。

3.12 实现细节与比较纪律

所有模型使用 PyTorch 2.9.1+cu128^[28] 与 NVIDIA driver 570.* 实现，数据集固定划分（训练/验证/测试集一次性确定，全程不变）。主实验 9 个模型行在 RTX 4070 Ti (Ada, sm_89) 上训练；提案模型及消融变体在 RTX 3090 (Ampere, sm_86) 上训练。两批实验的硬件差异作为协议混淆因素显式登记，不参与跨批直接数值比较。

共用训练设置：优化器 AdamW^[15-16]，学习率 $\eta = 10^{-3}$ （AMC 卷积网络的常用设定^[17,29]），权重衰减 10^{-4} ^[30]，批量大小 256。主实验矩阵最大训练轮数 30，早停耐心值 8（依据验证集准确率）；提案模型及消融变体最大轮数 50，早停耐心值 15，额外采用

5 轮线性 warmup 加 cosine annealing 学习率调度^[31]。损失函数默认为标准交叉熵；提案模型加 $\varepsilon = 0.1$ 标签平滑（式 3.8）。所有模型以种子集合 {42, 2025, 3407} 各训练一次，报告均值 $\pm$ 标准差。

统一超参作用于主实验矩阵全部 9 个模型，不做模型级事后调参，以保持比较纪律。提案模型及消融变体独立评估，结论限于第 4.7.4 节范围内，不与主实验矩阵做直接数值比较。本章方法描述限于已登记模型与训练设置，不引入未在第 4 章评估的诊断性候选。

第四章 实验结果与统计检验

本章在第 2 章定义的固定划分、模型矩阵和评价指标基础上展示主实验结果。除特别说明外，所有数值均来自自己同步的主实验聚合表、低信噪比分组表、受控 CUDA 前向延迟表以及配对统计检验表。本章不新增训练、不重建主表，也不把诊断性输出纳入性能结论。

4.1 主实验整体结果

表 4.1 汇总 9 个模型行在 3 个训练种子上的结果。该表同时列出整体准确率、宏平均 F1、均衡准确率、低/中/高信噪比分组准确率和参数量，用于从总体性能、信噪比分组和模型规模三个角度观察结果。

表 4.1 固定划分主实验结果（三训练种子均值与标准差）

模型行	输入视图	整体准确率	宏平均 F1	均衡准确率	低信噪比准确率	中信噪比准确率	高信噪比准确率	参数量
cnnid	I/Q ^[2]	0.5820 ± 0.0045	0.5952 ± 0.0039	0.5820 ± 0.0045	0.2095 ± 0.0055	0.7956 ± 0.0018	0.8650 ± 0.0066	37,131
resnet1d	I/Q ^[20]	0.5959 ± 0.0005	0.6122 ± 0.0007	0.5959 ± 0.0005	0.2059 ± 0.0025	0.8197 ± 0.0041	0.8922 ± 0.0015	111,755
tfcnn_stft	STFT	0.5063 ± 0.0018	0.5093 ± 0.0064	0.5063 ± 0.0018	0.1713 ± 0.0039	0.6900 ± 0.0055	0.7693 ± 0.0036	24,123
fusion_iq_stft	I/Q+STFT	0.5771 ± 0.0017	0.5849 ± 0.0035	0.5771 ± 0.0017	0.2213 ± 0.0061	0.7858 ± 0.0062	0.8428 ± 0.0058	98,299
clldnn ^[19]	I/Q	0.6129 ± 0.0005	0.6332 ± 0.0034	0.6129 ± 0.0005	0.2224 ± 0.0052	0.8396 ± 0.0029	0.9070 ± 0.0034	241,675
mcldnn [†] [17]	I/Q	N/A [†]	N/A [†]	N/A [†]	0.2121 ^{††}	0.7729 ^{††}	0.8391 ^{††}	406,199
lwamcnet ^[21]	I/Q	0.5511 ± 0.0018	0.5579 ± 0.0080	0.5511 ± 0.0018	0.2025 ± 0.0085	0.7510 ± 0.0067	0.8160 ± 0.0035	20,395
iq_param_matched	I/Q	0.5945 ± 0.0005	0.6124 ± 0.0046	0.5945 ± 0.0005	0.2163 ± 0.0071	0.8121 ± 0.0073	0.8809 ± 0.0035	136,395
gated_fusion_iq_stft	I/Q+STFT	0.5719 ± 0.0020	0.5853 ± 0.0045	0.5719 ± 0.0020	0.2113 ± 0.0067	0.7840 ± 0.0048	0.8407 ± 0.0046	134,780

[†] MCLDNN 三种子呈现极端双峰分布（seed 42 正常收敛至 0.5684，seed 2025 与 seed 3407 单类塌陷至 11 类均匀基准 0.0909）。
 算术均值（0.2501）无法反映模型真实拟合能力，属于统计失效，故整体准确率、宏平均 F1 与均衡准确率三列均标记 N/A，不参与模型间排序。
 后续与其他模型比较一律基于 seed 42 单种子结果（整体准确率 0.5684），并在每处比较中明确标注口径。详见第 4.6 节。


^{††} SNR 分组列改用 seed 42 单种子真值；seed 2025 与 3407 因单类塌陷不列出、不参与比较。

在当前固定协议内，clldnn 的整体平均准确率为 0.6129，宏平均 F1 为 0.6332，是 9 个模型行中测得的最高结果。主要 I/Q 基线中，resnet1d 的整体准确率为 0.5959，参数匹配控制模型 iq_param_matched 为 0.5945，二者与 CLDNN 的差距分别约为 1.70 和 1.84 个百分点。该结果说明本实验矩阵中的固定划分表现。

iq_param_matched 与 resnet1d 的整体准确率几乎相等，分别为 0.5945 和 0.5959，因此它的价值并不在于形成新的强基线排序，而在于作为融合解释的边际控制。它只使用 I/Q 输入，同时参数量接近双视图融合模型；当 fusion_iq_stft 相对它在低信噪比范围有小幅正差值、整体范围又为负差值时，这个对照能帮助区分“额外参数规模”与“新增 STFT 视图”带来的影响。


图 4.2 显示，静态 I/Q-STFT 融合在低信噪比区间接近 CLDNN，但在中高信噪比区间没有保持同等优势。门控融合曲线也未相对静态融合形成稳定改善。因此，主结果首先支持的是“不同信噪比区间存在性能权衡”，而不是“融合结构整体优于 I/Q 模型”。

图 4.3 从类别维度补充表 4.1。不同模型在 AM、PSK、QAM 和 WBFM 等类别上的表现并不均匀，说明整体准确率不能完全代表每一类调制方式的识别难度。低信噪比



Data source: main_table_metrics.csv; values are mean $\pm$ std across seeds 42, 2025, 3407.

图 4.1 9 个模型在 4 个 SNR 分组下的准确率对比（三种子均值 $\pm$ std, main_table_metrics.csv）。MCLDNN 因三种子双峰分布（详见第 4.6 节），均值柱不具统计意义，仅保留用于展示异常形态。



Data source: metrics_per_snr.csv for seeds 42, 2025, and 3407; bands show across-seed std.

图 4.2 代表模型在 -20 至 $+18$ dB 的逐 SNR 准确率与宏平均 F1（三种子聚合，metrics_per_snr.csv）。




图 4.3 9 个模型 $\times$ 11 类调制的整体类别准确率热力图 (metrics_per_class.csv)。分析也应结合类别混淆结构解释。

4.2 整体性能的配对检验

表 4.2 给出 CLDNN 与两个主要 I/Q 参照模型的整体准确率配对检验。差值定义为前一个模型准确率减去后一个模型准确率。

表 4.2 CLDNN 与主要 I/Q 参照模型的整体准确率配对检验

比较	范围	准确率差值	95% 置信区间	McNemar 检验
cldnn vs. resnet1d	整体测试集	0.0170	[0.0153, 0.0187]	$p < 0.001$
cldnn vs. iq_param_matched	整体测试集	0.0185	[0.0168, 0.0202]	$p < 0.001$

关于配对统计检验独立性假设的坦白。本章所有配对统计检验所用的 $n = 44,000$ 个测试样本，在按（调制类别 $\times$ SNR）联合分层后，同一 cell 内的约 1,000 个样本来自相同的发射机仿真与信道实现，不满足 McNemar 检验要求的逐样本独立性假设。该 cell 内相关性使有效样本量（effective sample size, ESS）可能比名义 $n = 44,000$ 低一到两个量级——即便保守估计 $ESS \sim 2,000\text{--}4,000$ （每 cell 视为一个近似独立单元），大样本下任何系统性微小差异仍会产生极小 p 值，但这与效应量的实际意义无关。

因此，本章以效应量（准确率差值）与 95% 置信区间作为主要证据，McNemar p 值仅作辅助参考，不单独构成“效果成立”的判据。读者应将 $p < 0.001$ 解读为“在独立

性假设下方向得到支持”，而非“效应量在实际意义上足够大”。所有仅 $p < 0.001$ 的项统一标注为“ $p < 0.001$ ”；决策相关的临界 p 值（如 $p = 0.0155$ 、 $p = 0.476$ 、 $p = 0.941$ ）保留具体数值。




图 4.4 已登记模型对配对自助法的准确率差值与 95% CI (10000 重采样, paired_bootstrap_accuracy_deltas.csv)。差值方向为 model_a - model_b。

两项比较的置信区间均未跨越 0，说明 CLDNN 相对 resnet1d 和 iq_param_matched 的整体优势方向在当前配对样本上得到支持。McNemar 检验提供同方向的辅助证据；但鉴于上述独立性效应量缺口， p 值本身对效应量信息有限，效应量与置信区间才是本章所有比较的主要参照。统计表覆盖已登记模型对；表外模型对留给后续完整检验。

多重比较方面，本文将统计包中的 6 对已登记模型比较作为比较族，并分别考察 overall 与低信噪比两个范围。Holm-Bonferroni 修正后^[32]，overall 范围内 6 对比较均仍达到统计支持；低信噪比范围内，fusion_iq_stft vs. cldnn 的差值置信区间跨 0 且 McNemar $p = 0.476$ ，保持不显著，其余 5 对仍达到统计支持。该修正不改变主要解释：CLDNN 的整体优势方向稳定，静态融合相对 CLDNN 的低信噪比优势没有统计支持，门控融合相对静态融合为负结果。

4.3 低信噪比下的融合权衡

低信噪比区域定义为 $\text{SNR} \leq -6 \text{ dB}$ 。在这一范围内，cldnn 的平均准确率为 0.2224，fusion_iq_stft 为 0.2213，iq_param_matched 为 0.2163，gated_fusion_iq_stft 为 0.2113。静态融合接近 CLDNN，并高于参数匹配 I/Q 控制模型，但差异幅度较小。




图 4.5 代表模型在低信噪比区间（ $\text{SNR} \leq -6\text{dB}$ ）的逐 SNR 准确率曲线（low_snr_table.csv）。


4.3.1 低信噪比混淆边界推移的物理分析

图 4.6 是解释低信噪比融合权衡的核心证据。它不是把两个模型的平均准确率相减，而是统计同一测试样本上“模型 A 正确、模型 B 错误”和相反方向的分歧比例，因此可以观察分歧出现在哪些 SNR 点。若 STFT 视图能提供稳定的新增判别信息，静态融合相对 I/Q 参照模型应在低信噪比区间持续出现正向净分歧；实际结果更像局部正向与局部负向的交替图谱。

相对 `iq_param_matched`，静态融合在 -14 、 -12 、 -10 dB 的净分歧分别约为 $+1.08$ 、 $+1.74$ 、 $+1.94$ 个百分点；STFT 视图在 -14 至 -10 dB 区间表现出方向一致的局部正向净分歧，但单点幅度未达统计显著（单 SNR 点约 3,300 个配对样本， $+1$ pp 量级差异 95% CI 宽度约为 ± 1.0 pp）。在 -8 和 -6 dB，净分歧转为 -0.80 和 -0.36 个百分点，表明这种局部正向分歧没有覆盖整个低信噪比区间。相对 `clldnn` 时，静态融合在 -14 和 -10 dB 有 $+1.35$ 和 $+1.24$ 个百分点的局部正向净分歧，却在 -8 和 -6 dB 出现 -1.77 和 -1.76 个百分点的反向分歧。这解释了为什么低信噪比总差值为 -0.001061 且置信区间跨 0：融合不是全局领先，而是在不同 SNR 点上互相抵消。

关于单点不确定性的补充。单 SNR 点的净分歧基于约 3,300 个配对样本（三种子合并），单点 $+1$ pp 量级差异的 95% 置信区间宽度约为 ± 1.0 pp，多个个别点的局部正向分歧在该不确定性下不可单独声明显著。本节的解释基于多点方向一致的整体图谱，

Paired correctness disagreements by SNR



Data source: predictions_test.csv in predictions_archive_20260508; positive bars favor the first model in each panel.

图 4.6 关键模型对在各 SNR 点的配对正确性净分歧（“仅 A 正确”占比 - “仅 B 正确”占比，predictions_test.csv 三种子聚合）。

不依赖任何单点差异。

门控融合的分歧图进一步强化负结果判断。相对静态融合，门控融合在 -16 到 -6 dB 多数点为负向净分歧，其中 -10 dB 约为 -2.50 个百分点， -12 dB 约为 -1.65 个百分点。这说明当前标量门控没有学到“低信噪比时增加 STFT、较高信噪比时回退 I/Q”的策略，反而在静态融合已有局部正差值的位置损失了样本。

表 4.3 低信噪比关键比较与配对检验摘要

比较	Low-SNR Acc.	Δ 与 95% CI	McNemar p	解释边界
CLDNN vs IQ matched	22.24% vs. 21.63%	+0.006042 [+0.003125, +0.008883]	$3.88e-05$	方向由当前 paired test 支持。
Fusion vs CLDNN	22.13% vs. 22.24%	-0.001061 [-0.003939, +0.001838]	0.476	CI 跨 0，不能声称优势。
Fusion vs IQ matched	22.13% vs. 21.63%	+0.004981 [+0.001970, +0.007973]	0.00106	方向由当前 paired test 支持。
Gated vs Fusion	21.13% vs. 22.13%	-0.010019 [-0.012746, -0.007292]	$1.23e-12$	方向由当前 paired test 支持。

相对于 CLDNN，静态 I/Q-STFT 融合的低信噪比准确率差值为 -0.0011 ，95% 置信区间为 $[-0.0039, +0.0018]$ ，区间跨越 0；McNemar 检验 $p = 0.476$ （辅助参考）。效应量与 CI 共同支持“接近但未优于 CLDNN”的解释。




图 4.7 静态 fusion_iq_stft 相对 iq_param_matched 与 CLDNN 在低 SNR 各调制类别的召回率差值 Δrecall (confusion_low_snr.csv 三种子聚合)。

相对于参数匹配 I/Q 控制模型，静态融合的低信噪比准确率差值为 0.0050，95% 置信区间为 [0.0020, 0.0080]，McNemar 检验 $p = 0.001$ 。但同一比较在整体测试集上的准确率差值为 -0.0174 ，95% 置信区间为 $[-0.0193, -0.0155]$ 。因此，合理结论是：STFT 视图在本实现中测得低信噪比局部小幅正向差值，但伴随整体准确率下降。

图 4.7 进一步说明，静态融合的低信噪比差异并非对所有调制类别同向。相对 iq_param_matched，静态融合在 QAM16 上的召回率下降 7.4 个百分点，却在 QAM64 上的召回率上升 8.9 个百分点，接近等幅、方向相反。这一现象的物理根源在于 **STFT 幅度谱对相位信息的不可逆丢弃**。QAM16 与 QAM64 同属正交幅度调制族，低信噪比下两者的星座点云严重重叠；区分二者的核心线索之一是相位旋转结构的细粒度差异——QAM16 的 4×4 星座网格与 QAM64 的 8×8 星座网格在 I/Q 平面上的相位排列不同。STFT 幅度谱作为时频能量分布的投影，**系统性地丢弃了瞬时相位信息**，构成对相位敏感特征的信息有损投影 (lossy projection)。引入该视图使分类器对 QAM 子族的判别边界发生整体偏移——以 QAM16 的召回损失换取 QAM64 的召回提升。

关键在于，QAM16 召回率 -7.4 pp 与 QAM64 召回率 $+8.9$ pp 的接近等幅反向变化**不支持单一“干扰”假设**：若 STFT 视图仅为噪声干扰，两类 QAM 的召回率应同向下降。实际观察到的反向变化表明 STFT 幅度域投影确实携带了可供分类器利用的结构信息，但该信息使 QAM16/QAM64 之间的判别边界发生了系统性偏移，而非提供额外的类别区分度。净效应取决于评价指标的类别权重选择——在均衡权重下，一类的召回增益被另一类的等量损失抵消。这是引入信息有损视图的固有代价，而非多视图融合所声称的“互补性”的体现。

但本文未做 logits 分布检查、STFT 分支消融或梯度显著性归因等验证实验，因此上述物理机制保留为基于通信原理的诠释性解释，不作为因果意义上的已确立结论。附录图 A.2 给出代表模型在低信噪比范围内的行归一化混淆矩阵，作为类别混淆解释的补充。

4.4 门控融合负结果

`gated_fusion_iq_stft` 的整体准确率为 0.5719，低信噪比准确率为 0.2113，均低于静态融合 `fusion_iq_stft`。配对检验也支持这一判断：门控融合相对静态融合的整体准确率差值为 -0.0052 ，95% 置信区间为 $[-0.0068, -0.0035]$ ，McNemar 检验 $p < 0.001$ （辅助参考）；低信噪比范围内的差值为 -0.0100 ，95% 置信区间为 $[-0.0127, -0.0073]$ ，McNemar 检验 $p < 0.001$ 。

由于差值定义为“门控融合减静态融合”，上述负值说明当前标量门控机制没有改善静态融合。本文因此将门控融合作为负结果保留，不写作“门控提升鲁棒性”或“门控融合整体准确率高於静态融合”。

门控权重 g 的逐 SNR 诊断实验。为诊断门控失败的机制，本文在 RTX 3090 上以相同三训练种子重训 `gated_fusion_iq_stft`（证据标签 `GATED_FUSION_DIAGNOSTIC_3090`），并在测试集上提取逐样本标量门控权重 $g \in [0, 1]$ （ $g = 0$ 表示仅 I/Q、 $g = 1$ 表示仅 STFT）。三种子整体准确率分别为 0.5701 / 0.5736 / 0.5763（均值 0.5733），与 Stage 5A 主表值（0.5719）一致，确认门控融合的负结果在新硬件上可复现。

发现一： g 呈现清晰的 SNR 单调递减模式。以 seed 42 为例，逐 SNR 的 g 均值从 -20 dB 的 0.787 单调下降至 $+18$ dB 的 0.125（表 4.4）。这说明门控网络**确实学到了 SNR 条件信息**：低信噪比时偏好 STFT 视图，高信噪比时偏好 I/Q 视图。该方向与物理直觉一致——低信噪比下 I/Q 的瞬时幅度和相位结构被噪声严重扰动，STFT 的局部频率能量分布可能提供更稳定的特征。

表 4.4 门控权重 g 的逐 SNR 分布（seed 42，测试集）。 $g \rightarrow 1$ 偏好 STFT， $g \rightarrow 0$ 偏好 I/Q。

SNR (dB)	-20	-18	-16	-14	-12	-10	-8	-6	-4	-2
g 均值	0.787	0.785	0.772	0.751	0.711	0.636	0.509	0.339	0.200	0.148
g 标准差	0.064	0.064	0.079	0.113	0.164	0.219	0.271	0.265	0.236	0.234
SNR (dB)	0	+2	+4	+6	+8	+10	+12	+14	+16	+18
g 均值	0.128	0.126	0.122	0.126	0.120	0.123	0.125	0.127	0.125	0.125
g 标准差	0.237	0.241	0.239	0.241	0.238	0.237	0.239	0.244	0.240	0.239

发现二： g 的跨种子稳定性差。三种子的 g 全局均值分别为 0.344（seed 42）、0.331（seed 2025）和 0.184（seed 3407），全局标准差为 0.351 / 0.331 / 0.255。seed 3407 的门控均值仅为 seed 42 的一半，说明标量门控网络在不同初始化下收敛到不同的操作点。这种跨种子不稳定性表明，当前门控输入特征（绝对差与逐元素乘积）不足以可靠地驱动视图加权。

发现三：正确的门控方向未转化为分类增益。尽管门控网络学到了“低信噪比偏好 STFT、高信噪比偏好 I/Q”的方向，整体准确率（0.5733）仍低于静态融合（0.5851，延长预算同硬件值）和纯 CLDNN 基线（0.6145）。这排除了第 4.7.1 节假设中的“ g 退化

为常数”解释，转而支持容量与优化假设：标量门控 sigmoid 压缩使加权决策过于粗糙（全局一维标量无法区分类别与样本层面的视图偏好），且门控训练增加了优化负担，在有限训练预算下劣于固定权重。多头/向量门控及显式 SNR 条件门控的对照实验保留为后续工作。




图 4.8 门控权重 g 的逐 SNR 分布（左，三种子）与全局统计（右）。 $g \rightarrow 1$ 偏好 STFT， $g \rightarrow 0$ 偏好 I/Q。


4.5 复杂度与受控 CUDA 前向延迟

复杂度与延迟结果来自 CUDA 设备上的受控前向传播测量。测量使用 50 次预热和 200 次计时迭代，批量大小为 1 和 256；表 4.5 摘录与结果解释最相关的模型行。

表 4.5 模型参数量与受控 CUDA 前向延迟摘录

模型行	参数量	批量 1 延迟/ms	批量 256 延迟/ms	测量边界
resnet1d	111,755	2.081249	2.098535	仅 CUDA 前向传播。
iq_param_matched	136,395	1.250068	1.273155	仅 CUDA 前向传播。
cldnn	241,675	1.306352	1.543833	仅 CUDA 前向传播。
fusion_iq_stft	98,299	1.844381	1.857622	STFT 预处理未计入。
gated_fusion_iq_stft	134,780	2.535083	2.545334	STFT 预处理未计入。

这些数值说明同一受控测量条件下不同模型的参数量和 CUDA 前向耗时背景。例如，CLDNN 参数量较高但前向延迟并非最高；门控融合参数量低于 CLDNN，却具有



Data sources: main_table_metrics.csv and complexity_latency_table.csv. CONTROLLED_LATENCY only; STFT preprocessing excluded.

图 4.9 9 个模型的整体准确率 vs. CUDA 批量 1 前向延迟, 气泡大小 $\propto$ 参数量 (warmup 50 / measured 200, complexity_latency_table.csv)。STFT 预处理耗时未计入。

更高的受控前向延迟。CPU 延迟、FLOPs/MACs 和 STFT 预处理完整耗时需要独立测量协议支撑。

关于 MACs 与部署效率的关系。需要注意, MACs 与实测前向延迟的关系并非单调: fusion_iq_stft MACs 仅 2.0 M 但批量 1 延迟 1.84 ms, cldnn MACs 8.7 M 但批量 1 延迟仅 1.31 ms。差异主要来自 STFT 分支 2D 卷积结构与现代 GPU 上 1D 卷积的不同优化路径, 而非纯算量。这说明 MACs 不是部署效率的可靠代理; 第 4.7.1 节以参数量论证 I/Q 分支表征容量, 而非以 MACs 论证。

4.6 MCLDNN 异常与负结果保留

mclldnn 三个训练种子的整体准确率为 0.5684 / 0.0909 / 0.0909, 宏平均 F1 为 0.5891 / 0.0152 / 0.0152。其中 seed 42 收敛到 0.5684; seed 2025 和 seed 3407 单类塌陷至 11 类均匀基准 0.0909 (宏平均 F1 0.0152), 表现为近似随机水平的单类预测。seed 42 在低/中/高 SNR 子集上的准确率分别为 0.2121 / 0.7729 / 0.8391。

统计失效声明。因 MCLDNN 三种子呈现极端双峰分布 (seed 42 正常收敛至 0.5684, seed 2025 与 seed 3407 单类塌陷至 11 类均匀基准 0.0909), 算术均值 (0.2501) 无法反映模型真实拟合能力, 属于统计失效。该数值**绝对禁止**参与任何宏观性能排序、图表展示或文本论述。表 4.1 中 MCLDNN 的整体准确率、宏平均 F1 与均衡准确率三列已标记 N/A。后续与其他模型的比较一律基于 seed 42 单种子结果 (整体准确率 0.5684), 并在每处比较中明确标注口径。

表 4.6 MCLDNN 异常训练种子的测试集预测分布

训练种子	主要预测类别	预测样本数	现象判断
2025	8PSK (类别 0)	44,000 / 44,000	单类塌陷
3407	AM-DSB (类别 1)	44,000 / 44,000	单类塌陷

表 4.6 进一步确认, seed 2025 并不是”多数类别偏置”, 而是全部测试样本均预测为 8PSK; seed 3407 则全部预测为 AM-DSB。该现象与一个 11 类均衡测试集上的 0.090909 准确率一致, 属于单类塌陷而非普通方差波动。




图 4.10 9 个模型在 3 个训练种子上的整体与低信噪比准确率稳定性散点 (metrics_test.json)。

本文保留这两个异常种子, 因为它们属于已登记的固定协议运行。删除异常种子并重算主表会改变实验协议, 也会掩盖训练稳定性问题。协议纪律要求主表保留 3 个训练种子的完整结果; 研究责任则要求对失败形态给出可检验解释, 避免把异常简单归为”随机坏运气”。

当前可提出三类诊断假设。第一, 学习率与权重衰减组合可能不适合 MCLDNN: 全模型统一使用学习率 10^{-3} 、权重衰减 10^{-4} 、batch size 256, 有利于协议对齐, 但对多分支卷积、融合卷积和 LSTM 串联的结构未必公平。第二, 初始化敏感性可能更强: seed 42 正常收敛而 seed 2025/3407 塌陷, 提示某些初始门控、卷积核或循环层状态可能把梯度引向退化分类头。第三, 输入格式或维度排列可能与该实现的结构假设不完全匹配:

MCLDNN 常依赖对 I/Q 分支、时间维和通道维的特定组织方式，若实现中的 reshape、permute 或分支拼接与预期不一致，模型可能在部分初始化下无法形成有效类别边界。

因此，沿用统一超参对 MCLDNN 公平性不足。统一学习率、权重衰减和 batch size 的优点是避免为单个模型做事后调参，保证主表比较纪律；缺点是把结构稳定性、优化敏感性和超参适配能力混在一起。更负责的后续诊断应预先登记 MCLDNN 专用学习率网格、初始化重复、梯度范数监控、输入张量形状单元测试和早期 logits 分布检查，并在新的输出目录中形成独立证据。附录图 A.4 单独展示 MCLDNN 三个训练种子的差异。

4.7 扩展实验与提案模型

本节扩展实验在 RTX 3090 上完成，与 Stage 5A 的 RTX 4070 Ti 硬件不同；跨硬件的样本级配对统计检验因此不可直接执行，三种子均值层面的解释仍受支持。所有扩展实验仅在本节用作协议化解释证据，不修改主表数值与统计检验。

4.7.1 扩展实验摘要

四类敏感性 / 诊断扩展实验（延长预算、低信噪比加权交叉熵、扩展复杂度、低信噪比混淆后处理）的发现汇总于表 4.7；详细每 cell 数据见同名独立证据标签的报告文档。

三条要点支撑后续提案模型解释。其一，延长预算不改写主表排序，也不缓解低信噪比退化，Stage 5A 主表不是欠训练造成。其二，分组 SNR 加权 CE 是不合算干预，单凭损失加权无法同时改善低信噪比与整体性能。其三，深低信噪比 (≤ -16 dB) 退化为偏置预测 AM-SSB 是 8 个稳定模型共同出现的经验现象。在本协议内已评估的 9 个稳定模型中均未观察到对该下限的突破。该下限是协议内的经验观察，并非信息论意义下的最优分类器边界——其作为“AMC 任务深低信噪比理论下限”的解读需要独立的类条件可分性分析或贝叶斯错误率估计来支撑，本文未做此论证。

fusion_iq_stft 整体参数量 98 K，其中 I/Q 分支约占 50 K，显著低于 CLDNN 的 241 K（表 4.5 与表 4.8）；该参数规模差异提示静态融合的 I/Q 分支可能不足以提取与 CLDNN 同等水平的时序表征，构成提案模型把 I/Q 分支替换为 CLDNN 风格编码器的设计动机。MACs 与该论断的关系是间接的：MACs 反映前向计算量而非表征能力。

表 4.7 四类扩展实验摘要。Δ 列均为相对主实验矩阵同模型的整体准确率均值变化。

证据标签	模型范围 / 干预	Δ overall	主要发现
EXTENDED_BUDGET_3090	4 模型 × 3 seed; epoch 50 + 5 轮 warmup + cosine annealing	±1 pp 内	排除欠训练假设；最佳轮 15–42，未触上限。
LOW_SNR_WEIGHTED_CE_3090	2 模型 × 3 seed; 分组 SNR 加权 CE (low= 2.0, mid= 1.0, high= 0.7)	cldnn −2.3, fusion −0.7	低 SNR 微涨 +0.4–0.6 pp, 但中高 SNR 跌 2–4 pp; 不合算干预。
CONTROLLED_LATENCY_EXTENDED	9 模型; CPU 单线程前向延迟 + thop MACs, warmup 50/measured 200	—	见表 4.8; fusion_iq_stft MACs (2.0 M) 少于 resnet1d (4.9 M)。
Stage 5A predictions 后处理	9 模型 × 3 seed; 行归一化低信噪比混淆矩阵	—	8 稳定模型在 SNR ≤ −6 dB 共同退化为偏置预测 AM-SSB (数字调制 → AM-SSB 比例 0.63–0.81); 构成各模型共同的经验下限。

表 4.8 扩展复杂度 (thop MACs) 与单线程 CPU 前向延迟

模型行	参数量	MACs (单样本)	CPU bs=1 / ms	CPU bs=256 / ms
tfcnn_stft	24,123	424,704	0.363	21.992
cnn1d	37,131	1,553,920	0.411	61.285
lwamcnet	20,395	1,504,096	2.327	52.871
fusion_iq_stft	98,299	2,015,488	0.834	83.240
gated_fusion_iq_stft	134,780	2,051,712	0.996	52.292
iq_param_matched	136,395	4,945,408	0.688	74.088
resnet1d	111,755	4,929,024	0.891	90.929
cldnn	241,675	8,668,544	1.055	182.586
mcldnn	406,199	49,097,472	2.994	572.462

4.7.2 文献校准与可比 SOTA

表 4.9 列出可比文献的报告值，区分 avg-all-SNR (−20 至 +18 dB 共 20 点平均，与本文 overall_accuracy 同口径)、avg SNR > 0 (+2 至 +18 dB 共 9 点平均) 与 peak (单 SNR 最佳点) 三种口径，避免标题党的“95%+”或“92%”单点结果与本文 overall_accuracy 错配。

跨论文比较受不同划分、不同测试集大小、不同种子和不同聚合口径影响，不构成严格 head-to-head 比较。本文以表 4.9 作为同量级参照：本文 CLDNN 0.6129 在 avg-across-SNR 维度上与 LENet-M 0.6463 和 SigFormer 0.6371 仍有 2–3 个百分点差距，提示固定协议下尚有可改进空间。

表 4.9 近期文献在 RadioML2016.10A 上的可比性能校准。“avg-all-SNR”是 -20 至 $+18$ dB 共 20 点平均，与本文 overall_accuracy 同口径；“avg SNR > 0 ”是 9 点平均 ($+2$ 至 $+18$ dB)；“peak”是单 SNR 最佳点。原论文未给出对应口径数字时记 “-”。

方法 (来源)	avg-all-SNR	avg SNR > 0	peak	备注
LENet-M ^[33]	0.6463	-	-	轻量 CNN+ 循环; 2024 DSP
SigFormer ^[34]	0.6371	-	-	金字塔 Transformer; 2023 IEEE
ICRNNA ^[35]	0.6324	-	-	RNN+attention; 2024
CC-MSNet ^[36]	0.6286	-	-	复值多流; 2024 Sci Rep
MCLDNN ^[17]	-	0.9112	0.9227	原论文与 AMR-Benchmark ^[37]
LSTM2 ^[37]	-	-	0.9205	AMR-Benchmark
PET-CGDNN ^[29,37]	-	-	0.916	AMR-Benchmark
CLDNN2 ^[37]	-	-	0.908	AMR-Benchmark
本文 cldnn (主实验矩阵)	0.6129	0.9044	0.9138	三种子均值, 本文
本文 fusion_iq_stft (主实验矩阵)	0.5771	0.8402	0.8482	三种子均值, 本文
本文 fusion_cldnn_stft+aug (提案主配置)	0.6284	0.9252	0.9327	三种子均值, RTX 3090, 第 4.7.3 节
本文 fusion_cldnn_stft+aug+LS (full, 消融对照)	0.6264	0.9237	0.9327	三种子均值, RTX 3090, 第 4.7.3 节

4.7.3 提案模型 fusion_cldnn_stft+ 增强 (跨硬件三种子均值比较)

硬件差异限定与效度缺口声明。本节比较涉及两类硬件：提案模型在 RTX 3090 (Ampere, sm_86) 上训练，主实验矩阵 CLDNN 基线在 RTX 4070 Ti (Ada, sm_89) 上训练。跨硬件环境下，cuDNN 算法选择差异 (不同 GPU 微架构触发不同的卷积实现路径)、浮点累加顺序差异 (非确定性归约操作在不同硬件上产生不同舍入偏置)、以及可能的驱动版本与 CUDA 内核编译差异，共同构成该对比在严格意义上的效度缺口。因此，样本级配对自助法和 McNemar 检验在该比较中不可执行；本节所有差值仅在三种子均值层面解释，不声明样本级统计显著性。

同硬件环境下的重训控制组已在本轮补充实验中完成 (证据标签 EXTENDED_BUDGET_3090 和 CLDNN_AUG_ABLATION_3090)。同硬件配对检验结果 (第 4.7.5 节) 表明： $+1.55$ pp 增益完全由信号域增强驱动，融合架构本身未贡献可检测的独立增益。

需要先行说明的是，本文最初登记于证据标签 FUSION_CLDNN_STFT_AUG_LS_3090 的配置同时包含 $\epsilon = 0.1$ 标签平滑；第 4.7.4 节的单干预消融揭示，标签平滑在已有信号域增强时未能取得正向效应 (详见第 4.7.4 节多重检验校正讨论)。因此本节把提案模型重新定义为不含标签平滑的 arch+aug 配置 (即 fusion_cldnn_stft + 相位旋转加循环时移信号域增强)，并以该配置作为最终推荐的训练计划；arch+aug+LS 作为消融对照保留在第 4.7.4 节，不作为提案主结果汇报。提案主配置整体准确率 0.6284 ± 0.0011 ；消融对照 arch+aug+LS 整体准确率 0.6264 ± 0.0004 。

提案主配置 (arch+aug) 在四个指标上同时正向高于主实验矩阵 CLDNN 基线：整体 0.6284 vs 0.6129 ($\Delta = +1.55$ pp)，低/中/高 SNR 均正向 (图 4.11)。然而，必须在以下约束下解读该差值。

第一，该 1.55 pp 的差值为跨硬件三种子均值之差。同硬件 (RTX 3090) 配对检验 (第 4.7.5 节) 已表明，该增益完全由信号域增强驱动：CLDNN + aug + LS 在同硬件下达到 0.6272 ，相对同硬件 CLDNN 基线 0.6145 的增量为 $+1.27$ pp (McNemar $p < 0.001$,

表 4.10 提案模型与三类参照的同协议比较（单位：准确率）。提案模型在 RTX 3090 训练，主实验矩阵参照在 RTX 4070 Ti 训练； Δ 列为跨硬件三种子均值之差，不可用于样本级统计检验。

模型行（参照 / 提案）	整体	低 SNR	中 SNR	高 SNR
fusion_iq_stft（主实验矩阵, RTX 4070 Ti）	0.5771	0.2213	0.7858	0.8428
fusion_iq_stft（延长预算, RTX 3090）	0.5851	0.2124	0.8025	0.8646
cldnn（主实验矩阵, RTX 4070 Ti）	0.6129	0.2224	0.8396	0.9070
fusion_cldnn_stft+aug（提案主配置, RTX 3090）	0.6284 $\pm$ 0.0011	0.2254 $\pm$ 0.0013	0.8669 $\pm$ 0.0021	0.9272 $\pm$ 0.0013
fusion_cldnn_stft+aug+LS（full, 消融对照, RTX 3090）	0.6264 $\pm$ 0.0004	0.2259 $\pm$ 0.0006	0.8606 $\pm$ 0.0007	0.9264 $\pm$ 0.0003
Δ 提案主配置 vs. 主实验矩阵 CLDNN [‡]	+0.0155	+0.0030	+0.0273	+0.0202
Δ 提案主配置 vs. 主实验矩阵 fusion_iq_stft [‡]	+0.0513	+0.0041	+0.0811	+0.0844

[‡] 跨硬件三种子均值之差。存在 cuDNN 算法选择、浮点累加顺序与驱动版本差异导致的效度缺口。

同硬件配对证据见第 4.7.5 节（CLDNN + aug 对照实验），融合架构独立贡献为零。




图 4.11 提案模型相对 Stage 5A 九个基线在四个 SNR 分组的准确率增量热力图（百分点，三种子均值）。MCLDNN 行因种子异常（见第 4.6 节）应予忽略。

所有种子)，而 Proposed 相对 CLDNN+aug 的差值仅为 -0.08 pp (CI 跨零，不显著)。因此， $+1.55$ pp 中融合架构本身的独立贡献在当前统计精度下为零。

第二，与文献参照的对比（表 4.9）说明，提案主配置在 avg-all-SNR 维度的 0.6284 落入 2024 年代多流 / 复值文献基线的同一量级（CC-MSNet 0.6286、CCTL-Net 0.6297），与 LENet-M（0.6463）、SigFormer（0.6371）仍有约 1–2 个百分点差距，记入未来工作；avg(SNR > 0) 维度（提案 0.9252）在数值上高于 MCLDNN 原论文报告的 0.9112，但跨论文比较受不同划分、测试集大小和聚合口径影响，仅作量级参照。

第三，深低信噪比 (≤ -16 dB) 准确率仍约为 1/11 的随机水平，提案模型不改变第 4.7.1 节登记的经验下限。




图 4.12 提案模型与四类对照的逐 SNR 准确率曲线（三训练种子均值）。灰/绿阴影区分别为低 SNR (≤ -6 dB) 与高 SNR (≥ 8 dB) 范围。

4.7.4 提案模型单干预消融与配对统计检验

第 4.7.3 节把提案模型定义为 arch+aug 配置。本节汇报支撑该选择的完整消融证据：在证据标签 FUSION_CLDNN_STFT_ABLATION_3090 下登记四个变体（arch_only / arch_aug / arch_ls / arch+aug+LS），共享相同硬件（RTX 3090）、固定划分与三训练种子，仅在增强与标签平滑开关上区分；配对自助法（10000 重采样）与 McNemar 检验在整体集与低 SNR 子集分别执行（数据源：三种子 metrics_test.json 与 paired_bootstrap.csv）。

图 4.13 直观呈现四个变体在各 SNR 分组的差距；详细配对证据见表 4.12 及图 4.14。

归因逻辑（同硬件基线对照）。消融中的归因应以同硬件可比基线为起点。原主实验矩阵 fusion_iq_stft 的 0.5771 来自 RTX 4070 Ti，不能直接与 RTX 3090 上的消融

表 4.11 提案模型 `fusion_cldnn_stft` 的单干预消融（三训练种子均值 $\pm$ 标准差）。变体 `arch_only` 关闭增强且 $\epsilon = 0$ ；`arch_aug` 仅开增强；`arch_ls` 仅开标签平滑；“full”行复用第 4.7.3 节的提案模型结果。所有变体使用相同 RTX 3090 硬件、相同固定划分、相同三训练种子。

变体	整体	低 SNR	中 SNR	高 SNR
<code>arch_only</code>	0.6116 ± 0.0022	0.2173 ± 0.0037	0.8399 ± 0.0018	0.9089 ± 0.0023
<code>arch_aug</code> (proposed)	0.6284 ± 0.0011	0.2254 ± 0.0013	0.8669 ± 0.0021	0.9272 ± 0.0013
<code>arch_ls</code>	0.6108 ± 0.0010	0.2152 ± 0.0026	0.8435 ± 0.0004	0.9054 ± 0.0018
full (arch+aug+LS, ablation)	0.6264 ± 0.0004	0.2259 ± 0.0006	0.8606 ± 0.0007	0.9264 ± 0.0003




图 4.13 消融变体与 CLDNN+aug+LS 对照在四个 SNR 分组的准确率（三种子均值 $\pm$ std）。水平虚线为 Stage 5A CLDNN 基线（0.6129）。

变体配对。表 4.10 已记录同硬件（RTX 3090）的延长预算对照 `fusion_iq_stft` 整体准确率 0.5851，该值构成架构升级的同硬件演进起点。

- **架构升级** (`arch_only`, 均值 0.6116): 相对同硬件基线 `fusion_iq_stft`@RTX3090 (0.5851)，架构升级的真实贡献为 +2.65 pp ($0.6116 - 0.5851$)。该增量的根本作用在于缓解了原静态融合模型 I/Q 分支的表征瓶颈——原 I/Q 分支仅 $\sim 50K$ 参数

表 4.12 提案模型相对参照的配对统计检验。差值定义为 “ $\text{Acc}(\text{model_a}) - \text{Acc}(\text{model_b})$ ”；自助重采样 10000 次，种子 42；McNemar 使用连续性修正卡方近似 ($df = 1$)。

比较	范围	配对数	准确率差值	95% CI 是否跨 0	McNemar p
proposed vs. p11_fusion_iq_stft	整体	132,000	+0.0433 [+0.0414, +0.0451]	否	$0.000e + 00$
proposed vs. p11_fusion_iq_stft	低 SNR	52,800	+0.0130 [+0.0098, +0.0161]	否	$1.670e - 15$
proposed vs. ablation_arch_only	整体	132,000	+0.0168 [+0.0152, +0.0183]	否	$1.379e - 97$
proposed vs. ablation_arch_only	低 SNR	52,800	+0.0081 [+0.0052, +0.0110]	否	$2.767e - 07$
proposed vs. ablation_arch_ls	整体	132,000	+0.0176 [+0.0161, +0.0192]	否	$1.025e - 109$
proposed vs. ablation_arch_ls	低 SNR	52,800	+0.0101 [+0.0074, +0.0129]	否	$9.552e - 12$
proposed vs. ablation_full	整体	132,000	+0.0019 [+0.0006, +0.0033]	否	$1.553e - 02$
proposed vs. ablation_full	低 SNR	52,800	-0.0005 [-0.0030, +0.0021]	是	$9.406e - 01$




图 4.14 同硬件五组配对统计检验森林图 (● CI 不跨 0, ○ CI 跨 0; 三种子均值, all_paired_tests.json)。

的一维卷积编码器，不足以在 128 步 I/Q 序列上提取与 CLDNN (241K 参数、含 LSTM 时序建模) 同等水平的时序表征。将 I/Q 编码器替换为 CLDNN 风格的卷积-循环混合结构后，多视图融合重新具备与纯时域基线竞技的资格。arch_only 的 0.6116 相对 Stage 5A CLDNN 的 0.6129 仅差 -0.13 pp，落在种子噪声范围内，说明架构升级本身不是超越基线的来源，而是回到基线水平的必要条件。

辅助参照：若以跨硬件的主实验矩阵 fusion_iq_stft 0.5771 为起点，名义增量为 +3.45 pp，但该对比受 RTX 4070 Ti vs. RTX 3090 的系统性偏置影响，不作为主要归因依据。

- **信号域增强是主要涨点来源：**arch_aug (0.6284) 相对 arch_only (0.6116) 提升 +1.68 pp，同硬件配对检验 $p < 0.001$ (辅助参考)，95% CI [+0.0152, +0.0183] 不跨 0，低、中、高 SNR 均一致正向。信号域增强在架构瓶颈被缓解后进一步实现对 CLDNN 基线的超越差值。
- **标签平滑在已有增强条件下未取得正向效应：**arch+aug+LS (0.6264) 相对 arch+aug (0.6284)，整体差值 $\Delta = -0.0019$ (即 -0.19 pp)，95% CI [-0.0033, -0.0006]，CI 不跨 0 且完全位于负域；未校正 McNemar $p = 0.0155$ 。

多重检验校正。表 4.12 涉及 4 对比较 $\times$ 2 个范围 (整体 / 低 SNR) = 8 个 p 值，构成一个比较族。在 Bonferroni 校正下，族水平 $\alpha = 0.05$ 对应的逐比较阈值为 $\alpha_{\text{adj}} = 0.05/8 = 0.00625$ 。proposed vs. arch+aug+LS 整体的未校正 $p = 0.0155 > 0.00625$ ，校正后不再达到统计显著阈值¹。

¹在 Holm 逐步下降法中， $p = 0.0155$ 位于 8 个排序 p 值中的第 7 位，对应阈值 $\alpha/(8 - 7 + 1) = 0.025$ ， $0.0155 < 0.025$ 仍边缘通过。本文采用更保守的 Bonferroni 报告，与全文“效应量为主”的立场一致。

因此，关于标签平滑的结论应表述为：在已有信号域增强的条件下，叠加标签平滑 $\epsilon = 0.1$ 在未校正的配对 McNemar 下达到 $p = 0.0155$ ，但 95% CI 不跨 0 且效应量微小 (-0.19 pp)。多重检验校正 (Bonferroni, $\alpha_{\text{adj}} = 0.00625$) 后该差值不再达到统计显著阈值。基于效应量为负且 CI 完全位于负域的考量，最终提案模型选择不包含标签平滑，但这是基于点估计与 CI 方向的工程选择，而非强统计支持的结论。

4.7.5 CLDNN + 信号域增强对照实验与融合贡献归零

本节补足了前述消融中缺失的关键对照组：在同硬件 (RTX 3090)、同三训练种子下训练纯 I/Q CLDNN 加入相同信号域增强与标签平滑 (证据标签 CLDNN_AUG_ABLATION_3090)。该对照模型的配置与提案模型 (arch+aug+LS) 完全一致 (相位旋转 $\theta \sim U(-\pi, \pi)$ 概率 0.5 + 循环时移 $k \sim U(-8, +8)$ 概率 0.5, 标签平滑 $\epsilon = 0.1$, epoch 50 + cosine LR + warmup 5)，唯一区别是 I/Q 编码器为纯 CLDNN (无 STFT 分支)。

表 4.13 CLDNN + 增强对照实验与融合贡献分解 (同硬件 RTX 3090, 三种子)

模型行	整体准确率	低 SNR	中 SNR	高 SNR
CLDNN 基线	0.6145 ± 0.0017	0.2217 ± 0.0034	0.8478 ± 0.0040	0.9062 ± 0.0024
CLDNN + aug + LS	0.6272 ± 0.0007	0.2284 ± 0.0017	0.8632 ± 0.0010	0.9229 ± 0.0014
Proposed arch+aug+LS	0.6264 ± 0.0005	0.2259 ± 0.0008	0.8606 ± 0.0009	0.9264 ± 0.0003
Δ CLDNN+aug vs 基线	+1.27 pp	+0.67 pp	+1.54 pp	+1.67 pp
Δ Proposed vs CLDNN+aug	-0.08 pp	-0.25 pp	-0.26 pp	+0.35 pp

表 4.13 的结论是决定性的。

增强效果独立于融合架构。CLDNN + aug + LS 相对 CLDNN 基线的整体准确率差值为 +1.27 pp (三种子 +1.35 / +1.17 / +1.30 pp)，全部三个种子的 McNemar 检验 $p < 0.001$ ，bootstrap 95% CI 均不跨零 (最窄为 $[+0.92, +1.42]$ pp)。信号域增强在纯 I/Q CLDNN 上的收益与在融合架构上的收益量级一致 (提案模型相对基线 +1.20 pp)，说明增强效果不依赖多视图融合结构。

融合架构贡献归零。Proposed (arch+aug+LS) 相对 CLDNN + aug + LS 的整体准确率差值为 -0.08 pp (三种子 +0.02 / -0.17 / -0.08 pp)，三个种子的 McNemar 检验 p 值分别为 0.892 / 0.169 / 0.488，bootstrap 95% CI 均跨零。这意味着在同硬件配对统计检验下，融合架构相对纯 CLDNN 在同增强条件下未贡献任何可检测的独立增益。

该发现改写了本章此前的解释框架：第 4.7.3 节报告的跨硬件 +1.55 pp (或同硬件 +1.20 pp) 完全由信号域增强驱动，融合机制本身的独立贡献在当前统计精度下为零。提案模型的方法学新颖度因此仅限于“融合架构对信号域增强的兼容性验证”，而非“融合 + 增强的协同效应”。这一结论诚实暴露了实验设计的完整分析，符合实证研究的基

本伦理。

第五章 讨论、局限性与可复现性

5.1 固定协议下结果的含义

第 4 章结果表明, CLDNN 在本文固定协议中取得最高的整体准确率和宏平均 F1^[3,19], 并在已登记配对检验中优于 `resnet1d`^[20] 与 `iq_param_matched`。这一现象可以从结构上理解: CLDNN 先用卷积层提取局部时域模式, 再通过循环单元建模序列依赖^[22], 相比单纯一维卷积基线^[2]具有更强的时序表征能力。该优势属于协议内观察, 跨数据集和跨信道条件的稳定性需要新的验证。

固定划分的价值在于提高模型间比较的可比性。所有模型使用相同测试样本、相同训练种子集合和相同评价脚本, 因而结果差异更容易归因于当前模型实现与训练配置, 而不是测试集变化。其限制也同样明显: 单一固定划分之后还需要多划分重复实验, 并需要其他数据集或真实无线环境验证。

5.2 STFT 融合的低信噪比权衡

静态 I/Q-STFT 融合的结果说明, 多视图输入的价值具有条件性。相对参数匹配 I/Q 控制模型, 静态融合在低信噪比范围内有小幅正向差异; 相对 CLDNN, 该差异没有统计支持; 在整体测试集上, 静态融合又低于参数匹配 I/Q 控制模型。因此, 结论应写作“STFT 视图在低信噪比样本上可能提供局部补充信息”。

这种权衡具有合理机制解释。低信噪比下, 原始 I/Q 序列中的局部相位和幅度结构容易被噪声扰动, STFT 展开的局部频率能量分布可能提供另一种观察角度。但在中高信噪比样本上, I/Q 序列已经包含较清晰的时域判别线索, 额外的时频分支和融合分类器可能引入训练难度、特征冗余或视图不一致, 从而造成整体准确率下降。由此可见, 融合结构的关键问题不是“是否增加视图”, 而是如何在低信噪比收益与中高信噪比保持之间取得平衡。

5.3 融合失败原因诊断

保留“基于时频特征与深度神经网络融合”的题目时, 融合结果必须被解释为一次有边界的实证诊断, 而不是成功提升的叙事。第 4 章显示, 静态 I/Q-STFT 融合相对 CLDNN 的整体准确率差值为 -0.035833 , 95% 置信区间为 $[-0.037629, -0.034015]$; 相对参数匹配 I/Q 控制模型的整体准确率差值为 -0.017364 , 95% 置信区间为 $[-0.019288, -0.015470]$ 。这说明当前静态融合没有兑现整体性能优势, 门控融合也没有修复这一问题。

类别层面的异常更能说明融合失败的形态。图 4.7 中，静态融合相对参数匹配 I/Q 控制模型在低信噪比 QAM16 上的召回率差值为 -7.4 个百分点，而 QAM64 上的差值为 $+8.9$ 个百分点，二者接近等幅、方向相反。QAM16 与 QAM64 都属于正交幅度调制，低信噪比下星座点云更容易重叠；STFT 幅度视图强调局部频谱能量而弱化细粒度星座几何后，分类器可能把原先用于区分 QAM16/QAM64 的边界整体推向更偏 QAM64 的区域。这个解释与“融合获得普遍互补信息”相反：它提示新增视图改变了相邻 QAM 类别之间的判别边界，使某一类收益由另一类损失支付。

中高信噪比下的退化也支持“冗余视图”假设。相对 CLDNN，静态融合从 -4 dB 到 18 dB 的逐 SNR 净分歧均为负，约从 -3.24 到 -6.86 个百分点；相对参数匹配 I/Q 控制模型，同一区间也约为 -0.64 到 -4.12 个百分点。此时 I/Q 序列已经保留较清晰的相位轨迹和幅度结构，STFT 幅度图带来的额外频谱摘要可能主要复制已有信息，甚至压低相位敏感特征的权重。融合分类头在训练时同时适配两个相关视图，可能增加优化负担，并在高信噪比样本上把本来清晰的 I/Q 决策边界变钝。

第 4.4 节的门控诊断实验进一步揭示了一个耐人寻味的现象：标量门控权重 g 在低信噪比时偏向 STFT ($g \approx 0.79$ at -20 dB)，在高信噪比时偏向 I/Q ($g \approx 0.12$ at $+18$ dB)，说明门控网络确实学到了物理上合理的 SNR 条件信息。但这一正确的门控方向并未转化为分类增益——门控融合整体准确率 (0.5733) 仍低于静态融合 (0.5851) 和 CLDNN (0.6145)。这排除了“ g 退化为常数”的假设，转而支持容量假设：标量 sigmoid 门控过于粗糙，全局一维标量无法区分类别层面的视图偏好；且门控训练增加了优化负担。一个可检验的改进方向是多头/向量门控或显式 SNR 条件门控，但鉴于第 4.7.5 节已证明融合架构本身的增益为零，门控改进的优先级应低于探索更强的纯 I/Q 编码器方向。

5.4 复杂度与运行时证据限制

本文的复杂度讨论覆盖参数量、训练时间背景和受控 CUDA 前向延迟。该测量能帮助读者理解不同模型在相同硬件和相同计时设置下的前向耗时差异；完整部署成本还需要时频预处理、数据搬运、CPU 推理和端到端流水线时间。

因此，“更适合部署”“更高计算效率”或“硬件可迁移性能更好”需要系统级效率分析支撑。若未来开展该分析，应同时测量 CPU/GPU、不同批量大小、预处理耗时、内存峰值、吞吐率和端到端延迟，并将该协议与本报告的受控前向延迟区分开。

5.5 提案模型整体准确率高於基线的解释边界

第 4.7.4 节的消融把提案模型相对 Stage 5A CLDNN 的 $+1.55$ pp 整体增量拆分为：架构升级缓解了原融合 I/Q 分支的表征瓶颈，使融合回到 CLDNN 量级（同硬件贡献约

+2.65 pp, 以 RTX 3090 延长预算 fusion_iq_stft 0.5851 为演进起点)^[19]; 信号域增强在此基础上进一步贡献约 +1.68 pp (主要涨点来源, 同硬件配对 CI 不跨 0)^[25-26]; 标签平滑在已有增强时效应量为负 (-0.19 pp, 95% CI [-0.0033, -0.0006], 未校正 McNemar $p = 0.0155$), 多重检验校正 (Bonferroni, $\alpha_{adj} = 0.00625$) 后不再达到统计显著阈值, 最终提案模型不包含标签平滑, 但这是基于点估计与 CI 方向的工程选择, 而非强统计支持的结论。图 5.1 显示 arch_aug 在训练后期 val 准确率略高于含标签平滑变体, 与消融表的 0.6284 vs. 0.6264 数值方向一致。

融合贡献归零的决定性证据。第 4.7.5 节的 CLDNN + 信号域增强对照实验 (证据标签 CLDNN_AUG_ABLATION_3090) 进一步表明: 纯 CLDNN + aug + LS 在同硬件下达到整体准确率 0.6272 ± 0.0007 , 相对 CLDNN 基线提升 +1.27 pp (三种子均 $p < 0.001$); Proposed (arch+aug+LS) 相对 CLDNN+aug 的差值仅为 -0.08 pp (McNemar $p = 0.892/0.169/0.488$, CI 均跨零)。该结果改写了消融的归因逻辑: +1.55 pp 跨硬件增量完全由信号域增强驱动, 融合架构在同增强条件下未贡献任何可检测的独立增益。提案模型的新颖度因此仅限于”融合架构对增强的兼容性验证”, 而非此前暗示的”融合 + 增强的协同效应”。

两条解释边界仍然制约结论的适用范围: 其一, 本报告未同步检验复值网络^[36]与 Transformer 混合架构^[33-34]方向, 与 LENet-M (0.6463)、SigFormer (0.6371) 仍有 1-2 pp 差距记入未来工作; 其二, 深低信噪比退化在 8 个稳定模型上共同表现为对 AM-SSB 的偏置预测 (构成各模型共同的经验下限), 提案模型未改变该下限, 但本文未对该下限的最优分类器近似或类条件可分性给出独立论证, 因而仅作为经验观察。未来优先考虑细化增强强度网格与更强 I/Q 编码器方向。

5.6 协议局限与后续处理

表 5.1 汇总本报告最影响结论解释的四类协议局限。它们不改变第 4 章已有数值, 而是说明这些数值在后续研究中如何被进一步检验。

5.7 可复现性与证据边界

本文可复现性主要来自三个层面: 固定划分和三训练种子保证比较口径一致; 测试集预测归档支持同一样本上的配对统计检验; 聚合表、低信噪比分组表和受控延迟表使正文数值可追溯。表 5.2 用课程论文口径概括这些材料的用途, 具体路径、环境和同步状态放在附录 A。

附录图 A.5 进一步说明证据标签与排除规则。本报告的证据边界为: 主结论使用 Stage 5A/5B 固定协议、归档预测和已登记统计检验; 诊断性或工程检查材料用于后续工作边界; 当前本地材料支撑报告写作和统计解释, 完整 27 个训练权重文件需另行独




图 5.1 四个消融变体 (seed 42) 训练曲线 (metrics.csv)。(a) full; (b) arch_only; (c) arch_aug; (d) 四变体 val acc 叠加。

表 5.1 实验协议局限及后续处理方案。严重程度按对结论可信度影响排序，“高”= 改写解释、“中”= 收紧表述、“低”= 记入未来工作。

协议局限	严重程度	后续处理
扩展实验与提案模型使用的硬件 (RTX 3090) 与 Stage 5A 主实验 (RTX 4070) 不同。本轮补充实验已在 RTX 3090 上重训 CLDNN 基线 (EXTENDED_BUDGET_3090) 和 CLDNN + aug 对照组 (CLDNN_AUG_ABLATION_3090)，支持同硬件配对检验。	中 (已缓解)	同硬件配对检验已完成 (第 4.7.5 节)，跨硬件效率缺口在关键比较上已消除。Stage 5A 主实验矩阵其他模型的跨硬件重训仍可作为后续工作。
提案模型由 CLDNN 风格 I/Q 编码器、信号域增强与标签平滑三项干预联合构成；本报告在第 4.7.4 节给出三个单干预消融变体，并在第 4.7.5 节完成 CLDNN + aug 对照，证实融合架构本身贡献为零。	中	后续可对增强强度、LSTM 隐藏维做更细网格搜索；按预先登记表汇报。
单一固定划分提升了模型间配对比较的可比性，但外部效率仍取决于其他随机划分与真实信道条件。	中	采用多 split 重复实验，并报告跨 split 均值、方差和配对统计检验；在真实或半真实信道数据上复核主要排序。
每个模型 $n = 3$ 个训练种子，能够暴露 MCLDNN 不稳定性，但对方差和尾部失败概率的估计仍偏粗。	中	将主模型扩展到更多训练种子，预先登记失败判据，并用种子级分布而非单一均值描述稳定性。
9 个模型共用学习率 10^{-3} 、权重衰减 10^{-4} 、batch size 256，有利于统一协议，却会低估对超参更敏感结构的潜力。	中	设置“统一超参主表”和“模型内调参补充表”两层证据；调参空间、选择规则和验证集使用方式提前登记。
数据集只覆盖 RadioML2016.10A，跨数据集一致性未在本报告范围内验证。	低	列入未来工作但不计入本课程报告；如展开应使用相同模型身份、统计检验和证据标签独立报告。

表 5.2 课程报告使用的主要证据材料及边界

材料类型	主要作用	使用边界
聚合结果表	支撑主结果、低/中/高信噪比分组和复杂度背景。	对应 RadioML2016.10A 固定协议。
测试集预测归档	支撑配对自助法和 McNemar 检验。	覆盖 9 个模型行、3 个训练种子和已登记模型对。
受控延迟表	支撑参数量与 CUDA 前向延迟讨论。	对应 CUDA 前向传播测量口径。
环境与同步记录	说明本地写作环境、服务器实验环境和权重归档缺口。	不等同于本地完整训练权重归档。

立同步和哈希核验。

第六章 总结

6.1 工作总结

本文围绕 RadioML2016.10A 自动调制识别任务，完成了一份证据边界清晰的课程实验报告。报告由两层证据构成。第一层是固定划分 `stratified_by_mod_snr_seed42` 下的 Stage 5A 主实验，共 9 个模型行 $\times$ 3 个训练种子 = 27 个运行单元，覆盖 I/Q 序列基线、STFT 时频分支、I/Q-STFT 静态融合、标量门控融合、卷积-循环混合模型、轻量模型和参数匹配 I/Q 控制模型；该层使用统一划分、统一评价指标和同一样本配对统计检验，主表数值与统计检验结果在本报告任何位置都不被覆盖。第二层是五个独立证据标签的扩展实验：训练预算延长（4 模型 $\times$ 3 种子）、低信噪比加权交叉熵（2 模型 $\times$ 3 种子）、扩展复杂度与单线程 CPU 延迟、低信噪比类别混淆后处理，以及一项联合架构升级、信号域增强与标签平滑的提案模型评估（1 模型 $\times$ 3 种子）；该层使用独立输出根目录与独立证据标签登记，仅作为协议化的敏感性、干预筛查和正面贡献材料，不进入主表。

在实验组织上，报告完整记录两层证据的训练计划、评价指标、统计检验、复杂度边界与硬件设置变更，使每一项数值都能追溯到固定的证据标签与运行目录。报告写作未在 Stage 5A/5B 主实验之上启动新训练，也未把诊断性材料合并到主表。

6.2 主要结论

第一，在 Stage 5A 固定协议内，CLDNN 取得最高的整体平均准确率 0.612932 和宏平均 F1 0.633238。相对 `resnet1d` 和 `iq_param_matched`，CLDNN 的整体准确率差异在已登记配对检验中得到统计支持。该结论仅限于本报告的数据集、固定划分、模型矩阵和训练种子集合。

第二，静态 I/Q-STFT 融合体现的是低信噪比局部权衡。它在低信噪比范围内相对参数匹配 I/Q 控制模型有小幅正向差异，但相对 CLDNN 的低信噪比优势没有统计支持，并且在整体测试集上存在准确率损失。因此，本报告不能把 Stage 5A 的静态融合表述为广义优越模型。

第三，标量门控融合在本文实现中没有改善静态融合。整体和低信噪比两个范围的配对检验均显示门控融合低于静态融合，因此该模型应作为负结果保留。

第四，MCLDNN 的两个异常训练种子被保留在主表中。该处理维护了固定协议完整性，也提示当前实现存在优化或初始化敏感性。本报告不删除异常种子，不重算清洗后结果。

第五，扩展实验为主表结论提供了多角度敏感性检验。延长训练预算未明显改变主表排序也未提升低信噪比，排除“主表是欠训练造成”的常见质疑；分组 SNR 加权交叉熵在低信噪比上小幅获益但中高信噪比代价更大；8 个稳定模型在深低信噪比共同退化为对 AM-SSB 的偏置预测，构成 8 模型共同的经验下限（本文未独立论证最优分类器近似或类条件可分性，故不主张其为信息论意义下的失败下限）；扩展复杂度证据进一步显示静态融合 I/Q 分支参数量约 50K 显著低于 CLDNN 整体 242K，提示融合输给 CLDNN 是 I/Q 分支表征容量问题，MACs 数值仅作算力背景参考。

第六，提案模型 `fusion_cldnn_stft` 在同一固定划分与三训练种子下，由 CLDNN 风格 I/Q 编码器^[19,22]与相位旋转加循环时移信号域增强（仅训练）^[25-26]两项干预联合构成（`arch+aug` 配置，不含标签平滑）。相对 Stage 5A CLDNN 基线，提案模型整体准确率三种子均值 0.6284（RTX 3090），跨硬件差值 +1.55 pp，三种子标准差 0.0011；整体、低、中、高 SNR 四项指标同时正向。第 4.7.4 节的单干预消融把这一收益拆解为：架构升级缓解了原融合模型 I/Q 分支的表征瓶颈，使融合回到 CLDNN 量级（同硬件贡献约 +2.65 pp）；信号域增强在此基础上进一步贡献约 +1.68 pp（主要涨点来源，同硬件配对 CI 不跨 0）。然而，第 4.7.5 节的 CLDNN + 信号域增强对照实验揭示了决定性结论：纯 CLDNN + `aug` + `LS` 在同硬件下达到 0.6272（+1.27 pp，三种子均 $p < 0.001$ ），而 **Proposed** 相对 CLDNN+`aug` 的差值仅为 -0.08 pp（CI 跨零，不显著）。融合架构本身在同增强条件下未贡献任何可检测的独立增益，+1.55 pp 完全由信号域增强驱动。本文最初登记的 `arch+aug+LS` 配置含标签平滑 0.1，但消融实验表明在已有增强条件下叠加标签平滑效应量为负（-0.19 pp），最终提案模型不包含标签平滑。提案模型与近期文献中复值多流^[36]和 Transformer 混合方法^[33-35]的报告值量级一致，数值对比见表 4.9。

第七，门控融合诊断实验（第 4.4 节）揭示标量门控权重 g 呈现清晰的 SNR 单调递减模式（-20 dB 时 $g \approx 0.79$ 、+18 dB 时 $g \approx 0.12$ ），说明门控网络确实学到了 SNR 条件信息，但这一正确的门控方向未转化为分类增益（整体准确率仍低于静态融合），且 g 的跨种子稳定性差（均值 0.18-0.34）。

6.3 不足与后续工作

本报告最主要的局限来自实验范围。主结果只覆盖 RadioML2016.10A 和单一固定划分，没有纳入 RadioML2018.01A、真实外场信道或多划分重复验证；复杂度证据虽已补全 MACs/FLOPs 与单线程 CPU 延迟，仍不能等同于完整部署效率（CPU 多线程、ARM/移动/DSP、STFT 预处理完整成本均未独立测量）。本轮补充实验已消除此前最关键的两个缺口：同硬件配对检验（`EXTENDED_BUDGET_3090` + `CLDNN_AUG_ABLATION_3090`）已完成，门控融合诊断（`GATED_FUSION_DIAGNOSTIC_3090`）也已执行。

后续工作可以沿四条方向推进。其一，多 stratified split 敏感性验证（至少 2-3 个划分种子），确认主表排序与增强收益在划分随机性下的稳健性。其二，既然融合架构贡献归零（第 4.7.5 节），后续方向应转向更强的 I/Q 编码器：沿文献中最一致涨点方向（复值网络如 CC-MSNet^[36] 系列、Transformer 混合如 SigFormer^[34] 系列）实现更强的 I/Q 编码器或注意力组件，目标对齐 LENet-M 0.6463 / SigFormer 0.6371 区间。其三，对比 arch_aug 与 arch_only 的逐 SNR 准确率差值，确认信号域增强收益的 SNR 分布，并补充 fusion_iq_stft 模型在低 SNR QAM16/QAM64 子集上的 logits 分布分析与梯度显著性归因，验证第 4.3.1 节提出的 STFT 幅度域相位丢弃导致判别边界偏移的物理机制假设。其四，在 RadioML2018.01A 子集上以相同模型身份、统计检验与证据标签复核主表排序与增强收益的可重复性。

参考文献

- [1] O'SHEA T J, WEST N. Radio Machine Learning Dataset Generation with GNU Radio[C/OL]//Proceedings of the GNU Radio Conference: vol. 1: 1. 2016. <https://pubs.gnuradio.org/index.php/grcon/article/view/11>.
- [2] O'SHEA T J, CORGAN J, CLANCY T C. Convolutional Radio Modulation Recognition Networks[G/OL]//Engineering Applications of Neural Networks. Cham: Springer International Publishing, 2016: 213-226. DOI: 10.1007/978-3-319-44188-7_16.
- [3] WEST N E, O'SHEA T J. Deep Architectures for Modulation Recognition[C/OL]//2017 IEEE International Symposium on Dynamic Spectrum Access Networks (DySPAN). 2017: 1-6. DOI: 10.1109/DySPAN.2017.7920754.
- [4] AZZOUZ E E, NANDI A K. Automatic Modulation Recognition of Communication Signals[M]. Boston: Kluwer Academic Publishers, 1996.
- [5] SWAMI A, SADLER B M. Hierarchical Digital Modulation Classification Using Cumulants[J/OL]. IEEE Transactions on Communications, 2000, 48(3): 416-429. DOI: 10.1109/26.837045.
- [6] DOBRE O A, ABDI A, BAR-NESS Y, et al. Survey of Automatic Modulation Classification Techniques: Classical Approaches and New Trends[J/OL]. IET Communications, 2007, 1(2): 137-156. DOI: 10.1049/iet-com:20050176.
- [7] HAMEED F, DOBRE O A, POPESCU D C. On the Likelihood-Based Approach to Modulation Classification[J/OL]. IEEE Transactions on Wireless Communications, 2009, 8(12): 5884-5892. DOI: 10.1109/TWC.2009.12.080883.
- [8] OPPENHEIM A V, SCHAFER R W. Discrete-Time Signal Processing[M]. 3rd ed. Pearson, 2010.
- [9] ALLEN J B. Short Term Spectral Analysis, Synthesis, and Modification by Discrete Fourier Transform[J/OL]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1977, 25(3): 235-238. DOI: 10.1109/TASSP.1977.1162950.
- [10] GRIFFIN D W, LIM J S. Signal Estimation from Modified Short-Time Fourier Transform[J/OL]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1984, 32(2): 236-243. DOI: 10.1109/TASSP.1984.1164317.
- [11] COHEN L. Time-Frequency Analysis[M]. Prentice Hall, 1995.

- [12] BOASHASH B. Time-Frequency Signal Analysis and Processing: A Comprehensive Reference[M]. 2nd ed. Academic Press, 2015.
- [13] EFRON B. Bootstrap Methods: Another Look at the Jackknife[J/OL]. The Annals of Statistics, 1979, 7(1): 1-26. DOI: 10.1214/aos/1176344552.
- [14] MCNEMAR Q. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages[J/OL]. Psychometrika, 1947, 12(2): 153-157. DOI: 10.1007/BF02295996.
- [15] LOSHCHILOV I, HUTTER F. Decoupled Weight Decay Regularization[C]// International Conference on Learning Representations (ICLR). 2019.
- [16] KINGMA D P, BA J. Adam: A Method for Stochastic Optimization[C]// International Conference on Learning Representations (ICLR). 2015.
- [17] XU J, LUO C, PARR G, et al. A Spatiotemporal Multi-Channel Learning Framework for Automatic Modulation Recognition[J/OL]. IEEE Wireless Communications Letters, 2020, 9(10): 1629-1632. DOI: 10.1109/LWC.2020.2999453.
- [18] DEMŠAR J. Statistical Comparisons of Classifiers over Multiple Data Sets[J/OL]. Journal of Machine Learning Research, 2006, 7: 1-30. <https://www.jmlr.org/papers/v7/demsar06a.html>.
- [19] SAINATH T N, VINYALS O, SENIOR A, et al. Convolutional, Long Short-Term Memory, Fully Connected Deep Neural Networks[C/OL]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2015: 4580-4584. DOI: 10.1109/ICASSP.2015.7178838.
- [20] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition [C/OL]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
- [21] WANG Y, LIU M, YANG J, et al. A Lightweight CNN Architecture for Automatic Modulation Classification[J/OL]. IEEE Communications Letters, 2021, 25(6): 1850-1854. DOI: 10.1109/LCOMM.2021.3060835.
- [22] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J/OL]. Neural Computation, 1997, 9(8): 1735-1780. DOI: 10.1162/neco.1997.9.8.1735.
- [23] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]//International Conference on Machine Learning (ICML). 2015: 448-456.

- [24] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting[C]//: vol. 15. 2014: 1929-1958.
- [25] HUANG L, PAN W, ZHANG Y, et al. Data Augmentation for Deep Learning-Based Radio Modulation Classification[J/OL]. IEEE Access, 2020, 8: 1498-1506. DOI: 10.1109/ACCESS.2019.2960775.
- [26] SHORTEN C, KHOSHGOFTAAR T M. A survey on Image Data Augmentation for Deep Learning[J/OL]. Journal of Big Data, 2019, 6: 60. DOI: 10.1186/s40537-019-0197-0.
- [27] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the Inception Architecture for Computer Vision[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2818-2826. DOI: 10.1109/CVPR.2016.308.
- [28] PASZKE A, GROSS S, MASSA F, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[J]. Advances in Neural Information Processing Systems, 2019, 32: 8024-8035.
- [29] ZHANG F, LUO C, XU J, et al. An Efficient Deep Learning Model for Automatic Modulation Recognition Based on Parameter Estimation and Transformation [J/OL]. IEEE Communications Letters, 2021, 25(10): 3287-3290. DOI: 10.1109/LC OMM.2021.3102656.
- [30] KROGH A, HERTZ J A. A Simple Weight Decay Can Improve Generalization[C] //Advances in Neural Information Processing Systems: vol. 4. 1992: 950-957.
- [31] LOSHCHILOV I, HUTTER F. SGDR: Stochastic Gradient Descent with Warm Restarts[C]//International Conference on Learning Representations (ICLR). 2017.
- [32] HOLM S. A Simple Sequentially Rejective Multiple Test Procedure[J/OL]. Scandinavian Journal of Statistics, 1979, 6(2): 65-70. <https://www.jstor.org/stable/4615733>.
- [33] LIU Y, LIU H, CHEN W, et al. A lightweight cross-scale feature fusion enhanced multi-level recurrent convolutional neural network for automatic modulation recognition[J/OL]. Digital Signal Processing, 2024. DOI: 10.1016/j.dsp.2024.104896.
- [34] CAO H, ZHAO Y, WANG H, et al. Robust and Efficient Modulation Recognition with Pyramid Signal Transformer[J]. IEEE Conference on Signal Processing and Information Networks, 2023.
- [35] LI M, ZHANG W, LIU W, et al. Improved automatic modulation recognition using deep learning with additive attention[J/OL]. Heliyon, 2025. DOI: 10.1016/j.heliyon.2025.e44520.

- [36] WANG Y, BAI J, CHEN J, et al. A complex-valued convolutional fusion-type multi-stream spatiotemporal network for automatic modulation classification[J/OL]. Scientific Reports, 2024, 14: 22506. DOI: 10.1038/s41598-024-73547-w.
- [37] ZHANG F, LUO C, XU J, et al. AMR-Benchmark: A Unified Implementation of Several Baseline Deep Learning Models for Automatic Modulation Recognition[Z]. GitHub repository: <https://github.com/Richardzhangxx/AMR-Benchmark>. Implements CNN1, CNN2, MCNET, IC-AMCNET, ResNet, DenseNet, GRU, LSTM, DAE, MCLDNN, CLDNN, CLDNN2, CGDNet, PET-CGDNN on RML2016.10a/10b/2018.01a/HisarMod2019.1. 2022.

附录 A 证据包、环境与补充图表

A.1 证据包与环境摘要

表 A.1 将原附录 A.1–A.6 的证据包路径、同步状态、环境差异和排除规则压缩为课程报告可核查的摘要。主结果来自 Stage 5A/5B 固定协议聚合表、低信噪比分组表、受控 CUDA 前向延迟表和 27 个测试集预测文件；统计检验包基于这些归档预测生成。Stage 6B smoke/diagnostic 材料保留为工程追踪记录，正文性能结论使用 Stage 5A/5B 主证据。

表 A.1 证据包、环境与使用规则压缩摘要

项目	摘要
主实验证据包	<code>paper_package/server_sync_20260508</code> ; 包含主表、低信噪比分组表、复杂度/延迟表和 Stage 5B audit 材料。
预测归档	<code>paper_package/predictions_archive_20260508</code> ; 27 个 <code>predictions_test.csv</code> , 覆盖 9 个模型行和 3 个训练种子。
统计检验包	<code>paper_package/statistical_tests_20260508</code> ; 包含配对自助法、McNemar 检验、显著性 JSON 和清单。
证据标签	PROJECT_SUPPORTED 支撑主结果; CONTROLLED_LATENCY 支撑 CUDA 前向延迟; SMOKE TEST/DIAGNOSTIC 用于工程追踪。
环境差异	本地 Windows/Python 3.13.7/PyTorch 2.11.0+cpu 用于写作与核查; 服务器 Linux/Python 3.11.12/PyTorch 2.9.1+cu128/RTX 4070 用于 GPU 实验。
剩余缺口	本地材料包含预测和聚合证据; 完整 27 个 Stage 5A <code>best_model.pt</code> 权重需要另行独立同步与哈希核验。

A.2 图表证据源映射

表 A.2 列出本报告各图表与对应数据文件、证据标签及使用位置的映射关系，供审阅时核查各图数据来源。

表 A.2 图表证据源映射表

图号	文件	主要数据源	证据标签	使用位置
图 1	<code>fig01_protocol_pipeline.tex</code>	Protocol docs, manifest, statistical package	PROJECT_SUPPORTED	正文
图 2	<code>fig02_model_taxonomy.tex</code>	<code>main_table_metrics.csv</code> ; code registry	PROJECT_SUPPORTED	正文
图 3	<code>fig03_fusion_architecture.tex</code>	<code>src/radioml_amc/models</code>	PROJECT_SUPPORTED	正文
图 4	<code>fig04_accuracy_by_snr_group.pdf</code>	<code>main_table_metrics.csv</code>	PROJECT_SUPPORTED	正文

图号	文件	主要数据源	证据标签	使用位置
图 5	fig05_low_snr_per_snr_curve.pdf	low_snr_table.csv	PROJECT_SUPPORTED	正文
图 6	fig06_bootstrap_delta_forest.pdf	paired_bootstrap_accuracy_deltas.csv	PROJECT_SUPPORTED	正文
图 7	fig07_accuracy_latency_params_bubble.pdf	main_table_metrics.csv; complexity_latency_table.csv	CONTROLLED_LATENCY	正文
图 8	fig08_low_snr_confusion_panels.pdf	confusion_low_snr.csv	PROJECT_SUPPORTED	附录
图 9	fig09_mclldnn_seed_anomaly.pdf	mclldnn/seed_*/metrics_test.json	PROJECT_SUPPORTED	附录
图 10	fig10_evidence_boundary.tex	REPORT_EVIDENCE_MAP.md; environment audit	Mixed labels	附录
图 11	fig11_full_snr_accuracy_macro_f1.pdf	metrics_per_snr.csv	PROJECT_SUPPORTED	正文
图 12	fig12_model_class_accuracy_heatmap.pdf	metrics_per_class.csv	PROJECT_SUPPORTED	正文
图 13	fig13_low_snr_class_recall_delta.pdf	confusion_low_snr.csv	PROJECT_SUPPORTED	正文
图 14	fig14_paired_disagreement_by_snr.pdf	predictions_test.csv	PROJECT_SUPPORTED	正文
图 15	fig15_seed_stability_all_models.pdf	metrics_test.json	PROJECT_SUPPORTED	正文
图 16	fig16_overall_confusion_panels.pdf	confusion_overall.csv	PROJECT_SUPPORTED	附录

A.3 补充超参、训练曲线与混淆矩阵

表 A.3 汇总主实验共用训练设置。该表用于解释第 4 章 MCLDNN 异常诊断中的“统一超参”含义。

表 A.3 主实验训练与特征超参摘要

项目	设置
数据划分	stratified_by_mod_snr_seed42; 训练/验证/测试为 154,000 / 22,000 / 44,000。
训练种子	42, 2025, 3407。
最大轮数与早停	最大 30 轮; 早停 patience 为 8。
优化器核心设置	学习率 10^{-3} , 权重衰减 10^{-4} , batch size 256。
STFT 设置	窗口长度 32, 重叠长度 16; 受控延迟表未计入完整 STFT 预处理。
低信噪比定义	$\text{SNR} \leq -6 \text{ dB}$; 每个训练种子测试集中 17,600 个低信噪比样本。




图 A.1 代表模型训练曲线补充 (seed 42); MCLDNN seed 2025 对应第 4 章单类塔陷案例。






图 A.2 代表模型在低信噪比范围内的行归一化混淆矩阵，三训练种子聚合（confusion_low_snr.csv）。

Overall normalized confusion matrices (aggregated across seeds)



Data source: confusion_overall.csv for seeds 42, 2025, and 3407.

图 A.3 代表模型在整体测试集上的行归一化混淆矩阵，三训练种子聚合（confusion_overall.csv）。



Data source: mclldnn/seed_*/metrics_test.json. Seeds 2025 and 3407 are retained negative evidence.

图 A.4 MCLDNN 在三个训练种子上的整体准确率与宏平均 F1（seed 2025 与 seed 3407 作为负结果保留）。




图 A.5 本文证据标签与排除规则示意图。

附录 B 完整训练超参表

为便于复现，表 B.1 把本报告所有训练运行的超参按证据标签汇总成一张主表。所有运行共享同一固定划分 stratified_by_mod_snr_seed42（按 modulation $\times$ snr 联合分层；切分种子 42；训练/验证/测试 70/10/20%）与同一三训练种子集合 42, 2025, 3407。脚本与配置路径见正文章节引用。

表 B.1 按证据标签汇总的训练超参（所有标签共用固定划分与三训练种子集合）

证据标签	GPU	epoch	batch	lr	调度器	损失	增强	模型范围
PROJECT_SUPPORTED (Stage 5A)	4070	30	256	10^{-3}	恒定	CE	无	9 个主表模型
EXTENDED_BUDGET_3090	3090	50	256	10^{-3}	cosine + 5w	CE	无	cnn1d / resnet1d / iq_param_matched / fusion_iq_stft cldnn / fu- sion_iq_stft fusion_cldnn_stft fusion_cldnn_stft $\times 3$ 变体
LOW_SNR_WEIGHTED_CE_3090	3090	50	256	10^{-3}	cosine + 5w	SnrW (2/1/0.7)	无	—
FUSION_CLDNN_STFT_AUG_LS_3090	3090	50	256	10^{-3}	cosine + 5w	CE $\epsilon = 0.1$	rot+shift	—
FUSION_CLDNN_STFT_ABLATION_3090	3090	50	256	10^{-3}	cosine + 5w	见变体	见变体	—
arch_only 变体						CE	无	—
arch_aug 变体						CE	rot+shift	—
arch_ls 变体						CE $\epsilon = 0.1$	无	—
CONTROLLED_LATENCY_EXTENDED	EPYC CPU	—	1/256	—	—	—	—	9 个模型, 仅前 向 (warmup 50/measured 200, 单线程)

共用项：优化器 AdamW ($\beta_1=0.9$, $\beta_2=0.999$, $\epsilon=10^{-8}$, 权重衰减 10^{-4})；早停耐心值 Stage 5A=8、Stage 6 扩展 =15，依据均为验证集准确率；划分 NPZ 路径 data/splits/rml2016a/stratified_by_mod_snr_seed42.npz。增强 “rot+shift” 表示相位旋转 $\theta \sim \mathcal{U}(-\pi, \pi)$ prob 0.5 + 循环时移 $k \sim \mathcal{U}(-8, +8)$ prob 0.5，仅 train loader 启用。损失 “SnrW (2/1/0.7)” 表示分组 SNR 加权 CE，权重 low= 2.0、mid= 1.0、high= 0.7，SNR 边界 $\text{low} \leq -6$ dB / $\text{mid} \in [-4, 6]$ dB / $\text{high} \geq 8$ dB。配置文件分别为 configs/paper/rml2016a_main_table_full_template.yaml、rml2016a_extended_budget_3090.yaml、rml2016a_low_snr_weighted_ce_3090.yaml、rml2016a_fusion_cldnn_stft_aug_ls_3090.yaml、rml2016a_fusion_cldnn_stft_ablation_3090.yaml。