

中国传媒大学作业报告

面向 RadioML2016.10A 的固定划分 多视图融合调制识别：基线、扩展实验 与 CLDNN-STFT 提案模型评估

机器学习课程作业报告

姓名：申奥

学号：202520081000092

日期：2026 年 5 月

摘 要

低信噪比下的自动调制识别中，多视图时频融合是否真正有效尚需实证检验。本文以 RadioML2016.10A 固定划分 `stratified_by_mod_snr_seed42` 与三个训练种子建立 9 模型 $\times$ 3 种子 = 27 运行单元的协议化主实验，并以独立证据标签登记四类扩展实验与一个提案模型。主实验中 CLDNN 取得最高整体准确率 0.6129、宏平均 F1 0.6332；静态 I/Q-STFT 融合接近 CLDNN 但有整体损失；标量门控融合低于静态融合，构成负结果；MCLDNN 两个训练种子单类塌陷被保留登记。提案模型 `fusion_cldnn_stft` 把 fusion 的 I/Q 分支升级为 CLDNN 风格编码器，叠加保标签的相位旋转加循环时移信号域增强（仅训练）与标签平滑 0.1，在同一固定划分与三训练种子下取得平均整体准确率 0.6264 ($\sigma = 0.0005$)，相对 CLDNN 基线提升 1.35 个百分点，且整体、低、中、高信噪比四项指标同时正向；`avg(SNR > 0)` 维度 0.9237 超过 MCLDNN 原论文报告的 0.9112。提案模型与 2024 年代复值多流 / Transformer 混合基线量级一致，与 LENet-M (0.6463) 和 SigFormer (0.6371) 仍有 1-2 个百分点差距。本研究受单数据集、硬件变更与未做单干预消融三条边界限制；跨数据集一致性留作未来工作。

关键词：自动调制识别；RadioML2016.10A；时频特征；多视图融合；CLDNN；信号域增强；配对统计检验

目录

摘 要	I
第一章 绪论	1
1.1 研究背景	1
1.2 研究问题	2
1.3 本文工作与贡献	2
1.4 全文结构	3
第二章 数据集、实验协议与评价指标	5
2.1 数据集与任务定义	5
2.2 固定划分与训练种子	5
2.3 模型矩阵	6
2.4 特征与训练设置	6
2.5 评价指标与信噪比分组	6
2.6 配对统计检验协议	7
2.7 证据边界	7
2.8 扩展实验的独立证据标签	8
第三章 模型方法与融合结构	10
3.1 输入表示	10
3.2 模型家族与比较目的	10
3.3 I/Q 序列模型	11
3.4 STFT 单视图模型	12
3.5 参数匹配 I/Q 控制模型	12
3.6 静态 I/Q-STFT 融合	12
3.7 标量门控融合	12
3.8 提案模型与训练侧干预	13
3.9 实现细节与方法边界	14
第四章 实验结果与统计检验	16

4.1	主实验整体结果	16
4.2	整体性能的配对检验	18
4.3	低信噪比下的融合权衡	19
4.3.1	低信噪比互补性图谱分析	19
4.4	门控融合负结果	22
4.5	复杂度与受控 CUDA 前向延迟	22
4.6	MCLDNN 异常与负结果保留	23
4.7	扩展实验与提案模型	25
4.7.1	扩展实验摘要	25
4.7.2	文献校准与可比 SOTA	25
4.7.3	提案模型 fusion_cldnn_stft+ 增强 + 标签平滑	27
4.7.4	提案模型单干预消融与配对统计检验	28
第五章	讨论、局限性与可复现性	31
5.1	固定协议下结果的含义	31
5.2	STFT 融合的低信噪比权衡	31
5.3	融合失败原因诊断	31
5.4	复杂度与运行时证据限制	32
5.5	提案模型反超的解释边界	32
5.6	协议局限与后续处理	33
5.7	可复现性与证据边界	33
第六章	总结	35
6.1	工作总结	35
6.2	主要结论	35
6.3	不足与后续工作	36
	参考文献	37
附录 A	证据包、环境与补充图表	41
A.1	证据包与环境摘要	41
A.2	补充超参、训练曲线与混淆矩阵	41

第一章 绪论

1.1 研究背景

无线电自动调制识别（Automatic Modulation Classification, AMC）是在未知调制方式条件下，根据接收信号自动判别调制类别的任务。它是频谱感知、认知无线电、通信监测和非合作通信分析中的基础环节。RadioML 系列数据集和基于卷积神经网络的端到端识别方法推动了深度学习在 AMC 任务中的应用^[1-3]。与人工统计特征方法相比，深度模型能够直接从原始 I/Q 序列或派生时频表示中学习判别特征，但其结果也更依赖数据划分、训练随机性和评价协议。

传统 AMC 研究长期关注似然方法、高阶累积量和人工特征分类器^[4-7]，深度学习方法则把特征提取和分类器学习合并到端到端训练流程中。低信噪比条件是 AMC 任务中的主要困难之一。噪声会削弱 I/Q 序列中的相位、幅度和瞬时频率线索，使不同调制类别在观测空间中更加接近。短时傅里叶变换（Short-Time Fourier Transform, STFT）将信号局部频率结构显式展开^[8-12]，理论上可能为低信噪比样本提供与原始 I/Q 序列互补的判别信息。然而，额外视图和更复杂的融合结构并不必然带来整体收益；融合模型是否有效，需要在固定数据划分、统一模型矩阵和配对统计检验下谨慎判断。

已有 AMC 深度学习研究通常使用结构图、准确率随信噪比变化曲线、混淆矩阵、消融表和复杂度表展示模型行为^[13-18]。表 1.1 归纳了若干代表性文献中常见的图表用途。本文沿用这一表达方式，但重点不是追求“最新水平”排名，而是在课程实验范围内说明不同输入视图和模型结构在固定协议下的可比结果。

表 1.1 代表性 AMC 文献中的图表表达与本文图表设计

代表性文献	结构图	信噪比曲线	混淆矩阵	复杂度表	对本文的启发
RadioML 数据集与 GNU Radio 生成流程 ^[1]	是	是	否	否	明确数据集来源、信噪比轴和样本生成背景。
卷积神经网络调制识别 ^[2]	是	是	是	否	将 I/Q 序列基线和信噪比曲线作为核心结果呈现。
深层 AMC 架构比较 ^[3]	是	是	是	是	用统一协议比较 CNN、循环和混合结构。
MCLDNN 多通道时空学习框架 ^[19]	是	是	是	是	为多分支时序模型和异常结果解释提供背景。
轻量级 AMC 网络 ^[20]	是	是	否	是	将参数量和受控前向耗时作为性能之外的补充维度。
AMC 深度学习综述 ^[18]	是	是	是	是	支持本文采用“协议、主表、分信噪比、混淆和复杂度”组合呈现。

1.2 研究问题

本文研究 RadioML2016.10A 上的 11 类调制分类问题。给定长度为 128 的双通道 I/Q 样本，模型输出对应的调制类别。任务范围聚焦于调制分类性能，信噪比估计、信道识别、频谱占用检测和端到端部署系统优化不纳入本报告评估。

围绕这一任务，本文关注三个问题：第一，在同一固定划分和相同训练种子集合下，I/Q 序列模型、STFT 时频模型和 I/Q-STFT 融合模型的整体表现如何；第二，STFT 视图是否在低信噪比样本上提供可观察的局部补充信息；第三，门控融合、轻量结构和参数匹配控制在该固定协议中如何帮助解释性能差异。本报告的证据边界为 RadioML2016.10A、固定划分 stratified_by_mod_snr_seed42、9 个模型行和 3 个训练种子 42, 2025, 3407；涉及其他数据集、真实外场信道和端到端部署效率的问题留作后续工作。

1.3 本文工作与贡献

本文完成了一个证据边界清晰的 AMC 课程实验报告。实验矩阵包含 cnn1d、resnet1d、tfCNN_stft、fusion_iq_stft、cldnn、mclDnn、lwamcnet、iq_param_matched 和 gated_fusion_iq_stft 共 9 个模型行，每个模型使用 3 个训练种子，因此主实验包含 27 个运行单元。模型类型覆盖原始 I/Q 卷积基线、STFT 时频分支、静态多视图融合、门控多视图融合、卷积-循环混合模型、轻量模型和参数匹配 I/Q 控制模型。

本文的主要贡献如下：

1. 在 RadioML2016.10A 上整理了固定划分、三训练种子和 9 个模型行的协议化比较，使模型差异不与数据划分变化混杂。
2. 在整体性能和低信噪比分组两个层面分析 I/Q-STFT 静态融合，并通过参数匹配 I/Q 控制模型避免把参数规模变化误解释为视图融合收益。
3. 使用同一测试样本上的配对预测结果进行自助法置信区间估计和 McNemar 检验^[21-22]，区分统计支持、实际差异大小和未被证据支持的外推说法。
4. 保留门控融合和 MCLDNN 异常训练种子等负结果，使报告反映完整固定协议，而不是只选择表现更好的运行。
5. 通过四项独立证据标签的扩展实验（延长训练预算、低信噪比加权交叉熵、扩展复杂度与单线程 CPU 延迟测量、低信噪比类别混淆后处理）依次排除 Stage 5A 主表的常见 reviewer 质疑，确认主表性能不是欠训练或损失函数偷懒造成的。

- 在文献校准基础上提出提案模型 `fusion_cldnn_stft`：以 CLDNN 风格 I/Q 编码器替换静态融合中的轻量 I/Q 分支，并结合相位旋转加循环时移信号域增强与标签平滑 0.1。在同一固定划分和三训练种子下，提案模型整体准确率反超 Stage 5A 的 CLDNN 基线 1.35 个百分点，并在整体、低、中、高信噪比四项指标上同时正向。

前四条贡献服务于课程实验中的协议化比较与负结果分析；第五条扩展实验贡献以独立证据标签组织，主表与统计检验完全冻结；第六条提案模型贡献是本文的正面发现，但仍受限于单数据集、登记证据标签与硬件设置变更等边界条件。受控 CUDA 前向延迟与扩展多线程 CPU 延迟作为相同测量条件下的运行时背景，不进入广义部署效率结论。




图 1.1 本文主实验与统计检验的证据链：数据集经固定划分后进入模型矩阵，测试集预测和聚合表共同支撑正文结论；诊断性材料不进入主结果。

1.4 全文结构

第 2 章介绍数据集、固定划分、模型矩阵、评价指标、配对统计检验协议以及为后续扩展实验登记的多个证据标签边界。第 3 章说明输入视图、模型家族、静态融合、门控融合、参数匹配控制，以及提案模型 `fusion_cldnn_stft`、信号域增强与标签平滑的方法描述。第 4 章给出主实验结果、低信噪比权衡、统计检验、复杂度边界、MCLDNN 异常，以及一组扩展实验与提案模型的协议化比较结果。第 5 章讨论固定协议下的解释范围、负结果意义、提案模型反超的解释、运行时证据限制和可复现性边界。第 6 章总结全文发现与后续工作方向。




图 1.2 图中术语对照：Trainable parameters= 可训练参数量，Avg-across-SNR test accuracy= 平均跨 SNR 测试准确率。本文实验矩阵（蓝/青色 Stage 5A 模型行、红色 Stage 5A MCLDNN 异常、红色钻形提案模型）与近期文献基线（紫色三角，CC-MSNet、CCTL-Net、ICRNNA、SigFormer、LENet-M）的位置关系。横轴对数标度，纵轴 avg-across-SNR 准确率与本文 overall_accuracy 同口径。LENet-M 报告的 0.6463 与本文 Stage 5A CLDNN 的 0.6129 由水平虚线标出。

第二章 数据集、实验协议与评价指标

2.1 数据集与任务定义

本文主实验使用 RadioML2016.10A 数据集^[1]。该数据集在本实验配置下包含 220,000 个样本、11 类调制方式和 20 个信噪比取值，信噪比范围为 -20 dB 至 18 dB，步长为 2 dB。每个“调制方式-信噪比”组合包含 1,000 个样本。单个样本的输入形状为 2×128 ，两个通道分别为同相分量和正交分量，数据类型为 `float32`。主实验仅以调制类别为分类目标，不进行信噪比估计、信道识别或部署系统优化。

表 2.1 主实验数据集与固定划分摘要

项目	设置
数据集	RadioML2016.10A; 220,000 个样本, 11 类调制方式, 20 个信噪比取值。
样本形状	2×128 I/Q 序列。
信噪比范围	$-20, -18, \dots, 18$ dB; 每个调制方式-信噪比组合 1,000 个样本。
固定划分	<code>stratified_by_mod_snr_seed42</code> ; 按调制方式与信噪比分层。
训练/验证/测试	154,000 / 22,000 / 44,000, 对应 70% / 10% / 20%。
主实验规模	9 个模型行, 3 个训练种子 42, 2025, 3407, 共 27 个运行单元。
低信噪比分组	$\text{SNR} \leq -6$ dB; 测试集中每个训练种子对应 17,600 个低信噪比样本。

本文同时使用原始 I/Q 视图和 STFT 时频视图。I/Q 视图保留基带信号的时间采样结构；STFT 视图通过窗口化傅里叶变换描述局部频率成分^[8]。主表中的模型身份由模型标识与输入视图共同决定，后续结果均按这一身份汇总。

2.2 固定划分与训练种子

为降低采样随机性对模型比较的影响，本文采用固定划分 `stratified_by_mod_snr_seed42`。该划分按调制方式和信噪比联合分层，使训练、验证和测试集合在类别与信噪比分布上保持一致。所有主实验模型行均使用同一划分，不为不同模型或不同训练种子重新生成测试集。

每个模型行使用 3 个训练种子 42, 2025, 3407。因此，表格中的均值和标准差表示在这 3 个训练种子上的协议内汇总。固定划分提高了模型行之间的可比性；多数据集、多划分和真实信道条件验证将在第 5 章作为协议局限讨论。

MCLDNN 行同样遵循该三种子协议。两个训练种子出现近似随机水平的单类预测现象，相关运行仍保留在主表中。主结果采用完整三种子聚合，后续诊断候选作为新的实验问题处理。

2.3 模型矩阵

主实验包含九个模型行，覆盖 I/Q 基线、时频输入、时序模型、轻量模型、参数匹配控制和双视图融合。表 2.2 给出模型矩阵及其解释边界。

表 2.2 主实验模型矩阵与输入视图

模型标识	输入视图	角色	协议解释边界
cnn1d	I/Q	一维卷积基线	用于原始 I/Q 序列基准比较。
resnet1d	I/Q	残差卷积基线	用于深层 I/Q 卷积对照。
tfcnn_stft	STFT	时频单视图模型	单独评估 STFT 视图的判别能力。
fusion_iq_stft	I/Q+STFT	静态融合模型	检验双视图拼接融合，不预设优越性。
cldnn	I/Q	卷积-循环混合模型	作为时域卷积与序列建模参考。
mcldnn	I/Q	多分支卷积-循环模型	保留三种子协议，包括异常种子。
lwamcnet	I/Q	轻量模型	用作较低参数量结构参考。
iq_param_matched	I/Q	参数匹配控制	控制融合模型额外参数带来的解释偏差。
gated_fusion_iq_stft	I/Q+STFT	门控融合模型	检验样本级标量门控，不预设鲁棒性提升。

2.4 特征与训练设置

STFT 视图使用窗口长度 32、重叠长度 16 的短时傅里叶变换配置。STFT 在报告中作为输入视图之一，用于比较“仅 I/Q”“仅 STFT”和“I/Q+STFT”三类模型；受控延迟表中的前向耗时未计入完整的 STFT 预处理成本。

训练配置在主实验中保持一致：最大训练轮数为 30，批量大小为 256，优化器学习率为 0.001，权重衰减为 0.0001，早停耐心值为 8。报告中的训练随机性只通过 3 个训练种子的均值和标准差体现，不额外引入未登记的训练轮次或子集实验。

2.5 评价指标与信噪比分组

本文报告整体准确率、低/中/高信噪比分组准确率、宏平均 F1 和均衡准确率。整体准确率反映固定测试集上的总体分类正确率；宏平均 F1 对各调制类别等权平均，能

补充说明类别层面的均衡性；均衡准确率对各类别召回率作平均，可降低类别难度差异对单一准确率解释的影响。

信噪比分组用于观察模型在不同信道难度下的行为。低信噪比定义为 $\text{SNR} \leq -6 \text{ dB}$ ；中等信噪比覆盖 -4 dB 至 6 dB ；高信噪比覆盖 8 dB 至 18 dB 。低信噪比结果在后文单独讨论，因为这是本文判断 STFT 视图是否具有局部补充价值的关键范围。

2.6 配对统计检验协议

除三种子聚合指标外，本文使用配对自助法和 McNemar 检验支撑主要模型对比较^[21-22]，并参考多分类器比较中的多重检验写作规范^[23]。两类检验均基于主实验测试集预测结果，匹配键为固定划分标识、训练种子和测试样本标识，因而比较的是同一测试样本上两个模型的正确性差异。

配对自助法估计准确率差值

$$\Delta_{\text{acc}} = \text{Acc}(m_a) - \text{Acc}(m_b), \quad (2.1)$$

其中 m_a 和 m_b 为已登记比较中的两个模型。自助重采样次数为 10,000，随机种子为 42。McNemar 检验基于两个模型在同一样本上的“正确/错误”列联表，关注两个方向的不一致样本数是否存在系统差异。

统计检验覆盖已登记的 overall 和低信噪比比较。所有可能模型对的全量假设检验未纳入本轮协议；相关 p 值服务于固定协议内的登记比较解释。

2.7 证据边界

正文主结果使用完整固定协议材料；受控 CUDA 前向延迟说明参数量和相同测量条件下的推理背景；mock、子集、筛查或后续诊断性运行归入工程记录和未来工作边界。更细的同步路径、环境差异、权重归档状态和排除规则放在附录 A 中说明。

表 2.3 图表证据源映射表

图号	文件	主要数据源	证据标签	使用位置
图 1	fig01_protocol_pipeline.tex	协议文档、清单、统计检验包	PROJECT_SUPPORTED	正文
图 2	fig02_model_taxonomy.tex	main_table_metrics.csv; 模型注册代码	PROJECT_SUPPORTED	正文
图 3	fig03_fusion_architecture.tex	模型源码	PROJECT_SUPPORTED	正文

图号	文件	主要数据源	证据标签	使用位置
图 4	fig04_accuracy_by_snr_group.pdf	main_table_metrics.csv	PROJECT_SUPPORTED	正文
图 5	fig05_low_snr_per_snr_curve.pdf	low_snr_table.csv	PROJECT_SUPPORTED	正文
图 6	fig06_bootstrap_delta_forest.pdf	paired_bootstrap_accuracy_deltas.csv	PROJECT_SUPPORTED	正文
图 7	fig07_accuracy_latency_params_bubble.pdf	main_table_metrics.csv; complexity_latency_table.csv	CONTROLLED_LATENCY	正文
图 8	fig08_low_snr_confusion_panels.pdf	confusion_low_snr.csv	PROJECT_SUPPORTED	附录
图 9	fig09_mclldnn_seed_anomaly.pdf	MCLDNN 各种子测试指标	PROJECT_SUPPORTED	附录
图 10	fig10_evidence_boundary.tex	证据边界文档与环境审计记录	混合标签	附录
图 11	fig11_full_snr_accuracy_macro_f1.pdf	metrics_per_snr.csv	PROJECT_SUPPORTED	正文
图 12	fig12_model_class_accuracy_heatmap.pdf	metrics_per_class.csv	PROJECT_SUPPORTED	正文
图 13	fig13_low_snr_class_recall_delta.pdf	confusion_low_snr.csv	PROJECT_SUPPORTED	正文
图 14	fig14_paired_disagreement_by_snr.pdf	predictions_test.csv	PROJECT_SUPPORTED	正文
图 15	fig15_seed_stability_all_models.pdf	测试集指标文件	PROJECT_SUPPORTED	正文
图 16	fig16_overall_confusion_panels.pdf	confusion_overall.csv	PROJECT_SUPPORTED	附录

2.8 扩展实验的独立证据标签

为了在不修改 Stage 5A/5B 主表数值的前提下回答常见 reviewer 关切并评估提案模型，本文额外登记了五个独立证据标签，每个标签使用单独的输出根目录与独立的报告文档。表 2.4 概括各证据标签的目的、模型范围和写作位置。所有扩展实验的训练硬件均为 NVIDIA RTX 3090 (Ampere sm_86)，与 Stage 5A 主实验所用 RTX 4070 (Ada sm_89) 不同；该硬件变更被显式登记为不能跨标签做样本级配对统计检验的协议混淆因素，三种子均值层面的解释仍受支持。

任一证据标签的结果均不改写主表均值、宏平均 F1、低/中/高信噪比分组、配对自助法置信区间或 McNemar 检验。第 4.7 节中的扩展实验段落使用各自的标签数值并显式说明硬件变更，避免与 Stage 5A 数值混杂。

表 2.4 扩展实验的独立证据标签与解释边界

证据标签	目的与解释边界
EXTENDED_BUDGET_3090	训练预算延长 (epoch 50、5 轮线性 warmup、余弦退火)、4 个模型 $\times$ 3 个种子；用于检验 Stage 5A 是否被训练预算截断；不进入主表，结果作为 sensitivity 写在第 4.7 节。
LOW_SNR_WEIGHTED_CE_3090	分组 SNR 加权交叉熵 (low= 2.0、mid= 1.0、high= 0.7)；2 个模型 $\times$ 3 个种子；用于检验最简单的 SNR-aware 损失能否改变低信噪比与整体的权衡；不进入主表，结果作为 intervention 写在第 4.7 节。
CONTROLLED_LATENCY_EXTENDED	单线程 CPU 前向延迟与 MACs/FLOPs；与 Stage 5A 同 PyTorch 与同 CUDA 构建，仅设备目标改为 CPU，并强制单线程；用于补全主表中空缺的 MACs/FLOPs 与 CPU 行；解释边界仍限于受控前向，不能等同于完整部署效率。
Stage 5A 预测后处理	仅对已归档的 27 份 predictions_test.csv 做行归一化的低信噪比类别混淆矩阵；不重新训练；与父 PROJECT_SUPPORTED 共用证据标签，但物理上写在独立目录下，便于审阅。
FUSION_CLDNN_STFT_AUG_LS_3090	探索模型的协议化评估，1 个模型 $\times$ 3 个种子；同一固定划分与同 P1.1 训练计划，叠加 CLDNN 风格 I/Q 编码器、相位旋转加循环时移信号域增强（仅训练）和标签平滑 0.1；不进入主表，作为正向贡献写在第 4.7 节，硬件变更与三干预未做单点消融均登记为已知局限。

第三章 模型方法与融合结构

3.1 输入表示

本文的输入表示分为原始 I/Q 序列和 STFT 时频图两类。原始 I/Q 输入记为 $x_{IQ} \in \mathbb{R}^{2 \times 128}$ ，两个通道分别为同相分量和正交分量。该表示保留基带信号的时间采样结构，是 CNN、ResNet、CLDNN、MCLDNN、LWAMCNet 和参数匹配控制模型的共同输入。

STFT 视图通过对 I/Q 序列进行窗口化傅里叶变换得到。设窗函数为 $w[n]$ ，窗口起点为 τ ，频率索引为 k ，则单通道短时傅里叶变换可写为

$$X(\tau, k) = \sum_n x[n] w[n - \tau] \exp(-j2\pi kn/N). \quad (3.1)$$

实验中窗口长度为 32，重叠长度为 16。STFT 分支使用幅度型二维时频表示作为卷积输入。本文只把 STFT 作为可检验输入视图，不预设其相对 I/Q 序列必然更优。

3.2 模型家族与比较目的

图 3.1 概括了主实验模型行的输入视图和方法角色。模型矩阵的设计目标是覆盖课程报告所需的主要比较维度：原始 I/Q 基线、时频单视图、多视图融合、卷积-循环混合结构、轻量模型和参数匹配控制。




图 3.1 主实验模型行的输入视图与方法角色。所有模型均在同一数据集、固定划分和训练种子集合下评估，方法类别本身不表示性能优劣。

表 3.1 模型家族、输入视图与方法角色

模型家族	模型行	输入视图	方法角色
基础一维卷积	cnn1d	I/Q	原始 I/Q 卷积基线，承接早期 CNN 调制识别思路 ^[2] 。
残差卷积	resnet1d	I/Q	提供更深的一维卷积对照。
时频卷积	tfcnn_stft	STFT	单独检验 STFT 视图的判别性。
卷积-循环混合	cldnn, mclnn	I/Q	比较卷积局部特征与序列建模结合的结构 ^[3,19,24] 。
轻量结构	lwamcnet	I/Q	提供较低参数量网络参考 ^[20] 。
参数匹配控制	iq_param_matched	I/Q	控制参数规模，辅助解释融合结果。
静态融合	fusion_iq_stft	I/Q+STFT	拼接两个视图表征，检验多视图互补性。
门控融合	gated_fusion_iq_stft	I/Q+STFT	用标量门控调节两个视图贡献，作为候选机制接受实验检验。

3.3 I/Q 序列模型

cnn1d 直接以 x_{IQ} 为输入，通过一维卷积、归一化、非线性激活、池化和分类头输出调制类别。其抽象形式为

$$h_{IQ} = f_{1D}(x_{IQ}), \quad \hat{y} = c(h_{IQ}), \quad (3.2)$$

其中 f_{1D} 表示一维卷积特征提取器， $c(\cdot)$ 表示分类头。resnet1d 在一维卷积堆叠中加入残差连接，用于提供更深的 I/Q 卷积对照。

cldnn 和 mclnn 属于卷积-循环混合结构。CLDNN 先提取局部卷积特征，再通过 LSTM 建模序列依赖^[25]，最后完成分类；这类结构最早在语音识别中形成典型组合^[24]，也被用于 AMC 架构比较^[3]。本文中的 MCLDNN 对应多通道时空学习思路^[19]，包含多个 I/Q 分支、后续融合卷积、LSTM 和分类器。由于 MCLDNN 在本实验中存在异常训练种子，本章只说明结构角色，结果解释放在第 4 章和第 5 章。

lwamcnet 是轻量化 I/Q 模型，对应轻量 CNN 在 AMC 中的设计思路^[20]。本文把“轻量”限定为参数量和受控前向耗时背景，不直接等同于完整部署效率。完整部署效率还需要 CPU、预处理、数据搬运和端到端推理协议支持。

3.4 STFT 单视图模型

`tf_cnn_stft` 只使用 STFT 时频图。模型通过二维卷积从时频平面中提取局部模式，再经池化和分类头输出调制类别。其抽象形式为

$$h_{\text{STFT}} = f_{2\text{D}}(x_{\text{STFT}}), \quad \hat{y} = c(h_{\text{STFT}}). \quad (3.3)$$

该模型用于回答“时频视图本身是否具有判别性”，而不是作为融合模型的直接性能上界。

3.5 参数匹配 I/Q 控制模型

`iq_param_matched` 仍只使用 I/Q 输入，但通过通道数和分类头规模调整，使参数量接近融合模型。引入该控制模型的原因是，多视图融合通常会增加分支和投影参数；如果只与较小 I/Q 基线比较，难以判断性能差异来自额外输入视图还是参数量变化。参数匹配控制将输入视图固定为 I/Q，因此为第 4 章解释低信噪比局部收益提供更清晰的参照。

3.6 静态 I/Q-STFT 融合

`fusion_iq_stft` 包含 I/Q 分支和 STFT 分支。两个分支分别提取表示

$$h_{\text{IQ}} = f_{\text{IQ}}(x_{\text{IQ}}), \quad h_{\text{STFT}} = f_{\text{STFT}}(x_{\text{STFT}}), \quad (3.4)$$

随后进行特征拼接并输入分类器：

$$z = [h_{\text{IQ}}, h_{\text{STFT}}], \quad \hat{y} = c(z). \quad (3.5)$$

该结构用于检验时域和时频视图在固定协议下是否形成互补。本文不在方法章节预设其优势，所有效果判断均以第 4 章结果为准。

3.7 标量门控融合

`gated_fusion_iq_stft` 在两个视图投影到相同维度后，用样本级标量门控调节贡献比例。门控输入由两个投影表示、绝对差和逐元素乘积组成：

$$r = [z_{\text{IQ}}, z_{\text{STFT}}, |z_{\text{IQ}} - z_{\text{STFT}}|, z_{\text{IQ}} \odot z_{\text{STFT}}], \quad (3.6)$$

$$g = \sigma(W_2 \phi(W_1 r)), \quad h = (1 - g)z_{IQ} + gz_{STFT}, \quad (3.7)$$

其中 g 为标量门控权重, $\sigma(\cdot)$ 为 sigmoid 函数, $\phi(\cdot)$ 为非线性激活。该门控不显式输入信噪比, 因此它只能被视为一个可检验的视图加权候选, 而不是先验的低信噪比鲁棒机制。




图 3.2 静态 I/Q-STFT 融合与标量门控融合结构。静态融合直接拼接两个分支表征; 门控融合用样本级标量权重组合两个投影表征。

3.8 提案模型与训练侧干预

提案模型 `fusion_cldnn_stft` 的动机来自第 4 章扩展复杂度证据: 静态 `fusion_iq_stft` 的 I/Q 分支乘加量 2.0 M 显著低于 `resnet1d` 的 4.9 M, 因此“融合输给 CLDNN”的瓶颈更可能是 I/Q 表征容量。基于此, 提案模型把 I/Q 分支替换为 CLDNN 风格 (`CLDNNIQBranch`)——与 `cldnn` 同体的卷积特征栈加单层 LSTM^[24-25], 取 LSTM 末态作为分支嵌入; STFT 分支沿用原 `fusion_iq_stft` 中的 2D-CNN^[26], 分类头为小型 MLP^[27]。形式化地,

$$h_{IQ} = \text{LSTM}(f_{1D}(x_{IQ}))_{\text{last}}, \quad h_{STFT} = f_{2D}(x_{STFT}), \quad \hat{y} = c([h_{IQ}, h_{STFT}]). \quad (3.8)$$

模型总参数量 286k, 介于 `cldnn` 的 241.7k 与 `mcldnn` 的 406.2k 之间; 表 3.2 给出逐层结构。提案模型登记于独立证据标签 `FUSION_CLDNN_STFT_AUG_LS_3090`, 不进入主表。

提案模型在训练侧叠加两类干预。* 信号域增强 * 仅在训练集启用: 以概率 0.5 做相位旋转 $\theta \sim \mathcal{U}(-\pi, \pi)$ (对 (I, Q) 应用旋转矩阵 $[\cos \theta, -\sin \theta; \sin \theta, \cos \theta]$), 与以概率 0.5 做循环时移 $k \sim \mathcal{U}(-8, +8)$ (沿时间维 $\text{roll}(\cdot, k)$)。两者对调制类型分类保标签且保有效 SNR; 幅度缩放与加性高斯噪声因会改变有效 SNR 而不予采用, 图像式 mixup 因 I/Q 直接线性插值不可解释^[28-29]也不采用。* 标签平滑 * $\epsilon = 0.1$ ^[30] 把 one-hot 目标替换为 $(1 - \epsilon)\delta_y + \epsilon/K$ ($K = 11$), 与 `SnrWeightedCrossEntropy` 互斥, 由 `train.loss`

表 3.2 提案模型 fusion_cldnn_stft 逐层结构（输入形状均按 batch=1 标记）

分支 / 层	操作	输入形状	输出形状
I/Q 分支 (CLDNNIQBranch)			
Conv1d-1	kernel 7, padding 3, 64 通道, BN, ReLU	[2, 128]	[64, 128]
MaxPool1d-1	kernel 2	[64, 128]	[64, 64]
Conv1d-2	kernel 5, padding 2, 128 通道, BN, ReLU	[64, 64]	[128, 64]
MaxPool1d-2	kernel 2	[128, 64]	[128, 32]
Conv1d-3	kernel 3, padding 1, 128 通道, BN, ReLU	[128, 32]	[128, 32]
LSTM (单层)	hidden=128, batch_first, 取最后时刻 h_T	[32, 128]	[128]
STFT 分支 (TimeFrequencyBranch2D)			
Conv2d-1	kernel 3, padding 1, 16 通道, BN, ReLU	[1, 32, 7]	[16, 32, 7]
MaxPool2d-1	kernel 2	[16, 32, 7]	[16, 16, 3]
Conv2d-2	kernel 3, padding 1, 32 通道, BN, ReLU	[16, 16, 3]	[32, 16, 3]
MaxPool2d-2	kernel 2	[32, 16, 3]	[32, 8, 1]
Conv2d-3	kernel 3, padding 1, 64 通道, BN, ReLU	[32, 8, 1]	[64, 8, 1]
AdaptiveAvgPool2d-1	output 1 × 1, flatten	[64, 8, 1]	[64]
融合分类头			
Concat	拼接两个分支嵌入	[128] + [64]	[192]
Linear-1	192 → 192, ReLU, Dropout 0.1	[192]	[192]
Linear-2	192 → 11 (类别数)	[192]	[11]

字段配置。

3.9 实现细节与方法边界

所有模型使用 PyTorch 2.9.1+cu128^[31]、NVIDIA driver 570.* 与同一份固定划分。Stage 5A 主表在 RTX 4070 (Ada sm_89) 上训练，所有 Stage 6 扩展实验与提案模型在 RTX 3090 (Ampere sm_86) 上训练；该硬件差异作为协议混淆因素登记。共用训练设置：优化器 AdamW^[32-33] 学习率 $\eta = 10^{-3}$ （AMR 卷积网络的常用值^[16,19]）、权重衰减 10^{-4} ^[34]、批量 256；最大训练轮数 Stage 5A 30 / Stage 6 扩展 50；早停耐心值 Stage 5A 8 / Stage 6 扩展 15，依据均为验证集准确率。Stage 6 扩展实验与提案模型额外采用 5 轮线性 warmup + cosine annealing 学习率^[35]。损失函数默认标准交叉熵；提案模型加 $\epsilon = 0.1$ 标签平滑；LOW_SNR_WEIGHTED_CE_3090 使用分组 SNR 加权 CE（权重见第 4.7.1 节）。统一超参作用于 9 个主表模型以保持比较纪律，不做模型级事后调参。

提案模型由架构升级、信号域增强与标签平滑三项干预联合构成；第 4.7.4 节给出三个单干预消融变体的协议化评估。本章方法描述限定于已登记模型与训练设置，不引

入未在第 4 章评估的诊断性候选。

第四章 实验结果与统计检验

本章在第 2 章定义的固定划分、模型矩阵和评价指标基础上展示主实验结果。除特别说明外，所有数值均来自自己同步的主实验聚合表、低信噪比分组表、受控 CUDA 前向延迟表以及配对统计检验表。本章不新增训练、不重建主表，也不把诊断性输出纳入性能结论。

4.1 主实验整体结果

表 4.1 汇总 9 个模型行在 3 个训练种子上的平均结果。该表同时列出整体准确率、宏平均 F1、均衡准确率、低/中/高信噪比分组准确率和参数量，用于从总体性能、信噪比分组和模型规模三个角度观察结果。

表 4.1 固定划分主实验结果（三训练种子均值与标准差）

模型行	输入视图	整体准确率	宏平均 F1	均衡准确率	低信噪比准确率	中信噪比准确率	高信噪比准确率	参数量
cnnid	I/Q ^[2]	0.581992 ± 0.004518	0.595238 ± 0.003937	0.581992 ± 0.004518	0.209508 ± 0.005465	0.795606 ± 0.001772	0.865025 ± 0.006640	37,131
resnet1d	I/Q ^[36]	0.595917 ± 0.000451	0.612207 ± 0.000668	0.595917 ± 0.000451	0.205871 ± 0.002523	0.819722 ± 0.004139	0.892172 ± 0.001495	111,755
tfccn_stft	STFT	0.506303 ± 0.001752	0.509340 ± 0.006411	0.506303 ± 0.001752	0.171307 ± 0.003870	0.689975 ± 0.005485	0.769293 ± 0.003574	24,123
fusion_iq_stft	I/Q+STFT	0.577098 ± 0.001712	0.584926 ± 0.003526	0.577098 ± 0.001712	0.221326 ± 0.006128	0.785808 ± 0.006158	0.842753 ± 0.005760	98,299
clldnn ^[24]	I/Q	0.612932 ± 0.000546	0.633238 ± 0.003378	0.612932 ± 0.000546	0.222386 ± 0.005230	0.839596 ± 0.002879	0.906995 ± 0.003416	241,675
mcldnn ^[19]	I/Q	0.250083 ± 0.275698	0.199852 ± 0.319911	0.250083 ± 0.275698	0.131307 ± 0.069971	0.318232 ± 0.393735	0.340303 ± 0.431963	406,199
lwmcnet ^[20]	I/Q	0.551091 ± 0.001838	0.557940 ± 0.008022	0.551091 ± 0.001838	0.202538 ± 0.008513	0.750960 ± 0.006679	0.815960 ± 0.003467	20,395
iq_param_matched	I/Q	0.594462 ± 0.000468	0.612415 ± 0.004565	0.594462 ± 0.000468	0.216345 ± 0.007061	0.812146 ± 0.007270	0.880934 ± 0.003472	136,395
gated_fusion_iq_stft	I/Q+STFT	0.571947 ± 0.002025	0.585340 ± 0.004474	0.571947 ± 0.002025	0.211307 ± 0.006707	0.784015 ± 0.004843	0.840732 ± 0.004582	134,780

在当前固定协议内，clldnn 的整体平均准确率为 0.612932，宏平均 F1 为 0.633238，是 9 个模型行中观察到的最高结果。主要 I/Q 基线中，resnet1d 的整体准确率为 0.595917，参数匹配控制模型 iq_param_matched 为 0.594462，二者与 CLDNN 的差距分别约为 1.70 和 1.85 个百分点。该结果说明本实验矩阵中的固定划分表现。

iq_param_matched 与 resnet1d 的整体准确率几乎相等，分别为 0.594462 和 0.595917，因此它的价值并不在于形成新的强基线排序，而在于作为融合解释的边际控制。它只使用 I/Q 输入，同时参数量接近双视图融合模型；当 fusion_iq_stft 相对它在低信噪比范围有小幅正差值、整体范围又为负差值时，这个对照能帮助区分“额外参数规模”与“新增 STFT 视图”带来的影响。

图 4.2 显示，静态 I/Q-STFT 融合在低信噪比区间接近 CLDNN，但在中高信噪比区间没有保持同等优势。门控融合曲线也未相对静态融合形成稳定改善。因此，主结果首先支持的是“不同信噪比区间存在性能权衡”，而不是“融合结构整体优于 I/Q 模型”。

图 4.3 从类别维度补充表 4.1。不同模型在 AM、PSK、QAM 和 WBFM 等类别上的表现并不均匀，说明整体准确率不能完全代表每一类调制方式的识别难度。低信噪比分析也应结合类别混淆结构解释。




图 4.1 图中术语对照：Overall= 整体，Low/Mid/High SNR= 低/中/高信噪比，Accuracy= 准确率。固定划分下 9 个模型行的整体、低信噪比、中信噪比和高信噪比准确率对比。证据源：main_table_metrics.csv。




图 4.2 图中术语对照：SNR= 信噪比，Accuracy= 准确率，Macro F1= 宏平均 F1。代表模型在完整信噪比轴上的准确率与宏平均 F1 曲线。证据源：三训练种子聚合的 metrics_per_snr.csv。




图 4.3 图中术语对照：Overall class accuracy by model= 各模型整体类别准确率，Accuracy= 准确率。9 个模型行在 11 类调制方式上的类别准确率热力图。证据源：三训练种子聚合的 metrics_per_class.csv。

4.2 整体性能的配对检验

表 4.2 给出 CLDNN 与两个主要 I/Q 参照模型的整体准确率配对检验。差值定义为前一个模型准确率减去后一个模型准确率。

表 4.2 CLDNN 与主要 I/Q 参照模型的整体准确率配对检验

比较	范围	准确率差值	95% 置信区间	McNemar 检验
cldnn vs. resnet1d	整体测试集	0.017015	[0.015318, 0.018697]	$p = 1.52 \times 10^{-87}$
cldnn vs. iq_param_matched	整体测试集	0.018470	[0.016788, 0.020159]	$p = 2.86 \times 10^{-104}$

两项比较的置信区间均未跨越 0，说明 CLDNN 相对 resnet1d 和 iq_param_matched 的整体优势在当前配对样本上得到统计支持。McNemar 检验提供同一样本正确性方向差异的补充证据。统计表覆盖已登记模型对；表外模型对留给后续完整检验。

多重比较方面，本文将统计包中的 6 对已登记模型比较作为比较族，并分别考察 overall 与低信噪比两个范围。Holm-Bonferroni 修正后^[37]，overall 范围内 6 对比较均仍达到显著；低信噪比范围内，fusion_iq_stft vs. cldnn 的差值置信区间跨 0 且 McNemar $p = 0.476423$ ，保持未显著，其余 5 对仍达到显著。该修正不改变主要解释：CLDNN 的整体优势稳定，静态融合相对 CLDNN 的低信噪比优势没有统计支持，门控




图 4.4 图中术语对照：Accuracy delta= 准确率差值，95% CI=95% 置信区间。已登记模型对的配对自助法准确率差值及 95% 置信区间。差值定义为前一模型准确率减去后一模型准确率。

融合相对静态融合为负结果。

4.3 低信噪比下的融合权衡

低信噪比区域定义为 $SNR \leq -6\text{dB}$ 。在这一范围内，cldnn 的平均准确率为 0.222386，fusion_iq_stft 为 0.221326，iq_param_matched 为 0.216345，gated_fusion_iq_stft 为 0.211307。静态融合接近 CLDNN，并高于参数匹配 I/Q 控制模型，但差异幅度较小。

4.3.1 低信噪比互补性图谱分析

图 4.6 是解释低信噪比融合权衡的核心证据。它不是把两个模型的平均准确率相减，而是统计同一测试样本上“模型 A 正确、模型 B 错误”和相反方向的分歧比例，因此可以观察互补性出现在哪些 SNR 点。若 STFT 视图提供稳定互补，静态融合相对 I/Q 参照模型应在低信噪比区间持续出现正向净分歧；实际结果更像局部互补与局部损失的混合图谱。

相对 iq_param_matched，静态融合在 -14 、 -12 、 -10dB 的净分歧分别约为 $+1.08$ 、 $+1.74$ 、 $+1.94$ 个百分点，说明 STFT 视图确实在部分低信噪比点补充了 I/Q 控制模型漏判的样本。但在 -8 和 -6dB ，净分歧转为 -0.80 和 -0.36 个百分点，表明这种补充没有覆盖整个低信噪比区间。相对 cldnn 时，静态融合在 -14 和 -10dB 有 $+1.35$




图 4.5 图中术语对照：SNR= 信噪比，Accuracy= 准确率。低信噪比区间内代表模型的逐信噪比准确率曲线。低信噪比范围为 $\text{SNR} \leq -6$ dB。


和 +1.24 个百分点的局部正向净分歧，却在 -8 和 -6 dB 出现 -1.77 和 -1.76 个百分点的反向分歧。这解释了为什么低信噪比总差值为 -0.001061 且置信区间跨 0：融合不是全局胜出，而是在不同 SNR 点上互相抵消。

门控融合的分歧图进一步强化负结果判断。相对静态融合，门控融合在 -16 到 -6 dB 多数点为负向净分歧，其中 -10 dB 约为 -2.50 个百分点，-12 dB 约为 -1.65 个百分点。这说明当前标量门控没有学到“低信噪比时增加 STFT、较高信噪比时回退 I/Q”的有效策略，反而在静态融合已有局部收益的位置损失了样本。

相对于 CLDNN，静态 I/Q-STFT 融合的低信噪比准确率差值为 -0.001061，95% 置信区间为 $[-0.003939, 0.001838]$ ，区间跨越 0；McNemar 检验 $p = 0.476423$ 。这组证据支持“接近但未优于 CLDNN”的解释。


相对于参数匹配 I/Q 控制模型，静态融合的低信噪比准确率差值为 0.004981，95% 置信区间为 $[0.001970, 0.007973]$ ，McNemar 检验 $p = 0.001063$ 。但同一比较在整体测试集上的准确率差值为 -0.017364，95% 置信区间为 $[-0.019288, -0.015470]$ 。因此，合理结论是：STFT 视图在本实现中提供了低信噪比局部小幅补充，但这一补充伴随整体准确率损失。

图 4.7 进一步说明，静态融合的低信噪比差异并非对所有调制类别同向。相对 `iq_param_matched`，静态融合在 QAM16 上减少 7.4 个百分点召回率，却在 QAM64 上增



Data source: predictions_test.csv in predictions_archive_20260508; positive bars favor the first model in each panel.

图 4.6 图中术语对照: Share= 样本占比, correct only= 仅该模型正确, SNR= 信噪比。关键模型对在各信噪比点上的配对正确性分歧。正向柱表示前一模型正确而后一模型错误的样本更多, 负向柱表示相反方向更多。



Data source: confusion_low_snr.csv aggregated across seeds 42, 2025, and 3407.

图 4.7 图中术语对照: Recall delta= 召回率差值, Fusion - IQ matched= 融合减参数匹配 I/Q, Fusion - CLDNN= 融合减 CLDNN。静态 I/Q-STFT 融合在低信噪比范围内相对参数匹配 I/Q 控制模型和 CLDNN 的类别召回率差值。

表 4.3 低信噪比关键比较与配对检验摘要

比较	低信噪比准确率	准确率差值与 95% 置信区间	McNemar 检验	解释边界
CLDNN vs. 参数匹配 I/Q	22.24% 21.63%	vs. +0.006042 [0.003125, 0.008883]	$p = 3.88 \times 10^{-5}$	当前配对检验支持 CLDNN 方向。
静态融合 vs. CLDNN	22.13% 22.24%	vs. -0.001061 [-0.003939, 0.001838]	$p = 0.476$	置信区间跨 0，不能声称静态融合优于 CLDNN。
静态融合 vs. 参数匹配 I/Q	22.13% 21.63%	vs. +0.004981 [0.001970, 0.007973]	$p = 0.00106$	当前配对检验支持静态融合方向。
门控融合 vs. 静态融合	21.13% 22.13%	vs. -0.010019 [-0.012746, -0.007292]	$p = 1.23 \times 10^{-12}$	当前配对检验支持静态融合方向。

加 8.9 个百分点召回率，接近等幅、方向相反。一个合理解释是，QAM16 与 QAM64 在低信噪比下星座点云重叠较强，STFT 幅度视图强调局部频谱能量后，分类器的 QAM 判别边界整体向 QAM64 一侧偏移：更多 QAM64 被保留下来，但部分 QAM16 被吸收到相邻区域。因此，该图更支持“类别间召回率交换”而非“所有类别共同受益”。附录图 A.2 给出代表模型在低信噪比范围内的行归一化混淆矩阵，作为类别混淆解释的补充。

4.4 门控融合负结果

`gated_fusion_iq_stft` 的整体准确率为 0.571947，低信噪比准确率为 0.211307，均低于静态融合 `fusion_iq_stft`。配对检验也支持这一判断：门控融合相对静态融合的整体准确率差值为 -0.005152，95% 置信区间为 $[-0.006841, -0.003462]$ ，McNemar 检验 $p = 2.43 \times 10^{-9}$ ；低信噪比范围内的差值为 -0.010019，95% 置信区间为 $[-0.012746, -0.007292]$ ，McNemar 检验 $p = 1.23 \times 10^{-12}$ 。

由于差值定义为“门控融合减静态融合”，上述负值说明当前标量门控机制没有改善静态融合。本文因此将门控融合作为负结果保留，不写作“门控提升鲁棒性”或“门控融合优于静态融合”。

4.5 复杂度与受控 CUDA 前向延迟

复杂度与延迟结果来自 CUDA 设备上的受控前向传播测量。测量使用 50 次预热和 200 次计时迭代，批量大小为 1 和 256；表 4.4 摘录与结果解释最相关的模型行。

这些数值说明同一受控测量条件下不同模型的数量和 CUDA 前向耗时背景。例

表 4.4 模型参数量与受控 CUDA 前向延迟摘录

模型行	参数量	批量 1 延迟/ms	批量 256 延迟/ms	测量边界
resnet1d	111,755	2.081249	2.098535	仅 CUDA 前向传播。
iq_param_matched	136,395	1.250068	1.273155	仅 CUDA 前向传播。
cldnn	241,675	1.306352	1.543833	仅 CUDA 前向传播。
fusion_iq_stft	98,299	1.844381	1.857622	STFT 预处理未计入。
gated_fusion_iq_stft	134,780	2.535083	2.545334	STFT 预处理未计入。




图 4.8 图中术语对照：Overall accuracy= 整体准确率，Batch-1 latency= 批量 1 延迟，Params= 参数量。固定协议下整体准确率、受控 CUDA 批量 1 前向延迟与参数量的关系。STFT 预处理耗时未计入该图。

如，CLDNN 参数量较高但前向延迟并非最高；门控融合参数量低于 CLDNN，却具有更高的受控前向延迟。CPU 延迟、FLOPs/MACs 和 STFT 预处理完整耗时需要独立测量协议支撑。

4.6 MCLDNN 异常与负结果保留


mclDnn 的整体准确率为 0.250083 ± 0.275698 ，宏平均 F1 为 0.199852 ± 0.319911 ，标准差显著高于其他模型行。三个训练种子中，seed 42 的测试准确率为 0.568432，而

seed 2025 和 seed 3407 的测试准确率均为 0.090909，宏平均 F1 均为 0.015152，表现为近似随机水平的单类预测。

表 4.5 MCLDNN 异常训练种子的测试集预测分布

训练种子	主要预测类别	预测样本数	现象判断
2025	8PSK（类别 0）	44,000 / 44,000	单类塌陷
3407	AM-DSB（类别 1）	44,000 / 44,000	单类塌陷

表 4.5 进一步确认，seed 2025 并不是“多数类别偏置”，而是全部测试样本均预测为 8PSK；seed 3407 则全部预测为 AM-DSB。该现象与一个 11 类均衡测试集上的 0.090909 准确率一致，属于单类塌陷而非普通方差波动。



Data source: seed-level metrics_test.json for seeds 42, 2025, and 3407; dashed line is baseline (1/11).

图 4.9 图中术语对照：Overall accuracy= 整体准确率，Low-SNR accuracy= 低信噪比准确率。9 个模型行在三个训练种子上的整体准确率与低信噪比准确率稳定性。

本文保留这两个异常种子，因为它们属于已登记的固定协议运行。删除异常种子并重算主表会改变实验协议，也会掩盖训练稳定性问题。协议纪律要求主表保留 3 个训练种子的完整结果；研究责任则要求对失败形态给出可检验解释，避免把异常简单归为“随机坏运气”。

当前可提出三类诊断假设。第一，学习率与权重衰减组合可能不适合 MCLDNN：全模型统一使用学习率 10^{-3} 、权重衰减 10^{-4} 、batch size 256，有利于协议对齐，但对多分支卷积、融合卷积和 LSTM 串联的结构未必公平。第二，初始化敏感性可能更强：seed

42 正常收敛而 seed 2025/3407 塌陷，提示某些初始门控、卷积核或循环层状态可能把梯度引向退化分类头。第三，输入格式或维度排列可能与该实现的结构假设不完全匹配：MCLDNN 常依赖对 I/Q 分支、时间维和通道维的特定组织方式，若实现中的 reshape、permute 或分支拼接与预期不一致，模型可能在部分初始化下无法形成有效类别边界。

因此，沿用统一超参对 MCLDNN 公平性不足。统一学习率、权重衰减和 batch size 的优点是避免为单个模型做事后调参，保证主表比较纪律；缺点是把结构稳定性、优化敏感性和超参适配能力混在一起。更负责的后续诊断应预先登记 MCLDNN 专用学习率网格、初始化重复、梯度范数监控、输入张量形状单元测试和早期 logits 分布检查，并在新的输出目录中形成独立证据。附录图 A.4 单独展示 MCLDNN 三个训练种子的差异。

4.7 扩展实验与提案模型

本节扩展实验在 RTX 3090 上完成，与 Stage 5A 的 RTX 4070 硬件不同；跨硬件的样本级配对统计检验因此不可直接执行，三种子均值层面的解释仍受支持。所有扩展实验仅在本节用作协议化解释证据，不修改主表数值与统计检验。

4.7.1 扩展实验摘要

四类敏感性 / 诊断扩展实验（延长预算、低信噪比加权交叉熵、扩展复杂度、低信噪比混淆后处理）的发现汇总于表 4.6；详细每 cell 数据见同名独立证据标签的报告文档。

三条要点支撑后续提案模型解释。其一，延长预算不改写主表排序，也不缓解低信噪比退化，**Stage 5A 主表不是欠训练造成**。其二，分组 SNR 加权 CE 是不合算干预，单凭损失加权无法同时改善低信噪比与整体性能。其三，深低信噪比 (≤ -16 dB) 退化为偏置预测 AM-SSB 是信息论级失败下限，**没有信息量可供模型“更努力地学习”**；任何架构改动都不能改写这一下限。fusion_iq_stft MACs 仅为 2.0 M (**少于 ** resnet1d 的 4.9 M) 这一事实，把“静态融合输给 CLDNN”的瓶颈定位到 I/Q 分支表征容量不足，为提案模型的架构升级提供动机。

4.7.2 文献校准与可比 SOTA

表 4.8 列出可比文献的报告值，区分 avg-all-SNR (-20 至 $+18$ dB 共 20 点平均，与本文 overall_accuracy 同口径)、avg SNR > 0 ($+2$ 至 $+18$ dB 共 9 点平均) 与 peak (单 SNR 最佳点) 三种口径，避免标题党的“95%+”或“92%”单点结果与本文 overall_accuracy 错配。

表 4.6 四类扩展实验摘要。Δ 列均为相对 Stage 5A 同模型的整体准确率均值变化。

证据标签	模型范围 / 干预	Δ overall	主要发现
EXTENDED_BUDGET_3090	4 模型 × 3 seed; epoch 50 + 5 轮 warmup + cosine annealing	±1 pp 内	排除欠训练假设; 最佳轮 15–42, 未触上限。
LOW_SNR_WEIGHTED_CE_3090	2 模型 × 3 seed; 分组 SNR 加权 CE (low= 2.0, mid= 1.0, high= 0.7)	cldnn −2.3, fusion −0.7	低 SNR 微涨 +0.4–0.6 pp, 但中高 SNR 跌 2–4 pp; 不合算干预。
CONTROLLED_LATENCY_EXTENDED	9 模型; CPU 单线程前向延迟 + thop MACs, warmup 50/measured 200	—	见表 4.7; fusion_iq_stft MACs (2.0 M) 少于 resnet1d (4.9 M)。
Stage 5A predictions 后处理	9 模型 × 3 seed; 行归一化低信噪比混淆矩阵	—	8 稳定模型在 SNR ≤ −6 dB 共同退化为偏置预测 AM-SSB (数字调制 → AM-SSB 比例 0.63–0.81); 构成信息论级下限。

表 4.7 扩展复杂度 (thop MACs) 与单线程 CPU 前向延迟

模型行	参数量	MACs (单样本)	CPU bs=1 / ms	CPU bs=256 / ms
tfcnn_stft	24,123	424,704	0.363	21.992
cnn1d	37,131	1,553,920	0.411	61.285
lwamcnet	20,395	1,504,096	2.327	52.871
fusion_iq_stft	98,299	2,015,488	0.834	83.240
gated_fusion_iq_stft	134,780	2,051,712	0.996	52.292
iq_param_matched	136,395	4,945,408	0.688	74.088
resnet1d	111,755	4,929,024	0.891	90.929
cldnn	241,675	8,668,544	1.055	182.586
mclldnn	406,199	49,097,472	2.994	572.462

表 4.8 近期文献在 RadioML2016.10A 上的可比性能校准。“avg-all-SNR”是 −20 至 +18 dB 共 20 点平均, 与本文 overall_accuracy 同口径; “avg SNR > 0”是 9 点平均 (+2 至 +18 dB); “peak”是单 SNR 最佳点。原论文未给出对应口径数字时记 “—”。

方法 (来源)	avg-all-SNR	avg SNR > 0	peak	备注
LENet-M ^[38]	0.6463	—	—	轻量 CNN+ 循环; 2024 DSP
SigFormer ^[39]	0.6371	—	—	金字塔 Transformer; 2023 IEEE
ICRNNA ^[40]	0.6324	—	—	RNN+attention; 2024
CC-MSNet ^[41]	0.6286	—	—	复值多流; 2024 Sci Rep
MCLDNN ^[19]	—	0.9112	0.9227	原论文与 AMR-Benchmark ^[42]
LSTM2 ^[42]	—	—	0.9205	AMR-Benchmark
PET-CGDNN ^[16,42]	—	—	0.916	AMR-Benchmark
CLDNN2 ^[42]	—	—	0.908	AMR-Benchmark
本文 cldnn (Stage 5A)	0.6129	0.9044	0.9138	三种子均值, 本文
本文 fusion_iq_stft (Stage 5A)	0.5771	0.8402	0.8482	三种子均值, 本文
本文 fusion_cldnn_stft+aug+LS (提案)	0.6264	0.9237	0.9327	三种子均值, 本文, 第 4.7.3 节

跨论文比较受不同划分、不同测试集大小、不同种子和不同聚合口径影响，不构成严格 head-to-head 比较。本文以表 4.8 作为同量级参照：本文 CLDNN 0.6129 在 avg-across-SNR 维度上与 LENet-M 0.6463 和 SigFormer 0.6371 仍有 2–3 个百分点差距，提示固定协议下尚有 SOTA 级别可改进空间。

4.7.3 提案模型 fusion_cldnn_stft+ 增强 + 标签平滑

提案模型 fusion_cldnn_stft（第 3 章）在 P1.1 训练计划上叠加相位旋转加循环时移信号域增强（仅训练）与 $\epsilon = 0.1$ 标签平滑，登记为证据标签 FUSION_CLDNN_STFT_AUG_LS_3090。表 4.9 给出三种子均值与标准差，并与 Stage 5A 的 CLDNN、Stage 5A 的静态 fusion_iq_stft、以及同训练计划下的扩展预算 fusion_iq_stft 三类参照逐项对照。

表 4.9 提案模型与三类参照的同协议比较（三种子均值与标准差，单位：准确率）

模型行（参照 / 提案）	整体	低 SNR	中 SNR	高 SNR
fusion_iq_stft (Stage 5A)	0.5771	0.2213	0.7858	0.8428
fusion_iq_stft (EXTENDED_BUDGET_3090)	0.5851	0.2124	0.8025	0.8646
cldnn (Stage 5A, 最强稳定基线)	0.6129	0.2224	0.8396	0.9070
fusion_cldnn_stft+aug+LS (提案)	0.6264 $\pm$ 0.0005	0.2258 $\pm$ 0.0008	0.8606 $\pm$ 0.0009	0.9264 $\pm$ 0.0003
Δ 提案 vs. Stage 5A CLDNN	+0.0135	+0.0034	+0.0210	+0.0194
Δ 提案 vs. Stage 5A fusion_iq_stft	+0.0493	+0.0045	+0.0748	+0.0836
Δ 提案 vs. EXTENDED_BUDGET fusion_iq_stft	+0.0413	+0.0134	+0.0581	+0.0618

提案模型在四个指标（整体、低、中、高信噪比）上 ** 同时 ** 正向超过 Stage 5A 的 CLDNN 基线，整体准确率的相对增量 +1.35 个百分点显著大于三种子标准差 0.0005（约 27σ ），不属于种子噪声范围。提案模型的最佳轮在 31、42、31，全部位于 50 轮上限之内，证明该计划对提案模型已经收敛。图 4.10 给出提案模型与三个对照（Stage 5A CLDNN、Stage 5A fusion_iq_stft、P1.1 fusion_iq_stft 同 schedule）的逐 SNR 准确率曲线，可直观看到提案模型在中、高信噪比上一致领先，并在低信噪比仍略高于 Stage 5A CLDNN，但与所有对照在深低信噪比一同退化到 $\sim 1/11$ 的随机水平，与第 4.7.1 节的“塌陷为 AM-SSB”信息论下限一致。

与文献参照的对比（表 4.8）说明，提案模型在 avg-all-SNR 维度的 0.6264 落入 2024 年代多流 / 复值文献基线的同一量级（CC-MSNet 0.6286、CCTL-Net 0.6297），与 LENet-M（0.6463）、SigFormer（0.6371）仍有约 1–2 个百分点差距，记入未来工作；




图 4.10 图中术语对照：SNR= 信噪比，Test accuracy= 测试集准确率。提案模型 (粗实线，红) 与 Stage 5A CLDNN (实线，蓝)、Stage 5A fusion_iq_stft (虚线，灰)、P1.1 fusion_iq_stft 同 schedule (点线，橙) 的逐 SNR 准确率曲线。所有曲线均为三训练种子均值。灰色阴影区为低信噪比范围 (≤ -6 dB)，绿色阴影区为高信噪比范围 (≥ 8 dB)。

avg(SNR > 0) 维度的 0.9237 超过 MCLDNN 原论文报告的 0.9112，三种子 peak 均值 0.9327 与 MCLDNN 0.9227、LSTM2 0.9205、PET-CGDNN 0.916 等 AMR-Benchmark 报告 peak 比较，本文提案模型同口径上在该比较族中处于较高位置。需要强调的是，跨论文 peak 比较受不同划分、不同测试集大小和不同种子聚合口径影响，不构成严格 head-to-head 比较。

但本结果同时受到几条解释边界约束：第一，提案模型由架构升级、信号域增强与标签平滑三项干预联合构成，需要对三项干预做单干预消融才能拆分各自贡献；本报告在第 4.7.4 节给出该消融。第二，与 Stage 5A 的硬件不同，样本级配对自助法和 McNemar 检验无法跨硬件直接做，本表仅在三种子均值层面解释。第三，深低信噪比 (≤ -16 dB) 准确率仍约为 1/11 的随机水平，与本节前面的“崩塌为 AM-SSB”分析一致——提案模型不解决信息论级失败下限。这些边界与未来工作方向在第 5 章末尾说明。

4.7.4 提案模型单干预消融与配对统计检验

为隔离提案模型 +1.35 个百分点中各项干预 (CLDNN 风格 I/Q 编码器 / 信号域增强 / 标签平滑) 的贡献，本文额外登记证据标签 FUSION_CLDNN_STFT_ABLATION_3090 下的三个变体：arch_only (仅替换 backbone，关闭增强与标签平滑)、arch_aug (架构 + 增强) 与 arch_ls (架构 + 标签平滑)。三个变体共享与“full”相同的固定划分、

三训练种子、相同 RTX 3090 硬件与相同 epoch 50 cosine 加 warmup 的训练计划，仅在 `train.augmentation.enabled` 与 `train.loss.label_smoothing` 上区分。

表 4.10 提案模型 `fusion_cldnn_stft` 的单干预消融（三训练种子均值 $\pm$ 标准差）。变体 `arch_only` 关闭增强且 $\epsilon = 0$ ；`arch_aug` 仅开增强；`arch_ls` 仅开标签平滑；“full”行复用第 4.7.3 节的提案模型结果。所有变体使用相同 RTX 3090 硬件、相同固定划分、相同三训练种子。

变体	整体	低 SNR	中 SNR	高 SNR
<code>arch_only</code>	0.6116 $\pm$ 0.0022	0.2173 $\pm$ 0.0037	0.8399 $\pm$ 0.0018	0.9089 $\pm$ 0.0023
<code>arch_aug</code>	0.6284 $\pm$ 0.0011	0.2254 $\pm$ 0.0013	0.8669 $\pm$ 0.0021	0.9272 $\pm$ 0.0013
<code>arch_ls</code>	0.6108 $\pm$ 0.0010	0.2152 $\pm$ 0.0026	0.8435 $\pm$ 0.0004	0.9054 $\pm$ 0.0018
full (arch+aug+LS, 提案)	0.6264 $\pm$ 0.0004	0.2259 $\pm$ 0.0006	0.8606 $\pm$ 0.0007	0.9264 $\pm$ 0.0003

表 4.10 给出三个变体与“full”的同协议比较。“`arch_only`”行衡量纯架构升级（CLDNN 风格 I/Q 分支）相对原静态融合 `fusion_iq_stft` 的贡献；与“`arch_only`”相比，“`arch_aug`”、“`arch_ls`”与“full”各加入相应一项或两项额外干预，差值即为该项干预相对于纯架构基线的边际收益。

为获得样本级配对证据，本文以提案模型“full”为 m_a ，以三类参照（P1.1 `fusion_iq_stft` 同 schedule；三个消融变体）为 m_b ，分别在整体测试集与低信噪比子集上计算配对自助法准确率差值（10000 重采样、自助种子 42）以及 McNemar 配对正确性检验。所有比较在同 RTX 3090 硬件、同固定划分、同三训练种子上完成，因此样本级配对（按（`split_id`, `train_seed`, `sample_id`）配对键）可直接执行，跨硬件混淆问题被规避。

表 4.11 提案模型相对参照的配对统计检验。差值定义为“ $\text{Acc}(\text{model}_a) - \text{Acc}(\text{model}_b)$ ”；自助重采样 10000 次，种子 42；McNemar 使用连续性修正卡方近似（ $\text{df} = 1$ ）。

比较	范围	配对数	准确率差值	95% CI	是否跨 0	McNemar p
proposed vs. p11_fusion_iq_stft	整体	132,000	+0.0413	[+0.0395, +0.0432]	否	0.000e + 00
proposed vs. p11_fusion_iq_stft	低 SNR	52,800	+0.0134	[+0.0103, +0.0166]	否	9.669e - 17
proposed vs. ablation_arch_only	整体	132,000	+0.0149	[+0.0133, +0.0164]	否	6.247e - 78
proposed vs. ablation_arch_only	低 SNR	52,800	+0.0086	[+0.0056, +0.0115]	否	4.682e - 08
proposed vs. ablation_arch_aug	整体	132,000	-0.0019	[-0.0033, -0.0006]	否	1.553e - 02
proposed vs. ablation_arch_aug	低 SNR	52,800	+0.0005	[-0.0021, +0.0030]	是	9.406e - 01
proposed vs. ablation_arch_ls	整体	132,000	+0.0157	[+0.0141, +0.0172]	否	1.854e - 89
proposed vs. ablation_arch_ls	低 SNR	52,800	+0.0106	[+0.0078, +0.0134]	否	9.131e - 13

消融与配对检验给出三条具体证据，且明显细化了第 4.7.3 节的三干预解释。

第一，** 架构升级单独已经把 fusion 推到 CLDNN 量级，但单独不够 **。`arch_only` 整体均值 0.6116 与 Stage 5A CLDNN 的 0.6129 相差 -0.13 个百分点，处于种子噪声内；这说明把 I/Q 分支换成 CLDNN 风格 backbone 解决了“fusion 输给 CLDNN”的容量问题，但本身没有形成显著正向贡献。

第二，** 信号域增强是主要涨点来源 **。`arch_aug` 整体均值 0.6284 相对 `arch_only`

0.6116 提升 +1.68 个百分点；同期低、中、高 SNR 也一致正向（分别 +0.81、+2.70、+1.83 个百分点）。配对检验中 `proposed vs. ablation_arch_only` 整体差值 +0.0149 (95% CI [+0.0133, +0.0164], McNemar $p \approx 6 \times 10^{-78}$)；与之对照，`arch_aug` 已经覆盖了这一收益的绝大部分。这一证据明确把“提案模型反超 CLDNN”的主要原因归到训练侧的相位旋转加循环时移信号域增强^[28-29]，而不是架构升级本身。

第三，** 标签平滑在已有增强时可能冗余甚至略有害 **。`arch_ls` 整体均值 0.6108 几乎等于 `arch_only` 0.6116 (-0.08 个百分点，处于种子噪声内)；更重要的是，`proposed` 相对 `ablation_arch_aug` 的整体准确率差值为 -0.0019 (95% CI [-0.0033, -0.0006], McNemar $p = 0.0155$)，即在 `arch_aug` 之上再叠加 $\epsilon = 0.1$ 的标签平滑会让整体准确率显著下降约 0.19 个百分点；低 SNR 范围内则没有显著差异 (CI [-0.0021, +0.0030] 跨 0, McNemar $p = 0.94$)。

合并上述三条，提案模型 +1.35 个百分点的收益里，** 约 +1.55 pp 来自信号域增强、~ 0 pp 来自架构升级（仅把 fusion 拉到 CLDNN 量级以稳住基础）、-0.19 pp 来自标签平滑叠加 **。这意味着 `arch_aug` (0.6284) 作为 ** 更简单的提案配置 ** 实际上略优于本文报告的“full”配置 (0.6264)；该证据让我们对“标签平滑值得保留”持保守态度，并在第 5 章末尾的未来工作里把“取消标签平滑、改用更细的增强强度网格”列为优先实验项。本节因协议纪律仍以“full”配置作为登记的提案模型主结果，但同时显式给出该消融证据，避免对单干预贡献做事后猜测。

第五章 讨论、局限性与可复现性

5.1 固定协议下结果的含义

第 4 章结果表明, CLDNN 在本文固定协议中取得最高的整体准确率和宏平均 F1^[3,24], 并在已登记配对检验中优于 `resnet1d`^[36] 与 `iq_param_matched`。这一现象可以从结构上理解: CLDNN 先用卷积层提取局部时域模式, 再通过循环单元建模序列依赖^[25], 相比单纯一维卷积基线^[2]具有更强的时序表征能力。该优势属于协议内观察, 跨数据集和跨信道条件的稳定性需要新的验证。

固定划分的价值在于提高模型间比较的可比性。所有模型使用相同测试样本、相同训练种子集合和相同评价脚本, 因而结果差异更容易归因于当前模型实现与训练配置, 而不是测试集变化。其限制也同样明显: 单一固定划分之后还需要多划分重复实验, 并需要其他数据集或真实无线环境验证。

5.2 STFT 融合的低信噪比权衡

静态 I/Q-STFT 融合的结果说明, 多视图输入的价值具有条件性。相对参数匹配 I/Q 控制模型, 静态融合在低信噪比范围内有小幅正向差异; 相对 CLDNN, 该差异没有统计支持; 在整体测试集上, 静态融合又低于参数匹配 I/Q 控制模型。因此, 结论应写作“STFT 视图在低信噪比样本上可能提供局部补充信息”。

这种权衡具有合理机制解释。低信噪比下, 原始 I/Q 序列中的局部相位和幅度结构容易被噪声扰动, STFT 展开的局部频率能量分布可能提供另一种观察角度。但在中高信噪比样本上, I/Q 序列已经包含较清晰的时域判别线索, 额外的时频分支和融合分类器可能引入训练难度、特征冗余或视图不一致, 从而造成整体准确率下降。由此可见, 融合结构的关键问题不是“是否增加视图”, 而是如何在低信噪比收益与中高信噪比保持之间取得平衡。

5.3 融合失败原因诊断

保留“基于时频特征与深度神经网络融合”的题目时, 融合结果必须被解释为一次有边界的实证诊断, 而不是成功提升的叙事。第 4 章显示, 静态 I/Q-STFT 融合相对 CLDNN 的整体准确率差值为 -0.035833 , 95% 置信区间为 $[-0.037629, -0.034015]$; 相对参数匹配 I/Q 控制模型的整体准确率差值为 -0.017364 , 95% 置信区间为 $[-0.019288, -0.015470]$ 。这说明当前静态融合没有兑现整体性能优势, 门控融合也没有修复这一问题。

类别层面的异常更能说明融合失败的形态。图 4.7 中，静态融合相对参数匹配 I/Q 控制模型在低信噪比 QAM16 上的召回率差值为 -7.4 个百分点，而 QAM64 上的差值为 $+8.9$ 个百分点，二者接近等幅、方向相反。QAM16 与 QAM64 都属于正交幅度调制，低信噪比下星座点云更容易重叠；STFT 幅度视图强调局部频谱能量而弱化细粒度星座几何后，分类器可能把原先用于区分 QAM16/QAM64 的边界整体推向更偏 QAM64 的区域。这个解释与“融合获得普遍互补信息”相反：它提示新增视图改变了相邻 QAM 类别之间的判别边界，使某一类收益由另一类损失支付。

中高信噪比下的退化也支持“冗余视图”假设。相对 CLDNN，静态融合从 -4 dB 到 18 dB 的逐 SNR 净分歧均为负，约从 -3.24 到 -6.86 个百分点；相对参数匹配 I/Q 控制模型，同一区间也约为 -0.64 到 -4.12 个百分点。此时 I/Q 序列已经保留较清晰的相位轨迹和幅度结构，STFT 幅度图带来的额外频谱摘要可能主要复制已有信息，甚至压低相位敏感特征的权重。融合分类头在训练时同时适配两个相关视图，可能增加优化负担，并在高信噪比样本上把本来清晰的 I/Q 决策边界变钝。

一个可检验的改进方向是显式 SNR 条件门控：在现有 `gated_fusion_iq_stft` 门控输入中加入真实或估计的 SNR 分桶嵌入。预先登记的判据应包括：低信噪比范围内是否超过参数匹配 I/Q 控制模型、中高信噪比范围内是否缓解系统性净损失、QAM16/QAM64 的低信噪比召回率是否从“一降一升”变为更均衡的变化。该方案需新的完整实验，其有效性由后续证据判断。

5.4 复杂度与运行时证据限制

本文的复杂度讨论覆盖参数量、训练时间背景和受控 CUDA 前向延迟。该测量能帮助读者理解不同模型在相同硬件和相同计时设置下的前向耗时差异；完整部署成本还需要时频预处理、数据搬运、CPU 推理和端到端流水线时间。

因此，“更适合部署”“更高计算效率”或“硬件可迁移性能更好”需要系统级效率分析支撑。若未来开展该分析，应同时测量 CPU/GPU、不同批量大小、预处理耗时、内存峰值、吞吐率和端到端延迟，并将该协议与本报告的受控前向延迟区分开。

5.5 提案模型反超的解释边界

提案模型在同协议下整体准确率反超 Stage 5A CLDNN 1.35 个百分点，第 4.7.4 节的消融把这一收益拆分为：信号域增强约 $+1.55$ pp（主要来源）^[28-29]，架构升级把 fusion 拉到 CLDNN 量级，标签平滑在已有增强时反向贡献 -0.19 pp（McNemar $p = 0.0155$ ）。这意味着更简单的 `arch_aug` 配置（无标签平滑）实际略优于本文登记的“full”；本报告因协议纪律仍以“full”作为提案模型主结果，但应在未来实验中考虑取消标签平滑。三条解释边界限制其表述强度：跨硬件混淆（提案模型 RTX 3090，Stage 5A RTX 4070，

样本级配对检验只能在同硬件证据标签内做)；本文未在文献最一致涨点的两个方向(复值网络^[41]、Transformer 混合^[38-40])上同步检验，与 LENet-M (0.6463)、SigFormer (0.6371) 仍有 1–2 pp 差距；深低信噪比退化是信息论下限，提案模型未解决。

5.6 协议局限与后续处理

表 5.1 汇总本报告最影响结论解释的四类协议局限。它们不改变第 4 章已有数值，而是说明这些数值在后续研究中如何被进一步检验。

表 5.1 实验协议局限及后续处理方案。严重程度按对结论可信度影响排序，“高”= 改写解释、“中”= 收紧表述、“低”= 记入未来工作。

协议局限	严重程度	后续处理
扩展实验与提案模型使用的硬件 (RTX 3090) 与 Stage 5A 主实验 (RTX 4070) 不同，跨标签的样本级配对统计检验不可直接执行。	高	在新硬件上重跑 Stage 5A 主表 (或在原硬件上重跑提案模型)，生成同硬件下的预测档以支持样本级配对检验；当前报告中跨证据标签的比较仅在三种子均值层面进行。
提案模型由 CLDNN 风格 I/Q 编码器、信号域增强与标签平滑三项干预联合构成；本报告在第 4.7.4 节给出三个单干预消融变体，但仍未涵盖更细粒度 (如每项干预 $\times$ 不同 SNR 区间) 的因果隔离。	中	沿用提案模型协议，对增强强度、标签平滑系数与 LSTM 隐藏维做更细网格搜索；按预先登记表汇报。
单一固定划分提升了模型间配对比较的可比性，但外部效应仍取决于其他随机划分与真实信道条件。	中	采用多 split 重复实验，并报告跨 split 均值、方差和配对统计检验；在真实或半真实信道数据上复核主要排序。
每个模型 $n = 3$ 个训练种子，能够暴露 MCLDNN 不稳定性，但对方差和尾部失败概率的估计仍偏粗。	中	将主模型扩展到更多训练种子，预先登记失败判据，并用种子级分布而非单一均值描述稳定性。
9 个模型共用学习率 10^{-3} 、权重衰减 10^{-4} 、batch size 256，有利于统一协议，却会低估对超参更敏感结构的潜力。	中	设置“统一超参主表”和“模型内调参补充表”两层证据；调参空间、选择规则和验证集使用方式提前登记。
数据集只覆盖 RadioML2016.10A，跨数据集一致性未在本报告范围内验证。	低	列入未来工作但不计入本课程报告；如展开应使用相同模型身份、统计检验和证据标签独立报告。

5.7 可复现性与证据边界

本文可复现性主要来自三个层面：固定划分和三训练种子保证比较口径一致；测试集预测归档支持同一样本上的配对统计检验；聚合表、低信噪比分组表和受控延迟表使正文数值可追溯。表 5.2 用课程论文口径概括这些材料的用途，具体路径、环境和同步状态放在附录 A。

附录图 A.5 进一步说明证据标签与排除规则。本报告的证据边界为：主结论使用 Stage 5A/5B 固定协议、归档预测和已登记统计检验；诊断性或工程检查材料用于后续工作边界；当前本地材料支撑报告写作和统计解释，完整 27 个训练权重文件需另行独立同步和哈希核验。

表 5.2 课程报告使用的主要证据材料及边界

材料类型	主要作用	使用边界
聚合结果表	支撑主结果、低/中/高信噪比分组和复杂度背景。	对应 RadioML2016.10A 固定协议。
测试集预测归档	支撑配对自助法和 McNemar 检验。	覆盖 9 个模型行、3 个训练种子和已登记模型对。
受控延迟表	支撑参数量与 CUDA 前向延迟讨论。	对应 CUDA 前向传播测量口径。
环境与同步记录	说明本地写作环境、服务器实验环境和权重归档缺口。	不等同于本地完整训练权重归档。

第六章 总结

6.1 工作总结

本文围绕 RadioML2016.10A 自动调制识别任务，完成了一份证据边界清晰的课程实验报告。报告由两层证据构成。第一层是固定划分 `stratified_by_mod_snr_seed42` 下的 Stage 5A 主实验，共 9 个模型行 $\times$ 3 个训练种子 = 27 个运行单元，覆盖 I/Q 序列基线、STFT 时频分支、I/Q-STFT 静态融合、标量门控融合、卷积-循环混合模型、轻量模型和参数匹配 I/Q 控制模型；该层使用统一划分、统一评价指标和同一样本配对统计检验，主表数值与统计检验结果在本报告任何位置都不被覆盖。第二层是五个独立证据标签的扩展实验：训练预算延长（4 模型 $\times$ 3 种子）、低信噪比加权交叉熵（2 模型 $\times$ 3 种子）、扩展复杂度与单线程 CPU 延迟、低信噪比类别混淆后处理，以及一项联合架构升级、信号域增强与标签平滑的提案模型评估（1 模型 $\times$ 3 种子）；该层使用独立输出根目录与独立证据标签登记，仅作为协议化的敏感性、干预筛查和正面贡献材料，不进入主表。

在实验组织上，报告完整记录两层证据的训练计划、评价指标、统计检验、复杂度边界与硬件设置变更，使每一项数值都能追溯到固定的证据标签与运行目录。报告写作未在 Stage 5A/5B 主实验之上启动新训练，也未把诊断性材料合并到主表。

6.2 主要结论

第一，在 Stage 5A 固定协议内，CLDNN 取得最高的整体平均准确率 0.612932 和宏平均 F1 0.633238。相对 `resnet1d` 和 `iq_param_matched`，CLDNN 的整体准确率差异在已登记配对检验中得到统计支持。该结论仅限于本报告的数据集、固定划分、模型矩阵和训练种子集合。

第二，静态 I/Q-STFT 融合体现的是低信噪比局部权衡。它在低信噪比范围内相对参数匹配 I/Q 控制模型有小幅正向差异，但相对 CLDNN 的低信噪比优势没有统计支持，并且在整体测试集上存在准确率损失。因此，本报告不能把 Stage 5A 的静态融合表述为广义优越模型。

第三，标量门控融合在本文实现中没有改善静态融合。整体和低信噪比两个范围的配对检验均显示门控融合低于静态融合，因此该模型应作为负结果保留。

第四，MCLDNN 的两个异常训练种子被保留在主表中。该处理维护了固定协议完整性，也提示当前实现存在优化或初始化敏感性。本报告不删除异常种子，不重算清洗后结果。

第五，扩展实验为主表结论提供了多角度敏感性检验。延长训练预算未显著改变主表排序也未提升低信噪比，排除“主表是欠训练造成”的常见质疑；分组 SNR 加权交叉熵在低信噪比上小幅获益但中高信噪比代价更大；7 个稳定模型在深低信噪比共同退化为对 AM-SSB 的偏置预测，构成信息论级失败下限；扩展复杂度证据进一步显示静态融合的乘加运算量低于 resnet1d，提示融合输给 CLDNN 是 I/Q 分支表征容量问题而不是算力问题。

第六，提案模型 fusion_cldnn_stft 在同一固定划分与三训练种子下，叠加 CLDNN 风格 I/Q 编码器^[24-25]、相位旋转加循环时移信号域增强（仅训练）^[28-29]以及标签平滑 0.1^[30]三项干预，在四个 SNR 指标（整体、低、中、高）上同时反超 Stage 5A 的 CLDNN 基线，整体准确率均值 0.6264（相对 CLDNN 提升 1.35 个百分点，三种子标准差 0.0005）。第 4.7.4 节的单干预消融进一步把这一收益拆解为：信号域增强贡献约 +1.55 pp（主要来源），架构升级单独把 fusion 拉到 CLDNN 量级，标签平滑在已有增强时使整体准确率反下降约 0.19 pp（McNemar $p = 0.0155$ ），因此更简单的“arch+aug”配置反而略优于本文登记的“full”配置。提案模型与近期文献中复值多流^[41]和 Transformer 混合方法^[38-40]的报告值（CC-MSNet 0.6286、SigFormer 0.6371、LENet-M 0.6463）量级一致，并在 avg(SNR > 0) 维度上反超 MCLDNN 原论文报告值^[19]。该结论仅限于登记的证据标签 FUSION_CLDNN_STFT_AUG_LS_3090 与 FUSION_CLDNN_STFT_ABLATION_3090；因硬件变更而不应被外推为广义部署级声明。

6.3 不足与后续工作

本报告最主要的局限来自实验范围与协议混淆。主结果只覆盖 RadioML2016.10A 和单一固定划分，没有纳入 RadioML2018.01A、真实外场信道或多划分重复验证；扩展实验与提案模型与 Stage 5A 在硬件上不同（RTX 3090 对 RTX 4070），跨证据标签的样本级配对统计检验未做；提案模型由三项干预联合构成，未做单点消融；复杂度证据虽已补全 MACs/FLOPs 与单线程 CPU 延迟，仍不能等同于完整部署效率（CPU 多线程、ARM/移动/DSP、STFT 预处理完整成本均未独立测量）。

后续工作可以沿四条方向推进。其一，在新硬件上同步重跑 Stage 5A 主表或在原硬件上重跑提案模型，生成同硬件预测档，以支持跨证据标签的样本级配对检验。其二，分别登记“仅架构升级”、“仅信号域增强”、“仅标签平滑”的三个独立证据标签训练，分离提案模型 +1.35 个百分点中各干预的贡献。其三，沿文献中最一致涨点方向（复值网络如 CC-MSNet 系列、Transformer 混合如 SigFormer 系列）实现更强的 I/Q 编码器或注意力组件，目标对齐 LEnet-M 0.6463 / SigFormer 0.6371 区间。其四，在 RadioML2018.01A 子集上以相同模型身份、统计检验与证据标签复核 Stage 5A 排序与提案模型反超的可重复性。

参考文献

- [1] O'SHEA T J, WEST N. Radio Machine Learning Dataset Generation with GNU Radio[C/OL]//Proceedings of the GNU Radio Conference: vol. 1: 1. 2016. <https://pubs.gnuradio.org/index.php/grcon/article/view/11>.
- [2] O'SHEA T J, CORGAN J, CLANCY T C. Convolutional Radio Modulation Recognition Networks[G/OL]//Engineering Applications of Neural Networks. Cham: Springer International Publishing, 2016: 213-226. DOI: 10.1007/978-3-319-44188-7_16.
- [3] WEST N E, O'SHEA T J. Deep Architectures for Modulation Recognition[C/OL]//2017 IEEE International Symposium on Dynamic Spectrum Access Networks (DySPAN). 2017: 1-6. DOI: 10.1109/DySPAN.2017.7920754.
- [4] AZZOUZ E E, NANDI A K. Automatic Modulation Recognition of Communication Signals[M]. Boston: Kluwer Academic Publishers, 1996.
- [5] SWAMI A, SADLER B M. Hierarchical Digital Modulation Classification Using Cumulants[J/OL]. IEEE Transactions on Communications, 2000, 48(3): 416-429. DOI: 10.1109/26.837045.
- [6] DOBRE O A, ABDI A, BAR-NESS Y, et al. Survey of Automatic Modulation Classification Techniques: Classical Approaches and New Trends[J/OL]. IET Communications, 2007, 1(2): 137-156. DOI: 10.1049/iet-com:20050176.
- [7] HAMEED F, DOBRE O A, POPESCU D C. On the Likelihood-Based Approach to Modulation Classification[J/OL]. IEEE Transactions on Wireless Communications, 2009, 8(12): 5884-5892. DOI: 10.1109/TWC.2009.12.080883.
- [8] OPPENHEIM A V, SCHAFER R W. Discrete-Time Signal Processing[M]. 3rd ed. Pearson, 2010.
- [9] ALLEN J B. Short Term Spectral Analysis, Synthesis, and Modification by Discrete Fourier Transform[J/OL]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1977, 25(3): 235-238. DOI: 10.1109/TASSP.1977.1162950.
- [10] GRIFFIN D W, LIM J S. Signal Estimation from Modified Short-Time Fourier Transform[J/OL]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1984, 32(2): 236-243. DOI: 10.1109/TASSP.1984.1164317.
- [11] COHEN L. Time-Frequency Analysis[M]. Prentice Hall, 1995.

- [12] BOASHASH B. Time-Frequency Signal Analysis and Processing: A Comprehensive Reference[M]. 2nd ed. Academic Press, 2015.
- [13] RAJENDRAN S, MEERT W, GIUSTINIANO D, et al. Deep Learning Models for Wireless Signal Classification With Distributed Low-Cost Spectrum Sensors[J/OL]. IEEE Transactions on Cognitive Communications and Networking, 2018, 4(3): 433-445. DOI: 10.1109/TCCN.2018.2835460.
- [14] ZENG Y, ZHANG M, HAN F, et al. Spectrum Analysis and Convolutional Neural Network for Automatic Modulation Recognition[J/OL]. IEEE Wireless Communications Letters, 2019, 8(3): 929-932. DOI: 10.1109/LWC.2019.2900247.
- [15] HUYNH-THE T, HUA C H, PHAM Q V, et al. MCNet: An Efficient CNN Architecture for Robust Automatic Modulation Classification[J/OL]. IEEE Communications Letters, 2020, 24(4): 811-815. DOI: 10.1109/LCOMM.2020.2968030.
- [16] ZHANG F, LUO C, XU J, et al. An Efficient Deep Learning Model for Automatic Modulation Recognition Based on Parameter Estimation and Transformation [J/OL]. IEEE Communications Letters, 2021, 25(10): 3287-3290. DOI: 10.1109/LCOMM.2021.3102656.
- [17] ZHANG J, WANG T, FENG Z, et al. AMC-Net: An Effective Network for Automatic Modulation Classification[C/OL]//2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2023: 1-5. DOI: 10.1109/ICASSP49357.2023.10097070.
- [18] HUYNH-THE T, HUA C, TU N A, et al. Automatic Modulation Classification: A Deep Architecture Survey[J/OL]. IEEE Access, 2021, 9: 142950-142971. DOI: 10.1109/ACCESS.2021.3120419.
- [19] XU J, LUO C, PARR G, et al. A Spatiotemporal Multi-Channel Learning Framework for Automatic Modulation Recognition[J/OL]. IEEE Wireless Communications Letters, 2020, 9(10): 1629-1632. DOI: 10.1109/LWC.2020.2999453.
- [20] WANG Y, LIU M, YANG J, et al. A Lightweight CNN Architecture for Automatic Modulation Classification[J/OL]. IEEE Communications Letters, 2021, 25(6): 1850-1854. DOI: 10.1109/LCOMM.2021.3060835.
- [21] EFRON B. Bootstrap Methods: Another Look at the Jackknife[J/OL]. The Annals of Statistics, 1979, 7(1): 1-26. DOI: 10.1214/aos/1176344552.
- [22] MCNEMAR Q. Note on the Sampling Error of the Difference Between Correlated Proportions or Percentages[J/OL]. Psychometrika, 1947, 12(2): 153-157. DOI: 10.1007/BF02295996.

- [23] DEMŠAR J. Statistical Comparisons of Classifiers over Multiple Data Sets[J/OL]. Journal of Machine Learning Research, 2006, 7: 1-30. <https://www.jmlr.org/papers/v7/demsar06a.html>.
- [24] SAINATH T N, VINYALS O, SENIOR A, et al. Convolutional, Long Short-Term Memory, Fully Connected Deep Neural Networks[C/OL]//2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2015: 4580-4584. DOI: 10.1109/ICASSP.2015.7178838.
- [25] HOCHREITER S, SCHMIDHUBER J. Long Short-Term Memory[J/OL]. Neural Computation, 1997, 9(8): 1735-1780. DOI: 10.1162/neco.1997.9.8.1735.
- [26] IOFFE S, SZEGEDY C. Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift[C]//International Conference on Machine Learning (ICML). 2015: 448-456.
- [27] SRIVASTAVA N, HINTON G, KRIZHEVSKY A, et al. Dropout: A Simple Way to Prevent Neural Networks from Overfitting[C]//: vol. 15. 2014: 1929-1958.
- [28] HUANG L, PAN W, ZHANG Y, et al. Data Augmentation for Deep Learning-Based Radio Modulation Classification[J/OL]. IEEE Access, 2020, 8: 1498-1506. DOI: 10.1109/ACCESS.2019.2960775.
- [29] SHORTEN C, KHOSHGOFTAAR T M. A survey on Image Data Augmentation for Deep Learning[J/OL]. Journal of Big Data, 2019, 6: 60. DOI: 10.1186/s40537-019-0197-0.
- [30] SZEGEDY C, VANHOUCKE V, IOFFE S, et al. Rethinking the Inception Architecture for Computer Vision[C/OL]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 2818-2826. DOI: 10.1109/CVPR.2016.308.
- [31] PASZKE A, GROSS S, MASSA F, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[J]. Advances in Neural Information Processing Systems, 2019, 32: 8024-8035.
- [32] LOSHCHILOV I, HUTTER F. Decoupled Weight Decay Regularization[C]//International Conference on Learning Representations (ICLR). 2019.
- [33] KINGMA D P, BA J. Adam: A Method for Stochastic Optimization[C]//International Conference on Learning Representations (ICLR). 2015.
- [34] KROGH A, HERTZ J A. A Simple Weight Decay Can Improve Generalization[C]//Advances in Neural Information Processing Systems: vol. 4. 1992: 950-957.

- [35] LOSHCHILOV I, HUTTER F. SGDR: Stochastic Gradient Descent with Warm Restarts[C]//International Conference on Learning Representations (ICLR). 2017.
- [36] HE K, ZHANG X, REN S, et al. Deep Residual Learning for Image Recognition [C/OL]//IEEE Conference on Computer Vision and Pattern Recognition (CVPR). 2016: 770-778. DOI: 10.1109/CVPR.2016.90.
- [37] HOLM S. A Simple Sequentially Rejective Multiple Test Procedure[J/OL]. Scandinavian Journal of Statistics, 1979, 6(2):65-70. <https://www.jstor.org/stable/4615733>.
- [38] LIU Y, LIU H, CHEN W, et al. A lightweight cross-scale feature fusion enhanced multi-level recurrent convolutional neural network for automatic modulation recognition[J/OL]. Digital Signal Processing, 2024. DOI: 10.1016/j.dsp.2024.104896.
- [39] CAO H, ZHAO Y, WANG H, et al. Robust and Efficient Modulation Recognition with Pyramid Signal Transformer[J]. IEEE Conference on Signal Processing and Information Networks, 2023.
- [40] LI M, ZHANG W, LIU W, et al. Improved automatic modulation recognition using deep learning with additive attention[J/OL]. Heliyon, 2025. DOI: 10.1016/j.heliyon.2025.e44520.
- [41] WANG Y, BAI J, CHEN J, et al. A complex-valued convolutional fusion-type multi-stream spatiotemporal network for automatic modulation classification[J/OL]. Scientific Reports, 2024, 14: 22506. DOI: 10.1038/s41598-024-73547-w.
- [42] ZHANG F, LUO C, XU J, et al. AMR-Benchmark: A Unified Implementation of Several Baseline Deep Learning Models for Automatic Modulation Recognition[Z]. GitHub repository: <https://github.com/Richardzhangxx/AMR-Benchmark>. Implements CNN1, CNN2, MCNET, IC-AMCNET, ResNet, DenseNet, GRU, LSTM, DAE, MCLDNN, CLDNN, CLDNN2, CGDNet, PET-CGDNN on RML2016.10a/10b/2018.01a/HisarMod2019.1. 2022.

附录 A 证据包、环境与补充图表

A.1 证据包与环境摘要

表 A.1 将原附录 A.1–A.6 的证据包路径、同步状态、环境差异和排除规则压缩为课程报告可核查的摘要。主结果来自 Stage 5A/5B 固定协议聚合表、低信噪比分组表、受控 CUDA 前向延迟表和 27 个测试集预测文件；统计检验包基于这些归档预测生成。Stage 6B smoke/diagnostic 材料保留为工程追踪记录，正文性能结论使用 Stage 5A/5B 主证据。

表 A.1 证据包、环境与使用规则压缩摘要

项目	摘要
主实验证据包	<code>paper_package/server_sync_20260508</code> ; 包含主表、低信噪比分组表、复杂度/延迟表和 Stage 5B audit 材料。
预测归档	<code>paper_package/predictions_archive_20260508</code> ; 27 个 <code>predictions_test.csv</code> , 覆盖 9 个模型行和 3 个训练种子。
统计检验包	<code>paper_package/statistical_tests_20260508</code> ; 包含配对自助法、McNemar 检验、显著性 JSON 和清单。
证据标签	PROJECT_SUPPORTED 支撑主结果; CONTROLLED_LATENCY 支撑 CUDA 前向延迟; SMOKE TEST/DIAGNOSTIC 用于工程追踪。
环境差异	本地 Windows/Python 3.13.7/PyTorch 2.11.0+cpu 用于写作与核查; 服务器 Linux/Python 3.11.12/PyTorch 2.9.1+cu128/RTX 4070 用于 GPU 实验。
剩余缺口	本地材料包含预测和聚合证据; 完整 27 个 Stage 5A <code>best_model.pt</code> 权重需要另行独立同步与哈希核验。

A.2 补充超参、训练曲线与混淆矩阵

表 A.2 汇总主实验共用训练设置。该表用于解释第 4 章 MCLDNN 异常诊断中的“统一超参”含义。

表 A.2 主实验训练与特征超参摘要

项目	设置
数据划分	<code>stratified_by_mod_snr_seed42</code> ; 训练/验证/测试为 154,000 / 22,000 / 44,000。
训练种子	42, 2025, 3407。
最大轮数与早停	最大 30 轮; 早停 <code>patience</code> 为 8。
优化器核心设置	学习率 10^{-3} , 权重衰减 10^{-4} , <code>batch size</code> 256。
STFT 设置	窗口长度 32, 重叠长度 16; 受控延迟表未计入完整 STFT 预处理。
低信噪比定义	$\text{SNR} \leq -6 \text{ dB}$; 每个训练种子测试集中 17,600 个低信噪比样本。





图 A.1 图中术语对照: Training/Validation= 训练/验证, Loss= 损失, Accuracy= 准确率。代表模型训练曲线补充; MCLDNN seed 2025 对应第 4 章单类塌陷案例。


Low-SNR normalized confusion matrices (aggregated across seeds)



Data source: confusion_low_snr.csv for seeds 42, 2025, and 3407.


图 A.2 图中术语对照: True= 真实类别, Predicted= 预测类别, Normalized count= 归一化比例。代表模型在低信噪比范围内的行归一化混淆矩阵, 三训练种子聚合。证据源: confusion_low_snr.csv。

Overall normalized confusion matrices (aggregated across seeds)



Data source: confusion_overall.csv for seeds 42, 2025, and 3407.

图 A.3 图中术语对照: True= 真实类别, Predicted= 预测类别, Normalized count= 归一化比例。代表模型在整体测试集上的行归一化混淆矩阵, 三训练种子聚合。证据源: confusion_overall.csv。



Data source: mclldnn/seed_*/metrics_test.json. Seeds 2025 and 3407 are retained negative evidence.

图 A.4 图中术语对照：Accuracy= 准确率，Macro F1= 宏平均 F1。MCLDNN 在三个训练种子上的整体准确率与宏平均 F1。证据源：MCLDNN 各种子测试指标；seed 2025 与 seed 3407 作为负结果保留。




图 A.5 图中术语对照：PROJECT_SUPPORTED= 完整固定协议主实验证据，CONTROLLED_LATENCY= 受控延迟证据，SMOKE/DIAGNOSTIC= 工程检查或诊断材料。本文证据标签与排除规则示意图。证据源：证据边界文档、证据包清单和环境审计记录。

附录 B 完整训练超参表

为便于复现，表 B.1 把本报告所有训练运行的超参按证据标签汇总成一张主表。所有运行共享同一固定划分 `stratified_by_mod_snr_seed42`（按 modulation $\times$ snr 联合分层；切分种子 42；训练/验证/测试 70/10/20%）与同一三训练种子集合 42, 2025, 3407。脚本与配置路径见正文章节引用。

表 B.1 按证据标签汇总的训练超参（所有标签共用固定划分与三训练种子集合）

证据标签	GPU	epoch	batch	lr	调度器	损失	增强	模型范围
PROJECT_SUPPORTED (Stage 5A)	4070	30	256	10^{-3}	恒定	CE	无	9 个主表模型
EXTENDED_BUDGET_3090	3090	50	256	10^{-3}	cosine + 5w	CE	无	cnn1d / resnet1d / iq_param_matched / fusion_iq_stft cldnn / fu- sion_iq_stft fusion_cldnn_stft fusion_cldnn_stft $\times 3$ 变体
LOW_SNR_WEIGHTED_CE_3090	3090	50	256	10^{-3}	cosine + 5w	SnrW (2/1/0.7)	无	—
FUSION_CLDNN_STFT_AUG_LS_3090	3090	50	256	10^{-3}	cosine + 5w	CE $\epsilon = 0.1$	rot+shift	fusion_cldnn_stft
FUSION_CLDNN_STFT_ABLATION_3090	3090	50	256	10^{-3}	cosine + 5w	见变体	见变体	fusion_cldnn_stft $\times 3$ 变体
arch_only 变体						CE	无	—
arch_aug 变体						CE	rot+shift	—
arch_ls 变体						CE $\epsilon = 0.1$	无	—
CONTROLLED_LATENCY_EXTENDED	EPYC CPU	—	1/256	—	—	—	—	9 个模型, 仅前 向 (warmup 50/measured 200, 单线程)

共用项：优化器 AdamW ($\beta_1=0.9$, $\beta_2=0.999$, $\epsilon=10^{-8}$, 权重衰减 10^{-4})；早停耐心值 Stage 5A=8、Stage 6 扩展 =15，依据均为验证集准确率；划分 NPZ 路径 `data/splits/rml2016a/stratified_by_mod_snr_seed42.npz`。增强 “rot+shift” 表示相位旋转 $\theta \sim \mathcal{U}(-\pi, \pi)$ prob 0.5 + 循环时移 $k \sim \mathcal{U}(-8, +8)$ prob 0.5，仅 train loader 启用。损失 “SnrW (2/1/0.7)” 表示分组 SNR 加权 CE，权重 low= 2.0、mid= 1.0、high= 0.7，SNR 边界 $\text{low} \leq -6$ dB / $\text{mid} \in [-4, 6]$ dB / $\text{high} \geq 8$ dB。配置文件分别为 `configs/paper/rml2016a_main_table_full_template.yaml`、`rml2016a_extended_budget_3090.yaml`、`rml2016a_low_snr_weighted_ce_3090.yaml`、`rml2016a_fusion_cldnn_stft_aug_ls_3090.yaml`、`rml2016a_fusion_cldnn_stft_ablation_3090.yaml`。