

中国传媒大学作业报告

基于时频特征与深度神经网络融合的无
线电调制识别方法研究

机器学习课程作业报告

姓名：待填写

学号：待填写

日期：2026 年 5 月

摘 要

无线电自动调制识别旨在根据接收信号判别调制类别,低信噪比条件下的可靠识别仍具有挑战。本文以 RadioML2016.10A 为实验对象,在固定划分 stratified_by_mod_snr_seed42 下比较 9 个模型行与 3 个训练种子,覆盖 I/Q 序列模型、STFT 时频分支、I/Q-STFT 静态融合、门控融合、CLDNN/MCLDNN/LWAMCNet 以及参数匹配 I/Q 控制模型。实验报告 overall、low/mid/high SNR accuracy、macro-F1 和 balanced accuracy,并基于 archived predictions 采用 paired bootstrap 与 McNemar 检验。结果表明,在当前固定协议下,CLDNN 是 strongest observed model;静态 I/Q-STFT 融合体现 low-SNR trade-off,而不是广义融合改进;门控融合未改善静态融合,应作为负结果保留;MCLDNN 的 seed 2025 与 seed 3407 chance-level collapse 继续纳入主表。上述发现仅限于 RadioML2016.10A 固定划分与三种子实验矩阵;latency 仅支持受控 CUDA forward latency,不外推 CPU、FLOPs/MACs、STFT 预处理完整延迟或部署效率。

关键词: 自动调制识别; RadioML2016.10A; 时频特征; 深度神经网络; 低信噪比; 统计检验

目录

摘 要	I
第一章 绪论	1
1.1 研究背景	1
1.2 问题定义	2
1.3 本文工作	2
1.4 贡献与边界	3
1.5 全文结构	4
第二章 数据集、实验协议与评价指标	5
2.1 数据集与任务定义	5
2.2 固定划分与训练种子	5
2.3 模型矩阵与输入视图	6
2.4 评价指标与信噪比分组	6
2.5 配对统计检验协议	7
2.6 复杂度与延迟测量范围	7
2.7 证据标签与排除规则	8
第三章 模型方法与融合结构	11
3.1 总体模型矩阵	11
3.2 I/Q 序列基础模型	12
3.3 时序模型与轻量模型	12
3.4 STFT 时频分支	13
3.5 参数匹配 I/Q 控制模型	13
3.6 静态 I/Q-STFT 融合	14
3.7 门控 I/Q-STFT 融合	14
3.8 方法边界	15
第四章 实验结果与统计检验	16
4.1 主实验结果	16

4.2	配对统计检验结果	18
4.3	低信噪比下的融合权衡	19
4.4	门控融合结果	21
4.5	复杂度与受控 CUDA 延迟	22
4.6	MCLDNN 异常与负结果保留	22
第五章	讨论、局限性与可复现性	25
5.1	固定协议下结果的解释	25
5.2	低信噪比融合权衡	25
5.3	门控融合负结果的意义	26
5.4	复杂度与延迟证据的边界	26
5.5	MCLDNN 异常与负结果保留	27
5.6	可复现性与 artifact 边界	27
第六章	总结	29
6.1	工作总结	29
6.2	主要发现	29
6.3	不足与后续工作	30
参考文献		31
附录 A	证据包与实验环境	32
A.1	主实验证据包	32
A.2	预测归档与统计检验	32
A.3	证据标签	32
A.4	本地与服务器环境	33
A.5	同步状态与剩余缺口	33
A.6	排除规则	34
A.7	补充图表清单与诊断性可视化	34

第一章 绪论

1.1 研究背景

无线电自动调制识别 (Automatic Modulation Classification, AMC) 旨在根据接收信号自动判别其调制方式, 是频谱感知、通信监测、认知无线电和非合作通信分析中的基础问题之一。在实际无线环境中, 接收信号会受到噪声、信道变化和采样扰动等因素影响, 尤其在低信噪比条件下, 不同调制类别之间的可分性会显著下降, 模型容易同时面临时域结构弱化和频域局部特征不稳定的问题。因此, 如何在固定、可复现的实验协议下比较不同特征视图和深度模型结构, 是自动调制识别实验报告中需要明确回答的问题。

传统 AMC 方法通常依赖人工设计的统计特征或高阶特征, 而深度神经网络可以直接从原始 I/Q 序列或派生时频表示中学习判别性表征。I/Q 序列保留了基带信号的同相与正交分量, 适合刻画时域相位和幅度变化; STFT 等时频视图则显式呈现局部频率结构, 为低信噪比下的互补信息分析提供了一个自然入口。不过, 引入额外视图并不必然带来整体性能收益, 融合结构是否有效仍需要在受控协议、参数控制和统计检验下判断。

为使报告中的图表安排与 AMC 论文常见呈现方式一致, 本文在已有项目文献综述基础上补充梳理了 20 篇开放论文或开放全文论文的图表类型。表 1.1 显示, 结构图、accuracy-vs-SNR 曲线、消融或结果对比表、混淆矩阵以及复杂度/延迟表是该方向中反复出现的表达方式。因此, 本文后续图表并非装饰性补充, 而是围绕固定协议、模型矩阵、低信噪比行为、统计检验和复杂度边界组织证据。

表 1.1 开放 AMC 论文中的常见图表模式与本文图表设计对应关系

文献线索	结构图	SNR 曲线	混淆矩阵	消融	复杂度	对本文图表设计的作用
O'Shea 2016	Y	Y	-	-	-	RadioML/CNN baseline and SNR curves
Deep architectures 2017	Y	Y	Y	Y	Y	Baseline families and experiment tables
Polar features 2018	Y	Y	-	-	Y	Alternative I/Q-derived views
Fast DL AMC 2019	Y	Y	-	-	Y	Efficiency-aware reporting
SCRNN 2019	Y	Y	-	-	Y	CNN/RNN model comparison
Data augmentation 2019	-	Y	-	Y	Y	Ablation and robustness framing
Constellation CNN 2020	Y	Y	Y	-	-	Non-I/Q visual representation
Complex CNN 2020	Y	Y	-	-	Y	Complex-valued model framing
Multi-scale networks 2021	Y	Y	-	Y	Y	Multi-scale architecture figure

文献线索	结构图	SNR 曲线	混淆矩阵	消融	复杂度	对本文图表设计的作用
Involution ResNet 2021	Y	Y	-	-	Y	Residual baseline variant
Time-frequency attention 2021	Y	Y	-	Y	Y	Time-frequency attention evidence
Adaptive fusion 2022	Y	Y	-	Y	Y	Fusion architecture and ablation
Ultra Lite CNN 2022	Y	Y	-	Y	Y	Lightweight complexity table
SE-MSFN 2022	Y	Y	-	Y	Y	Attention/multi-scale result curves
Harper 2023	Y	Y	Y	Y	Y	Systematic benchmark style
AMC-Net 2023	Y	Y	-	Y	Y	Dedicated AMC network comparison
MAMCA 2024	Y	Y	-	Y	Y	Accuracy/efficiency trade-off
UQ-AMC 2025	Y	Y	-	-	Y	Reliability and uncertainty framing
G-AMC 2026	Y	Y	-	Y	Y	Green/lightweight framing
HFECNET-CA/IDAF	Y	Y	Y	Y	Y	Open-access module and figure exemplars

1.2 问题定义

本文研究基于 RadioML2016.10A 的调制分类问题。给定一个无线电信号样本，其输入可以表示为原始 I/Q 序列，也可以通过预处理得到 STFT 时频视图；模型输出为调制类别标签。本文不研究信噪比估计、信道识别或端到端部署系统优化，而是围绕固定数据划分下的分类性能、低信噪比分组表现和统计检验组织实验。

为减少数据划分随机性对模型比较的干扰，本文主实验仅在固定划分 `stratified_by_mod_snr_split` 下解释。后文所有主结果均限定在 RadioML2016.10A、该固定 split、9 个模型行和 3 个训练种子 42, 2025, 3407 的协议内。若不满足这一协议边界，例如换用其他数据集、其他 split、Stage 6B smoke/diagnostic 输出或未来候选结构，均不能直接纳入本文主结果。

1.3 本文工作

本文完成了一个课程报告范围内的 fixed-split AMC benchmark。实验矩阵包含 9 个模型行与 3 个训练种子，共 27 个主实验单元。模型类别覆盖原始 I/Q baseline、STFT 单分支、I/Q-STFT 静态融合、门控融合、CLDNN/MCLDNN/LWAMCNet 时序或轻量结构，以及用于控制参数规模解释偏差的 `iq_param_matched` 模型。

在评价层面，本文报告 overall accuracy、low/mid/high SNR accuracy、macro-F1 与 balanced accuracy，并针对已登记的模型对使用 paired bootstrap 和 McNemar 检验。统计检验基于 archived predictions 的同一样本配对，而不是重新训练模型或重写 Stage 5A/5B 主表。复杂度和延迟讨论仅使用 CONTROLLED_LATENCY 证据，即受控 CUDA forward latency，不扩展为 CPU、FLOPs/MACs 或 STFT preprocessing-inclusive latency

结论。

本文还保留 MCLDNN seed 2025 与 seed 3407 的 chance-level collapse 结果。该处理体现了固定协议下的负结果保留原则：实验报告应忠实记录已登记运行的完整结果，而不是通过删除失败种子来获得更整齐的汇总值。相关异常解释、统计检验和可复现性边界将在后续章节展开。




图 1.1 本文主实验与统计检验证据链。Data source: Stage 5A/5B protocol documents, paper package manifests, predictions archive, and statistical-test package.

1.4 贡献与边界

本文的主要贡献可以概括为以下四点：

1. 构建了 RadioML2016.10A 上 fixed-split、多训练种子、可追踪 artifact 的 AMC benchmark，覆盖 9 个主实验模型行和 27 个运行单元。
2. 在参数匹配控制和低信噪比分组下分析 I/Q-STFT 静态融合的 low-SNR trade-off，避免将局部现象写成广义融合优越性。
3. 基于 archived predictions 进行 paired bootstrap 与 McNemar 检验，使主要比较建立在 split、seed 和 sample 级别的配对样本上。
4. 记录受控 CUDA forward latency 的证据范围，并保留 MCLDNN failed seeds 作为协议内负结果，强化结果解释的透明度。

上述贡献具有明确边界。本文不包含 RadioML2018.01A 实验，不进行跨数据集泛化判断；不声称 fusion 或 gated fusion 在一般 AMC 场景中优于单视图模型；不基于当前 latency 表作部署效率结论；Stage 6B smoke/diagnostic 输出只可作为工程或后续诊断边界说明，不属于本文主结果。

1.5 全文结构

第 2 章介绍数据集、固定划分、训练种子、模型矩阵、评价指标和统计检验协议。第 3 章说明各模型家族、输入视图、静态融合与门控融合结构，并明确方法描述不预设结果优劣。第 4 章给出固定协议下的主实验结果、低信噪比分析、配对统计检验、受控 CUDA latency 以及 MCLDNN 异常保留。第 5 章讨论结果解释边界、融合权衡、门控负结果、复杂度证据限制和 artifact 可复现性。第 6 章对全文工作、主要发现和后续工作边界进行总结。

第二章 数据集、实验协议与评价指标

2.1 数据集与任务定义

本文研究对象为无线电自动调制识别 (Automatic Modulation Classification, AMC) 任务, 即在给定接收信号观测的条件下, 将样本判别为相应的调制类别。本实验的主结果仅使用 RadioML2016.10A 数据集, 并将所有实验结论限定在该数据集、固定划分与既定模型矩阵内解释。数据集相关引用将在最终报告定稿阶段补充。

从输入形态看, 本报告关注两类互补视图: 一类是原始 I/Q 序列视图, 用于保留无线电基带信号的时域结构; 另一类是由信号变换得到的时频特征视图, 用于刻画频域局部结构。分类目标始终为调制类别, 而非信噪比估计、信道识别或部署时延预测。主表中的 `input_views` 字段记录每个模型实际使用的输入视图, 相关证据来自 `paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/main_table_metrics.csv` 与 Stage 5B 审计文档 `paper_package/server_sync_20260508/docs/paper/PAPER_STAGE5B_RESULT_AUDIT_AND_TABLES.md`。

需要强调的是, 本报告中的“主结果”均指 Stage 5A/5B 已审计的 RadioML2016.10A 固定协议证据。本文不将其他数据集、工程 smoke 输出或后续诊断候选纳入主结果, 也不据此提出跨数据集泛化结论。

2.2 固定划分与训练种子

为降低模型比较中由数据划分随机性带来的混杂, 本实验采用固定划分 `stratified_by_mod_snr`。Stage 5B 审计确认, 完成的主实验均以该划分作为 artifact-level protocol component, 而不是为每个模型或随机种子重新生成划分。该设计使不同模型行在同一划分口径下比较, 便于后续进行成对统计检验。证据来源为 `docs/paper/manuscript/section4_experimental_protocol.md`、`paper_package/server_sync_20260508/docs/paper/PAPER_STAGE5B_RESULT_AUDIT_AND_TABLES.md` 以及 `paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/main_table_metrics.csv`。

主实验矩阵由 9 个模型行与 3 个训练随机种子组成, 共计 $9 \times 3 = 27$ 个完整运行单元。训练种子固定为 42, 2025, 3407。Stage 5B 审计记录显示, 27 个计划单元均已完成, 并且每个运行的配置、指标与训练摘要均包含预期的 `split_id` 和 `train_seed` 元数据。因此, 本报告后续结果表中的均值与标准差均应理解为在这三个训练种子上的协议内汇总。

MCLDNN 行保留同一三种子协议。审计文档记录, `mclldnn` 的 seed 2025 与 seed 3407 出现 chance-level single-class prediction 行为, 但相关运行通过了划分、标签、schema

与 artifact 检查。基于实验协议守恒原则，本报告不删除这两个种子、不重算清洗后的 MCLDNN 汇总值，也不以未来诊断候选替换 Stage 5A/5B 中已经登记的 MCLDNN 证据。

2.3 模型矩阵与输入视图

本实验的模型矩阵包含九个模型行：cnn1d、resnet1d、tfcnn_stft、fusion_iq_stft、cldnn、mclnn、lwamcnet、iq_param_matched 和 gated_fusion_iq_stft。这些模型共同构成课程报告中的比较对象，覆盖 I/Q 基线、时频输入、时序模型、轻量化模型、参数匹配控制以及静态或门控的多视图融合方案。模型矩阵来自 Stage 5B 审计与 main_table_metrics.csv 的 model_id、input_views 字段。

表 2.1 主实验模型矩阵与输入视图

模型标识	输入视图	角色	协议解释边界
cnn1d	I/Q	时域卷积基线	用于 I/Q-only 基线比较。
resnet1d	I/Q	残差卷积基线	用于 I/Q-only 深层卷积参考。
tfcnn_stft	STFT	时频单视图模型	用于单独评估时频视图。
fusion_iq_stft	I/Q+STFT	静态融合模型	作为待评估多视图方案，不预设优越性。
cldnn	I/Q	时序模型	用于时域卷积与序列建模参考。
mclnn	I/Q	时序模型	保留三种子协议，包括异常种子。
lwamcnet	I/Q	轻量化模型	用于轻量结构参考。
iq_param_matched	I/Q	参数匹配控制	用于控制融合模型额外参数带来的解释偏差。
gated_fusion_iq_stft	I/Q+STFT	门控融合模型	作为待评估门控方案，不预设鲁棒性或广义优越性。

从输入视图划分看，cnn1d、resnet1d、cldnn、mclnn、lwamcnet 与 iq_param_matched 属于 I/Q-only 模型；tfcnn_stft 属于 STFT-only 模型；fusion_iq_stft 与 gated_fusion_iq_stft 属于 I/Q+STFT 模型。本文将 fusion 与 gated fusion 视为需要由实验检验的候选结构，而不是在协议定义阶段预先假定其优于 I/Q-only 模型。

2.4 评价指标与信噪比分组

本实验的主表评价指标包括 overall accuracy、low-SNR accuracy、mid-SNR accuracy、high-SNR accuracy、macro-F1 与 balanced accuracy。整体准确率用于度量固定测试划分上的总体分类正确率；macro-F1 对各调制类别的 F1 分数作宏平均，因而更关

注类别维度的均衡表现；balanced accuracy 对类别级召回进行均衡汇总，可作为整体准确率之外的补充指标。上述指标字段来自 `main_table_metrics.csv`，其汇总值以三个训练种子的均值和标准差呈现。

信噪比分组用于刻画不同信道难度下的模型行为。根据 Stage 5A/5B 聚合协议，low-SNR 子集定义为 `snr_db <= -6`，并在 `low_snr_table.csv` 中单独记录。该表同时给出每个低信噪比子集在单个训练种子下的样本数，以及不同 SNR 点上的准确率和 macro-F1 字段。mid-SNR 与 high-SNR 指标由 Stage 5B 聚合表按协议字段给出。本章只定义指标和分组口径，不在此提前给出模型优劣结论。

2.5 配对统计检验协议

除聚合指标外，本报告使用 paired bootstrap 与 McNemar 检验作为后续结果解释的统计工具。两类检验均基于 Stage 5A archived `predictions_test.csv` 文件生成，而不是重新运行模型推理或重写 Stage 5A/5B 主表。统计检验证据位于 `paper_package/statistical_tests_20260508/`，其生成说明见 `paper_package/statistical_tests_20260508/statistical_tests_summary.md` 与 predictions archive manifest docs/`paper/ARTIFACT_MANIFEST_PREDICTIONS_ARCHIVE_20260508.csv`。

成对比较的匹配键为 `split_id`、`train_seed` 与 `sample_id`。该匹配方式保证两个模型在同一固定划分、同一训练种子分组和同一测试样本上比较，避免将样本集合差异误计为模型差异。paired bootstrap 估计 accuracy delta:

$$\Delta_{\text{acc}} = \text{Acc}(m_a) - \text{Acc}(m_b), \quad (2.1)$$

其中 m_a 与 m_b 为成对比较的两个模型。统计检验 artifacts 记录 bootstrap resamples 为 10000，bootstrap seed 为 42。报告后续如引用置信区间，必须直接来自 `paired_bootstrap_accuracy_deltas.csv`，不得在正文中重新计算或扩展到未登记的比较。

McNemar 检验基于两个模型在同一样本上的正确/错误配对结果。设 b 表示模型 m_a 正确而 m_b 错误的样本数， c 表示模型 m_a 错误而 m_b 正确的样本数，则 McNemar 检验关注两个方向的 discordant counts 是否存在系统差异。当前统计检验的作用范围为 overall 与 low-SNR 两个 scope；任何 Stage 6B smoke、diagnostic 或未来候选输出均不得进入这些 paired statistical artifacts。

2.6 复杂度与延迟测量范围

复杂度与延迟证据来自 `paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/complexity_latency_table.csv`。该表的证据标签为 CONTROLLED_

LATENCY，表示其可用于受控 CUDA forward latency 范围内的运行时讨论。Stage 5B 审计确认，延迟测量使用 CUDA 设备，warm-up iterations 为 50，measured iterations 为 200，并在 batch size 1 与 batch size 256 两种设置下记录 forward-pass 相关字段。

该证据范围具有明确限制。首先，本报告不使用该表推断 CPU latency，因为当前证据包没有支持 CPU 延迟比较的完整测量。其次，虽然表中保留了 MACs/FLOPs 相关字段，但这些字段在当前聚合证据中并不完整，因此不得据此提出 FLOPs/MACs 效率结论。再次，STFT 预处理耗时与端到端推理耗时没有形成充分的 preprocessing-inclusive latency 证据，因此本报告不得把受控 CUDA forward latency 扩展为部署优越性或硬件可迁移效率结论。

2.7 证据标签与排除规则

为防止主实验、受控测量和工程诊断相互混淆，本报告采用 evidence label 管理证据使用范围。相关定义来自 docs/paper/course_report/REPORT_EVIDENCE_MAP.md、docs/paper/EXPERIMENT_ENVIRONMENT_AND_SYNC_STATUS_20260508.md、Stage 6A 计划 docs/paper/PAPER_STAGE6A_OPTIMIZATION_LITERATURE_AND_EXPERIMENT_PLAN.md 与 Stage 6B 协议 docs/paper/PAPER_STAGE6B_SCREENING_PROTOCOL_AND_CANDIDATE_QUEUE.md。

表 2.2 证据标签及其报告使用范围

证据标签	含义	本报告使用范围
PROJECT_SUPPORTED	Stage 5A/5B 完整固定协议证据	可用于主结果表、low-SNR 表、模型矩阵与统计检验解释。
CONTROLLED_LATENCY	受控 CUDA forward latency 测量	仅用于限定范围内的参数量与 CUDA forward latency 讨论。
SMOKE TEST	mock 或 synthetic code-path 检查	只能用于工程路径说明，不得作为性能证据。
DIAGNOSTIC	mock、subset 或调试筛查	只能用于未来诊断边界说明，不得进入主表或统计检验。

表 2.3 进一步列出本文新增图表与证据源之间的对应关系。凡是涉及模型性能、低信噪比表现或配对统计检验的图表，均只使用 PROJECT_SUPPORTED 主实验材料；复杂度相关图表仅使用 CONTROLLED_LATENCY 范围内的 CUDA forward latency 证据。

表 2.3 模型与图表证据源映射表

图号	文件	主要数据源	证据标签	使用位置
Fig. 1	fig01_protocol_pipeline.tex	Protocol docs, manifest, statistical package	PROJECT_SUPPORTED	正文
Fig. 2	fig02_model_taxonomy.tex	main_table_metrics.csv; code registry	PROJECT_SUPPORTED	正文
Fig. 3	fig03_fusion_architecture.tex	src/radioml_amc/models	PROJECT_SUPPORTED	正文
Fig. 4	fig04_accuracy_by_snr_group.pdf	main_table_metrics.csv	PROJECT_SUPPORTED	正文
Fig. 5	fig05_low_snr_per_snr_curve.pdf	low_snr_table.csv	PROJECT_SUPPORTED	正文
Fig. 6	fig06_bootstrap_delta_forest.pdf	paired_bootstrap_accuracy_deltas.csv	PROJECT_SUPPORTED	正文
Fig. 7	fig07_accuracy_latency_params_bubble.pdf	main_table_metrics.csv; complexity_latency_table.csv	CONTROLLED_LATENCY	正文
Fig. 8	fig08_low_snr_confusion_panels.pdf	confusion_low_snr.csv	PROJECT_SUPPORTED	附录
Fig. 9	fig09_mclnn_seed_anomaly.pdf	mclnn/seed_*/metrics_test.json	PROJECT_SUPPORTED	附录
Fig. 10	fig10_evidence_boundary.tex	REPORT_EVIDENCE_MAP.md; environment audit	Mixed labels	附录
Fig. 11	fig11_full_snr_accuracy_macro_f1.pdf	metrics_per_snr.csv	PROJECT_SUPPORTED	正文
Fig. 12	fig12_model_class_accuracy_heatmap.pdf	metrics_per_class.csv	PROJECT_SUPPORTED	正文
Fig. 13	fig13_low_snr_class_recall_delta.pdf	confusion_low_snr.csv	PROJECT_SUPPORTED	正文
Fig. 14	fig14_paired_disagreement_by_snr.pdf	predictions_test.csv	PROJECT_SUPPORTED	正文
Fig. 15	fig15_seed_stability_all_models.pdf	metrics_test.json	PROJECT_SUPPORTED	正文
Fig. 16	fig16_overall_confusion_panels.pdf	confusion_overall.csv	PROJECT_SUPPORTED	附录

Stage 6B smoke 或 diagnostic 输出不得进入 Stage 5A/5B 主表、low-SNR 表、paired bootstrap、McNemar 检验、摘要结论或总结结论。若后续存在新的诊断候选，其输出也必须使用单独模型标识、单独输出目录和明确 evidence label；除非另有完整协议授权，否则不能替代、修复或重写当前 Stage 5A/5B evidence。

本地同步状态也限定了报告写作方式。当前本地已有 paper package、27 个 Stage

5A prediction archive 文件和统计检验 artifacts，足以支撑课程报告的主结果写作与统计解释；但完整 27 个 Stage 5A `best_model.pt` 权重尚未同步到本地 package 或本地 Stage 5A 结果树。因此，本报告可以基于已归档预测与聚合表撰写实验结果，但不能宣称本地包已经构成完整训练权重归档。

第三章 模型方法与融合结构

3.1 总体模型矩阵

第 2 章已经给出本实验的数据集、固定划分、训练种子与评价协议。本章在该协议边界内说明模型方法与融合结构，重点回答“哪些模型被纳入比较、各模型使用何种输入视图、各结构在实验矩阵中的作用是什么”。本章不讨论模型排名、显著性或结果解释；相关内容留待第 4 章基于主表与统计检验证据展开。

本实验的主模型矩阵包含 9 个模型行：`cnn1d`、`resnet1d`、`tfcnn_stft`、`fusion_iq_stft`、`cldnn`、`mcldnn`、`lwamcnet`、`iq_param_matched` 与 `gated_fusion_iq_stft`。这些模型行来自 Stage 5A/5B 固定协议证据，模型身份与输入视图由 `paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/main_table_metrics.csv` 中的 `model_id` 和 `input_views` 字段记录；代码实现和注册关系主要对应 `src/radioml_amc/models/` 与 `src/radioml_amc/training/trainer.py`。

表 3.1 模型家族、输入视图与方法角色

模型家族	模型行	输入视图	方法角色
基础一维卷积	<code>cnn1d</code>	I/Q	原始 I/Q 序列卷积基线。
残差卷积	<code>resnet1d</code>	I/Q	引入残差连接的一维卷积对照。
时频分支	<code>tfcnn_stft</code>	STFT	使用时频图的单视图分支。
时序模型	<code>cldnn</code> , <code>mcldnn</code>	I/Q	结合卷积特征与序列建模的 I/Q 模型。
轻量模型	<code>lwamcnet</code>	I/Q	轻量化卷积结构对照。
参数匹配控制	<code>iq_param_matched</code>	I/Q	控制参数规模的 I/Q-only 对照。
静态融合	<code>fusion_iq_stft</code>	I/Q+STFT	连接 I/Q 与 STFT 分支特征的多视图候选。
门控融合	<code>gated_fusion_iq_stft</code>	I/Q+STFT	使用标量门控调节两个视图贡献的多视图候选。

从方法设计角度看，上述矩阵并不预设任何结构必然优于其他结构。I/Q-only 模型用于提供原始时域信号基线；STFT-only 模型用于评估时频视图本身；I/Q+STFT 模型用于检验多视图融合在固定协议下的行为；参数匹配控制用于降低“参数量增加”对融合解释的混杂。上述边界与 `docs/paper/manuscript/section4_experimental_protocol.md` 和 `docs/paper/course_report/REPORT_EVIDENCE_MAP.md` 中的证据约束一致。




图 3.1 主实验模型行的输入视图与方法角色分类。Data source: main_table_metrics.csv and Stage 5A/5B model registry.

3.2 I/Q 序列基础模型

I/Q 序列基础模型直接以形状为 $[B, 2, L]$ 的基带信号张量作为输入，其中两个通道分别对应同相分量与正交分量。该类模型不显式构造时频图，也不引入额外视图，因此适合作为检验其他结构是否带来额外信息的基础参照。相关实现见 `src/radioml_amc/models/cnn1d.py`、`src/radioml_amc/models/resnet1d.py` 以及模型构造函数 `src/radioml_amc/training/trainer.py`。

`cnn1d` 采用顺序一维卷积、批归一化、ReLU 激活、池化和全局池化，将 I/Q 序列映射为固定长度表征后进行调制类别分类。其作用是提供一个结构直接、可解释的时域卷积基线。设输入为 $x_{IQ} \in \mathbb{R}^{2 \times L}$ ，该类模型可抽象表示为

$$h_{IQ} = f_{1DConv}(x_{IQ}), \quad \hat{y} = c(h_{IQ}), \quad (3.1)$$

其中 f_{1DConv} 表示一维卷积特征提取器， $c(\cdot)$ 表示分类头。

`resnet1d` 同样使用 I/Q 输入，但在卷积堆叠中加入残差连接。残差块将卷积分支与 shortcut 分支相加后再经过非线性激活，目的在于提供与普通一维卷积不同的深层时域建模结构。本文只将其作为协议内 I/Q baseline 之一，不在本章讨论其结果表现。

3.3 时序模型与轻量模型

时序模型用于在卷积局部特征之上引入序列建模机制。本文纳入 `cldnn` 与 `mclnnc` 两个 I/Q-only 时序模型，它们均在 `src/radioml_amc/models/baselines.py` 中实现，并在 `src/radioml_amc/models/__init__.py` 与 `src/radioml_amc/training/trainer.py` 中注册为可训练模型。相关模型来源引用将在最终报告定稿阶段补充。

`cldnn` 使用一维卷积网络提取 I/Q 局部模式，再将卷积输出转置为时间序列形式

输入 LSTM，最后使用全连接分类头输出调制类别 logits。其方法抽象为

$$u_t = f_{\text{conv}}(x_{\text{IQ}})_t, \quad h = f_{\text{LSTM}}(u_1, \dots, u_T), \quad \hat{y} = c(h). \quad (3.2)$$

该模型在本报告中作为卷积-序列混合结构对照存在，本章不对其结果作排序性描述。

`mclldnn` 也是协议内 I/Q 模型。源码中该模型包含联合 I/Q 空间卷积分支、独立 I/Q 因果卷积分支、后续融合卷积、LSTM 与多层分类器。该结构的纳入目的在于覆盖 MCLDNN-style 的多分支时序建模思路。根据第 2 章协议，`mclldnn` 的三个训练种子均保留在 Stage 5A/5B 证据内；本章只说明其结构角色，异常细节和解释边界留待第 4 章与第 5 章讨论。

`lwamcnet` 作为轻量模型纳入比较。其实现使用二维卷积起始层、depthwise separable convolution residual stack、grouped depthwise convolution reconstruction 与线性分类头，目标是在 I/Q 输入上提供较低参数量的结构参照。本文不在方法章节中将“轻量”直接等同于效率或部署优势；复杂度与延迟范围仍以第 2 章定义的受控证据为准。

3.4 STFT 时频分支

除原始 I/Q 序列外，本文还纳入 STFT 视图对应的 `tfCNN_stft` 模型。该模型由 `src/radioml_amc/models/multiview.py` 中的 `TimeFrequencyCNN` 实现，使用 `TimeFrequencyBranch2` 对二维时频输入进行卷积、归一化、激活、池化和自适应池化，再接线性分类层输出调制类别。

从方法动机看，STFT 视图提供了与时域 I/Q 序列不同的观测方式。I/Q 序列强调时间采样点上的相位与幅度关系，而 STFT 视图将局部频率结构显式展开，有助于在方法层面检验时频表征能否提供互补信息。设 STFT 输入为 x_{STFT} ，单视图时频分支可写为

$$h_{\text{STFT}} = f_{2\text{DConv}}(x_{\text{STFT}}), \quad \hat{y} = c(h_{\text{STFT}}). \quad (3.3)$$

该节仅描述 STFT 分支的输入与结构，不评价其相对有效性。

3.5 参数匹配 I/Q 控制模型

`iq_param_matched` 是本实验中的参数匹配 I/Q-only 控制模型，对应 `src/radioml_amc/models/baselines.py` 中的 `ParameterMatchedIQOnlyNet`。该模型仍只使用 I/Q 输入，但通过调整一维卷积通道数和分类头规模，使其参数预算接近融合模型的量级。其设置目的不是提出新的 AMC 架构，而是为融合解释提供控制条件。

引入该控制模型的理由在于，多视图融合模型通常会增加分支、投影或分类器参数。

如果只比较融合模型与较小的 I/Q baseline，可能难以区分性能变化来自额外输入视图，还是来自参数量增加。参数匹配控制模型将输入视图固定为 I/Q，从而为后续分析提供更清晰的对照。本文在本章只说明控制变量设计，不写其与其他模型的结果胜负。

3.6 静态 I/Q-STFT 融合

`fusion_iq_stft` 是本实验中的静态 I/Q-STFT 融合候选，由 `src/radioml_amc/models/multiview.py` 中的 `MultiViewFusionNet` 实现。该模型包含两个分支：I/Q 分支使用一维卷积提取 h_{IQ} ，STFT 分支使用二维卷积提取 h_{STFT} ；随后将两个分支的表示拼接并输入分类器。其基本形式可写为

$$h_{IQ} = f_{IQ}(x_{IQ}), \quad h_{STFT} = f_{STFT}(x_{STFT}), \quad (3.4)$$

$$z = [h_{IQ}, h_{STFT}], \quad \hat{y} = c(z). \quad (3.5)$$

该结构的研究作用是检验在同一固定协议下，显式引入时频视图后模型行为如何变化。本文将其称为待评估 fusion candidate，而不是预设其相对 I/Q-only 模型具有广义优越性。后续任何关于该模型的解释均必须回到第 2 章定义的固定划分、三种子汇总与统计检验协议。

3.7 门控 I/Q-STFT 融合

`gated_fusion_iq_stft` 是本实验中的门控 I/Q-STFT 融合候选，由 `src/radioml_amc/models/gated_fusion.py` 中的 `ScalarGatedIQSTFTFusionNet` 实现。该模型同样包含 I/Q 分支与 STFT 分支，但在投影到相同融合维度后，通过一个标量 gate 调节两个视图表示的组合比例。源码中的 gate 输入包含两个投影表示、二者绝对差以及逐元素乘积：

$$r = [z_{IQ}, z_{STFT}, |z_{IQ} - z_{STFT}|, z_{IQ} \odot z_{STFT}], \quad (3.6)$$

$$g = \sigma(W_2 \phi(W_1 r)), \quad h = (1 - g)z_{IQ} + gz_{STFT}, \quad (3.7)$$

其中 g 为样本级标量门控权重， $\sigma(\cdot)$ 表示 sigmoid 函数， $\phi(\cdot)$ 表示非线性激活。分类器随后基于融合表示 h 输出调制类别 logits。

需要注意的是，该 gate 不接收显式 SNR 输入，其设计目的是在固定模型矩阵中提供一个可检验的视图加权机制。本章只描述其实现方式与实验角色，不写“门控提升鲁棒性”或类似结果性表述。




图 3.2 静态 I/Q-STFT 融合与标量门控融合的结构关系。Data source: `src/radioml_amc/models/multiview.py` and `src/radioml_amc/models/gated_fusion.py`.

3.8 方法边界

本报告并不声称提出全新的 SOTA 架构。第 3 章的任务是清晰记录 Stage 5A/5B 主实验中已经登记并完成的模型方法，使后续结果分析能够追溯到明确的输入视图、模型标识和代码实现。模型来源与相关工作引用将在最终报告定稿阶段补充。

Stage 6B 文档中出现的 `fusion_iq_amp_phase`、low-SNR weighted cross entropy、cheap signal augmentation、`tcn_gru`、`mcln_stable_v2` 等方向，只属于 diagnostic candidates 或 planning items。它们不构成本章主实验模型矩阵的一部分，也不能被写成已完成主实验。即使其中某些 mock smoke 路径已经存在，也只能说明工程路径或 artifact writer 可运行，不能支持第 4 章主结果或方法优越性结论。

因此，本文的方法解释遵循三条边界：第一，模型身份以 Stage 5A/5B 主表与代码注册为准；第二，方法描述只说明结构、输入视图与比较目的；第三，任何关于效果、显著性或局限性的判断均依赖第 2 章协议和第 4 章结果证据，而不在本章预先给出。

第四章 实验结果与统计检验

本章在第 2 章给出的固定划分、训练种子和评价指标基础上,整理本报告主实验结果与配对统计检验结论。所有数值均来自已经同步的 paper package 与 predictions archive,主要证据源包括 paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/main_table_metrics.csv、paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/low_snr_table.csv、paper_package/server_sync_20260508/results/paper_stage2/rml2016a/aggregate/complexity_latency_table.csv、paper_package/statistical_tests_20260508/paired_bootstrap_accuracy_deltas.csv 和 paper_package/statistical_tests_20260508/mcnemar_tests.csv。本章不重新生成主表,不运行任何训练或子集实验,也不纳入 Stage 6B 的 smoke/diagnostic 结果。

4.1 主实验结果


主实验采用第 2 章定义的 stratified_by_mod_snr_seed42 固定划分,对 9 个模型行分别使用 3 个训练种子 42, 2025, 3407 进行评估,因此主表对应 $9 \times 3 = 27$ 个固定协议运行。表 4.1 为主表证据的课程报告摘录,数值直接转写自 main_table_metrics.csv,其中均值和标准差均按三训练种子聚合得到。

表 4.1 固定划分主实验结果摘录 (证据源: main_table_metrics.csv)

模型行	输入视图	Overall Acc.	Macro-F1	Low-SNR Acc.	参数量	说明边界
cnn1d	I/Q	0.581992 ± 0.004518	0.595238	0.209508	37,131	原始 I/Q 卷积基线。
resnet1d	I/Q	0.595917 ± 0.000451	0.612207	0.205871	111,755	残差 I/Q 基线。
tfcnn_stft	STFT	0.506303 ± 0.001752	0.509340	0.171307	24,123	时频视图单分支。
fusion_iq_stft	I/Q+STFT	0.577098 ± 0.001712	0.584926	0.221326	98,299	静态双视图融合候选。
cldnn	I/Q	0.612932 ± 0.000546	0.633238	0.222386	241,675	当前协议下 observed 最优整体模型行。
mcldnn	I/Q	0.250083 ± 0.275698	0.199852	0.131307	406,199	含 seed 2025/3407 collapse, 未清洗。
lwamcnet	I/Q	0.551091 ± 0.001838	0.557940	0.202538	20,395	轻量结构对照。
iq_param_matched	I/Q	0.594462 ± 0.000468	0.612415	0.216345	136,395	参数匹配 I/Q 控制模型。
gated_fusion_iq_stft	I/Q+STFT	0.571947 ± 0.002025	0.585340	0.211307	134,780	门控双视图融合候选。


在当前固定划分协议下,cldnn 的 overall accuracy 为 0.612932,macro-F1 为 0.633238,是本轮 9 个模型行中观察到的最高 overall accuracy 与 macro-F1。该表述仅限定在 RadioML2016.10A、stratified_by_mod_snr_seed42、三训练种子聚合和本报告证据包范围内,不外推到其他数据集或其他划分协议。I/Q 基线中,resnet1d 的 overall accuracy 为 0.595917,iq_param_matched 的 overall accuracy 为 0.594462,二者构成接近的 I/Q baseline 与参数匹配控制参照。

图 4.2 将低信噪比局部结果放回完整 SNR 轨迹中观察。静态融合在若干低 SNR 点接近 cldnn,但在中高 SNR 区域没有保持同等优势;门控融合曲线也没有相对静态融合形成稳定改善。因此,该图支持的是分 SNR 的 trade-off 解释,而不是融合方法的总



Data source: main_table_metrics.csv; values are mean +/- std across seeds 42, 2025, 3407.

图 4.1 固定划分下 9 个模型行的 overall、low-SNR、mid-SNR 与 high-SNR accuracy 对比。Data source: main_table_metrics.csv.



Data source: metrics_per_snr.csv for seeds 42, 2025, and 3407; bands show across-seed std.

图 4.2 代表模型在完整 SNR 轴上的 accuracy 与 macro-F1 曲线。Data source: metrics_per_snr.csv for seeds 42, 2025, and 3407.

体优越性。




图 4.3 9 个模型行在 11 类调制方式上的 overall class accuracy。Data source: metrics_per_class.csv for seeds 42, 2025, and 3407.

图 4.3 从调制类别维度补充主表。该图用于说明 overall accuracy 并不是各类调制难度相同的结果；不同模型在 AM、PSK、QAM 与 WBFM 等类别上的行为存在差异，后续低信噪比分析也需要回到类别混淆结构中解释。

4.2 配对统计检验结果

为避免仅依赖聚合均值，本实验进一步使用 predictions archive 中的 predictions_test.csv 进行配对统计检验。配对键为 split_id+train_seed+sample_id，bootstrap accuracy delta 的定义为

$$\Delta = \text{Acc}(\text{model_a}) - \text{Acc}(\text{model_b}),$$

resamples 为 10,000，随机种子为 42。McNemar 检验使用同一批 paired sample 的正确/错误二元结果构造列联表。本节只讨论已在 paired_bootstrap_accuracy_deltas.csv 与 mcnemar_tests.csv 中存在的比较，不扩展到未检验组合。

表 4.2 表明，cldnn 相对 resnet1d 的 overall bootstrap delta 为 0.017015，95% 置信区间为 [0.015318, 0.018697]，McNemar 检验 $p = 1.52 \times 10^{-87}$ ；相对 iq_param_matched 的 overall bootstrap delta 为 0.018470，95% 置信区间为 [0.016788, 0.020159]，McNemar

表 4.2 CLDNN 与主要 I/Q baseline 的整体准确率配对统计检验

比较	Scope	Δ	95% CI	McNemar p	解释边界
cldnn vs. resnet1d	overall	0.017015	[0.015318, 0.018697]	1.52×10^{-87}	在当前 paired test 中支持 cldnn 高于 resnet1d。
cldnn vs. iq_param_matched	overall	0.018470	[0.016788, 0.020159]	2.86×10^{-104}	在当前 paired test 中支持 cldnn 高于参数匹配 I/Q 控制模型。




图 4.4 已登记 paired bootstrap accuracy delta 及其 95% 置信区间。Data source: paired_bootstrap_accuracy_deltas.csv; delta = $\text{Acc}(m_a) - \text{Acc}(m_b)$ 。

检验 $p = 2.86 \times 10^{-104}$ 。这些结论仅对应本报告已经执行并归档的 paired comparisons，不构成对未检验模型对、未测试数据集或不同训练协议的结论。

图 4.5 将配对统计检验背后的样本级分歧按 SNR 展开。它不替代 bootstrap 或 McNemar 检验，而是帮助解释 delta 的方向来自哪些 SNR 区间，并显示 gated_fusion_iq_stft 相对静态融合的负方向分歧在低信噪比区域更明显。


4.3 低信噪比下的融合权衡

本报告将低信噪比区域定义为 $\text{snr_db} \leq -6$ 。在 low_snr_table.csv 中，每个训练种子对应 17,600 个 low-SNR 测试样本，三种子合计用于配对统计检验的样本数为 52,800。主表摘录显示，cldnn 的 low-SNR accuracy 为 0.222386，fusion_iq_stft 为 0.221326，iq_param_matched 为 0.216345。

表 4.3 低信噪比关键比较与配对检验摘要

比较	Low-SNR Acc.	Δ 与 95% CI	McNemar p	解释边界
CLDNN vs IQ matched	22.24% vs. 21.63%	+0.006042 [+0.003125, +0.008883]	$3.88e-05$	方向由当前 paired test 支持。
Fusion vs CLDNN	22.13% vs. 22.24%	-0.001061 [-0.003939, +0.001838]	0.476	CI 跨 0，不能声称优势。
Fusion vs IQ matched	22.13% vs. 21.63%	+0.004981 [+0.001970, +0.007973]	0.00106	方向由当前 paired test 支持。
Gated vs Fusion	21.13% vs. 22.13%	-0.010019 [-0.012746, -0.007292]	$1.23e-12$	方向由当前 paired test 支持。

Paired correctness disagreements by SNR




Data source: predictions_test.csv in predictions_archive_20260508; positive bars favor the first model in each panel.

图 4.5 关键模型对在各 SNR 点上的 paired correctness disagreement。Data source: predictions_test.csv in predictions_archive_20260508; positive bars indicate samples where the first model in the panel is correct and the second is wrong.

相对于 cldnn, fusion_iq_stft 在 low-SNR scope 上的 bootstrap delta 为 -0.001061 , 95% 置信区间为 $[-0.003939, 0.001838]$, 该区间跨越 0; 对应 McNemar 检验 $p = 0.476423$ 。因此, 在当前 paired low-SNR 检验下, 不能声称静态 I/Q-STFT 融合优于 cldnn。


相对于参数匹配 I/Q 控制模型 iq_param_matched, fusion_iq_stft 在 low-SNR scope 上的 bootstrap delta 为 0.004981 , 95% 置信区间为 $[0.001970, 0.007973]$, McNemar 检验 $p = 0.001063$ 。但是同一比较在 overall scope 上的 bootstrap delta 为 -0.017364 , 95% 置信区间为 $[-0.019288, -0.015470]$ 。因此, 静态融合在本协议中的证据边界应表述为 low-SNR 局部小幅正向与 overall penalty 并存的 trade-off, 而不是广义融合优越性。

图 4.7 进一步显示静态融合的 low-SNR 差异并非对所有调制类别同向。附录图 A.1 给出了代表模型在 low-SNR scope 下的行归一化混淆矩阵, 用于补充说明不同模型在低信噪比样本上的类别混淆结构。



Data source: low_snr_table.csv; low-SNR scope is snr_db <= -6.

图 4.6 低信噪比区间内代表模型的 per-SNR accuracy 曲线。Data source: low_snr_table.csv; low-SNR scope is snr_db <= -6.



Data source: confusion_low_snr.csv aggregated across seeds 42, 2025, and 3407.

图 4.7 静态 I/Q-STFT 融合在 low-SNR scope 下相对参数匹配 I/Q 控制模型和 CLDNN 的 per-class recall delta。Data source: confusion_low_snr.csv aggregated across seeds 42, 2025, and 3407.

4.4 门控融合结果

gated_fusion_iq_stft 的 overall accuracy 为 0.571947, low-SNR accuracy 为 0.211307。与之相比,静态融合 fusion_iq_stft 的 overall accuracy 为 0.577098、low-SNR accuracy 为 0.221326, cldnn 的 overall accuracy 为 0.612932、low-SNR accuracy 为 0.222386。因此,在当前固定划分和三种子聚合结果中,门控融合行在 overall 与 low-SNR 两个指标

上均低于静态融合行和 cldnn 行。

配对检验进一步支持该负结果。对于 gated_fusion_iq_stft vs. fusion_iq_stft, overall bootstrap delta 为 -0.005152 , 95% 置信区间为 $[-0.006841, -0.003462]$, McNemar 检验 $p = 2.43 \times 10^{-9}$; low-SNR bootstrap delta 为 -0.010019 , 95% 置信区间为 $[-0.012746, -0.007292]$, McNemar 检验 $p = 1.23 \times 10^{-12}$ 。由于 delta 定义为 gated minus static, 负值和 McNemar 方向共同指向静态融合在该比较中更强。基于这些证据, 本报告不能写作“门控融合提升鲁棒性”或类似结论。

4.5 复杂度与受控 CUDA 延迟

复杂度与延迟证据来自 complexity_latency_table.csv, 其 evidence label 为 CONTROLLED_LATENCY。该测量仅覆盖 CUDA forward latency, 不包含 STFT 预处理耗时; 测量设置为 warmup=50、measured=200, batch size 分别为 1 和 256。表 4.4 摘录与第 4 章结果讨论最相关的模型行。


表 4.4 模型参数量与受控 CUDA forward latency 摘录

模型行	参数量	Batch 1 latency (ms)	Batch 256 latency (ms)	测量边界
resnet1d	111,755	2.081249	2.098535	CUDA forward-only。
iq_param_matched	136,395	1.250068	1.273155	CUDA forward-only。
cldnn	241,675	1.306352	1.543833	CUDA forward-only。
fusion_iq_stft	98,299	1.844381	1.857622	不含 STFT 预处理。
gated_fusion_iq_stft	134,780	2.535083	2.545334	不含 STFT 预处理。

这些数值可用于说明不同模型行在受控 CUDA forward 测量下的参数量和前向耗时差异。例如, cldnn 的参数量为 241,675, batch 1/256 forward latency 分别为 1.306352 ms 和 1.543833 ms; fusion_iq_stft 的参数量为 98,299, 对应 latency 为 1.844381 ms 和 1.857622 ms; gated_fusion_iq_stft 的参数量为 134,780, 对应 latency 为 2.535083 ms 和 2.545334 ms。由于该表不包含 CPU latency、FLOPs/MACs, 也不包含 STFT preprocessing-inclusive latency, 本报告不据此推导部署场景中的优越性或端到端系统结论。


4.6 MCLDNN 异常与负结果保留

mclldnn 行在主表中的 overall accuracy 为 0.250083, macro-F1 为 0.199852, 标准差明显高于其他模型行。根据 PAPER_STAGE5B_RESULT_AUDIT_AND_TABLES.md 与 section5_5_mclldnn_anomaly_retained_negative_evidence.md, 该聚合值包含三个训练种子, 其中 seed 42 的 test accuracy 为 0.568432, 而 seed 2025 和 seed 3407 分别出现 chance-level collapse, 二者 test accuracy 均为 0.090909, macro-F1 均为 0.015152。这些结果已经按协议保留在主表中, 没有进行 seed 清洗或主表重算。



Data sources: main_table_metrics.csv and complexity_latency_table.csv. CONTROLLED_LATENCY only; STFT preprocessing excluded.

图 4.8 固定协议下 overall accuracy、受控 CUDA batch-1 forward latency 与参数量的关系。Data sources: main_table_metrics.csv and complexity_latency_table.csv; CONTROLLED_LATENCY only, excluding STFT preprocessing.



Data source: seed-level metrics_test.json for seeds 42, 2025, and 3407; dashed line is model chance level (1/11).

图 4.9 9 个模型行在三个训练种子上的 overall accuracy 与 low-SNR accuracy 稳定性。Data source: metrics_test.json for seeds 42, 2025, and 3407.

该异常限制了 `mcln` 行在本报告中的解释方式：它可以作为当前训练配置下的负结果与优化敏感性证据，但不应被用作经过修复后的模型性能结论。与此同时，保留 `failed seeds` 并不推翻完整 `fixed-split 3-seed benchmark` 的有效性，因为其余模型行仍遵循相同的数据划分、训练种子集合、评估脚本和 `predictions archive` 记录。Stage 6B 中与稳定化或候选结构相关的 `smoke/diagnostic` 项目只能作为后续诊断线索，不得写成本章主结果或修复后结论。

图 4.9 将 `mcln` 放回 9 个模型行的 `seed` 稳定性背景中观察。附录图 A.3 以单模型 `seed` 级别展示该异常：`seed 42` 与 `seed 2025/3407` 的差异接近一个模型行内部的训练稳定性断裂，而不是普通随机波动。

第五章 讨论、局限性与可复现性

5.1 固定协议下结果的解释

第 4 章给出的主实验结果应被理解为固定协议内的观察，而不是无条件的模型排序。主结果只覆盖 RadioML2016.10A、固定划分 stratified_by_mod_snr_seed42、9 个模型行和 3 个训练种子 42, 2025, 3407。在这一协议中，cldnn 是 overall accuracy 与 macro-F1 最高的 observed model，并且相对 resnet1d 与 iq_param_matched 的 paired bootstrap 和 McNemar 检验均支持其在当前 paired comparison 中更高。该结论的有效范围由 main_table_metrics.csv、paired_bootstrap_accuracy_deltas.csv 和 mcnemar_tests.csv 共同限定。

固定划分的主要价值在于降低模型比较中的划分扰动。所有模型行在同一 split artifact、同一训练种子集合和同一测试样本标识下完成评估，使模型间差异更容易被解释为当前实现与训练配置下的差异，而不是测试样本集合变化造成的偏差。三训练种子汇总也为结果提供了基本的随机性缓冲，避免仅依据单次训练给出结论。

这一设计同时带来明确限制。固定 split 提高了模型行之间的可比性，但并不能替代多划分、多数据集或跨信道条件验证。本报告没有纳入其他数据集结果，也没有把任何 RadioML2018.01A 输出作为证据。因此，cldnn 的优势只能表述为“在当前固定划分协议下观察到的最强结果”，不能写成跨数据集泛化结论或最新水平比较。

5.2 低信噪比融合权衡

低信噪比分析显示，静态 I/Q-STFT 融合的价值主要体现为局部互补性线索，而不是整体性能优势。第 4 章中 fusion_iq_stft 在 snr_db ≤ -6 子集上接近 cldnn，并且相对 iq_param_matched 有小幅正向差异；统计检验中，fusion_iq_stft vs. iq_param_matched 的 low-SNR bootstrap delta 为正，McNemar 检验也支持该方向。然而，同一模型相对 iq_param_matched 的 overall delta 为负，说明低信噪比局部收益伴随整体准确率损失。

相对于 cldnn，静态融合的解释边界更窄。其 low-SNR paired bootstrap 置信区间跨越 0，McNemar 检验也未支持相对 cldnn 的 paired correctness 差异。因此，合理表述是：STFT 视图在当前实现中可能为低信噪比样本提供一定互补信息，但该互补性没有形成相对 cldnn 的统计支持优势，也没有抵消 overall scope 中的性能代价。

该结果对后续研究问题有两点启示。其一，多视图输入并不自动产生整体收益，融合结构需要同时满足低信噪比收益和中高信噪比保持。其二，参数匹配控制是必要的，因为它使静态融合的低信噪比表现可以与参数规模接近的 I/Q-only 模型比较，而不是

只与较小基线比较。基于当前证据，本报告只能讨论 low-SNR trade-off，不能将其扩展为广义融合优越性。

5.3 门控融合负结果的意义

`gated_fusion_iq_stft` 在当前证据集中应作为 retained negative result 处理。该模型的设计意图是通过样本级 gate 调节 I/Q 与 STFT 表征贡献，但第 4 章结果显示，它没有改善静态 `fusion_iq_stft`。在 overall 和 low-SNR 两个 scope 上，gated minus static 的 paired bootstrap delta 均为负，且 McNemar 检验方向支持 static fusion。该结果说明，当前实现和训练协议下的 gate 机制没有带来预期收益。

这一负结果不应被解释为所有门控或注意力式融合都无效。它只约束本报告中已经登记的 `gated_fusion_iq_stft` 模型行、固定 split、三训练种子和当前实现。若后续设计新的 gating 变体、SNR-aware gate 或其他视图加权机制，需要以新的模型标识、独立输出目录和明确 evidence label 重新评估。除非经过后续完整协议授权，这些候选只能作为 diagnostic candidates，不得从当前结果外推出性能结论。

因此，本报告在叙述门控融合时采用保守口径：它是一次被保留的负结果，能够约束“门控融合提升鲁棒性”这类未经证据支持的表述。保留该结果有助于避免只报告成功结构，也使第 3 章中的方法候选与第 4 章中的实验事实保持一致。

5.4 复杂度与延迟证据的边界

复杂度与延迟表提供了有用的运行时上下文，但其证据范围严格限定为受控 CUDA forward latency。该测量使用 CUDA 设备、50 次 warm-up、200 次 measured iterations，并在 batch size 1 和 256 下记录 forward-pass latency。该信息可以支持“在相同受控测量设置下，不同模型行具有不同参数量和 CUDA 前向耗时”的讨论，也可以帮助读者理解 accuracy 与 forward latency 之间的局部关系。

该证据不能推出部署效率结论。当前 aggregate 表中的 FLOPs/MACs 字段为空，CPU latency 没有形成完整测量，STFT preprocessing-inclusive latency 也不充分。尤其对于 STFT 或 I/Q+STFT 模型，forward-only timing 不包含从 I/Q 序列构造时频视图的预处理成本，因此不能代表端到端推理耗时。若要讨论真实部署系统，还需要补充硬件、批量、预处理、数据搬运和端到端 pipeline 的统一测量协议。

本报告据此采用受限解释：`complexity_latency_table.csv` 可作为 CONTROLLED_LATENCY 证据，用于报告参数量与 CUDA forward-pass timing；它不能支撑 CPU runtime、operation-count efficiency、preprocessing-inclusive runtime 或硬件可迁移部署优势。

5.5 MCLDNN 异常与负结果保留

`mclnndnn` 行是本实验中最重要负结果之一。第 4 章已经说明，seed 2025 与 seed 3407 出现 chance-level single-class collapse，并且二者继续保留在三种子聚合结果中。该处理符合固定协议要求：主表应反映登记运行的完整结果，而不是只保留成功种子。Stage 5B 审计未给出足以删除这些种子的证据，因此清洗 failed seeds 后重算主表会破坏实验记录的可追溯性。

保留 MCLDNN 异常提高了报告透明度。它提示读者：某些结构在当前超参数、初始化和训练流程下可能存在明显稳定性问题；该问题本身就是有价值的实验信息。将异常种子从聚合中移除，可能会制造一个更好看的但不忠实于协议的结果。相反，将其作为 retained negative evidence 报告，可以使读者区分“模型家族潜力”“当前实现结果”和“协议内实际证据”。

这一异常也限定了后续讨论方式。本报告不能把未来 `mclnndnn_stable_v2` 或其他稳定化诊断写成已经修复 Stage 5A 结果；也不能用新的 diagnostic run 替换当前 `mclnndnn` 行。后续若要分析 collapse 机制，应使用独立模型标识、独立输出目录和 DIAGNOSTIC evidence label，并在新的协议下评估。

5.6 可复现性与 artifact 边界

本报告的可复现性主要来自三个已同步证据集合。第一，`paper_package/server_sync_20260508` 保存了 Stage 5A/5B 聚合结果、受控 CUDA latency 表以及和 `paper_package` 相关的 manifest 记录；其 `paper package manifest` 共记录 299 行，其中包含 PROJECT_SUPPORTED、CONTROLLED_LATENCY 与 SMOKE TEST 等不同证据标签。第二，`paper_package/predictions_archive_20260508` 包含 27 个 Stage 5A `predictions_test.csv` 文件，覆盖 9 个模型行与 3 个训练种子，并且 manifest 中 27 行均为 `archive_hash_match`。第三，`paper_package/statistical_tests_20260508` 保存 paired bootstrap、McNemar、significance JSON、统计检验摘要和对应 manifest，用于支撑第 4 章的配对统计解释。

表 5.1 课程报告使用的主要 artifact 集合及边界

Artifact 集合	主要作用	使用边界
<code>paper_package/server_sync_20260508</code>	聚合主表、low-SNR 表、复杂度与受控 latency 表	支撑 Stage 5A/5B 主结果和 evidence label 记录。
<code>paper_package/predictions_archive_20260508</code>	27 个 Stage 5A 测试集预测文件	支撑 paired bootstrap 与 McNemar；不包含 Stage 6B 预测。
<code>paper_package/statistical_tests_20260508</code>	paired bootstrap、McNemar 和统计摘要	支撑已登记 comparison；不得外推到未检验模型对。
<code>docs/paper/EXPERIMENT_ENVIRONMENT_AND_SYNC_STATUS_20260508.md</code>	本地与服务器环境、同步状态、权重状态	支撑环境边界和后续复现实验前置条件说明。

附录图 A.4 将上述证据标签整理为三栏边界图。该图强调，PROJECT_SUPPORTED 与 CONTROLLED_LATENCY 可以分别支撑主结果和受控延迟讨论，而 SMOKE TEST/DIAGNOSTIC 只能用于工程追踪与未来诊断说明。

环境方面,本地环境为 Windows 与 CPU-only PyTorch,适合进行报告写作、manifest 检查、CSV 只读核验和轻量文档维护;服务器环境记录为 CUDA-capable PyTorch 与 NVIDIA GeForce RTX 4070,适合作为未来授权实验的执行环境。该区分对复现性很重要:本轮报告写作不应被描述为在本地复跑训练,也不应把本地 CPU-only 环境误写为 Stage 5A 主实验执行环境。

当前本地证据包足以支撑课程报告主结果写作,因为聚合表、prediction archive 和统计检验 artifacts 已经同步;但它不是完整训练权重归档。环境同步记录显示,服务器端存在 27 个 Stage 5A `best_model.pt` 权重,而本地 Stage 5A 结果树和 paper package 中没有完整 27 个权重文件。如果后续需要模型加载、推理复跑或权重级归档,应先将这些权重同步到单独 archive/package 路径并进行 hash 检查,不能默认覆盖本地 `results/` 或 Stage 5A/5B 根目录。

Stage 6B 的 smoke/diagnostic 输出在可复现性部分只能作为排除边界说明。已有 Stage 6B mock smoke 可说明某些工程路径和 artifact writer 被检查过,但其 data mode、evidence tag、输出根目录和运行设置均不同于 Stage 5A/5B 主实验。因此,它不得进入主结果表、统计检验、摘要结论或总结性性能判断。任何 future diagnostic candidate 在完成新的完整协议前,都只能作为后续工作线索,而不能写成当前课程报告的实验结果。

第六章 总结

6.1 工作总结

本文围绕无线电自动调制识别任务，完成了 RadioML2016.10A 固定划分协议下的课程实验报告写作。实验协议以 `stratified_by_mod_snr_seed42` 为固定测试口径，覆盖 9 个模型行与 3 个训练种子 42, 2025, 3407，共形成 $9 \times 3 = 27$ 个主实验单元。模型矩阵包含 I/Q-only、STFT-only、I/Q+STFT 静态融合、门控融合、时序模型、轻量模型和参数匹配 I/Q 控制模型，用于在同一数据划分与训练种子集合下比较不同输入视图和结构设计。

在实验结果组织上，本文基于已经同步的 Stage 5A/5B evidence package，整理了主表、low-SNR 表、受控 CUDA forward latency 表和 paired statistical tests。主结果来自 `main_table_metrics.csv` 与 `low_snr_table.csv`，复杂度与延迟解释限定在 `complexity_latency_table.csv` 的 CONTROLLED_LATENCY 范围内；统计检验来自 archived predictions 生成的 paired bootstrap 与 McNemar artifacts。整个报告写作过程没有重新训练模型、没有重建主表，也没有将 Stage 6B smoke/diagnostic 输出写入主结果。

6.2 主要发现

在当前 RadioML2016.10A 固定划分与三训练种子协议下，`clldnn` 是本报告中观察到的 strongest observed model。第 4 章的主表结果与 paired statistical tests 均支持其在当前已登记比较中相对主要 I/Q baseline 具有更高的整体表现。该发现应严格限定在本报告的数据集、划分、模型矩阵和训练种子范围内，不能扩展为跨数据集泛化结论或最新水平比较。

静态 I/Q-STFT 融合体现出低信噪比局部权衡。相对于参数匹配 I/Q 控制模型，`fusion_iq_stft` 在 low-SNR scope 上存在小幅正向证据，但其 overall scope 存在 penalty，且相对 `clldnn` 的 low-SNR paired test 不支持显著优势。因此，该结果只能解释为 low-SNR trade-off，而不是 broad improvement 或融合结构的普遍优越性。

门控融合在当前实现和协议下没有改善静态融合。`gated_fusion_iq_stft` 在 overall 与 low-SNR 两个 scope 上均未超过 `fusion_iq_stft`，paired bootstrap 与 McNemar 结果也支持将其作为 retained negative result 处理。本报告因此不写“门控融合提升鲁棒性”或类似结论。

`mclldnn` 行中的 seed 2025 与 seed 3407 chance-level collapse 被保留在主表聚合中。该处理维护了固定协议下的完整实验记录，也使报告能够呈现模型训练稳定性方面的负结

果。本文不删除 failed seeds, 不重算清洗后的 MCLDNN 结果, 也不使用未来 diagnostic candidate 替换当前 Stage 5A/5B 证据。

6.3 不足与后续工作

本文的局限性之一来自数据集与划分范围。当前主结果仅覆盖 RadioML2016.10A 与 stratified_by_mod_snr_seed42, 没有纳入 RadioML2018.01A 或其他数据集, 也没有进行多划分重复验证。因此, 本报告的发现只能作为 fixed-split evidence 使用, 不能作为一般 AMC 排名或跨数据集结论。

复杂度与运行时证据也存在边界。当前报告只具有受控 CUDA forward latency 证据, 不具备完整 FLOPs/MACs、CPU latency 或 STFT preprocessing-inclusive latency 证据。因此, 本文不讨论部署效率、硬件可迁移性能或端到端推理成本优势。若后续需要进行系统级效率分析, 应在单独协议下补充统一的 CPU/GPU、预处理和端到端 pipeline 测量。

本地 artifact 同步状态对后续复现也有约束。当前本地已有 paper package、27 个 Stage 5A predictions archive 文件和 statistical-test artifacts, 足以支撑本报告的主结果写作和统计解释; 但完整 27 个 Stage 5A best_model.pt 权重尚未同步到本地 package 或本地 Stage 5A 结果树。若后续需要模型加载、推理复跑或权重级归档, 应先将服务器端权重同步到独立 archive 路径并进行 hash 检查。

后续工作若继续开展新实验, 应与当前证据集清晰分离。Stage 6B 中的 amp-phase fusion、weighted CE、TCN-GRU、MCLDNN 稳定化等方向只能作为 future diagnostic candidates; 在没有新的完整协议、独立输出目录、明确 evidence label 和相应统计检验之前, 它们不能写作当前课程报告的实验结果, 也不能用于修复或替换 Stage 5A/5B 主表。

参考文献

附录 A 证据包与实验环境

A.1 主实验证据包

本文使用的主要证据包位于 `paper_package/server_sync_20260508`。该目录用于同步 Stage 5A/5B 固定协议实验的主要审计材料和聚合证据，包括 Stage 5B audit 文档、`main_table_metrics.csv`、`low_snr_table.csv`、`complexity_latency_table.csv` 以及若干小型 artifact 和 manifest 记录。根据 `docs/paper/ARTIFACT_MANIFEST_PAPER_PACKAGE_20260508.csv`，paper package manifest 共 299 行，其中 `PROJECT_SUPPORTED` 253 行、`CONTROLLED_LATENCY` 28 行、`SMOKE TEST` 18 行。

该证据包中存在 Stage 6B diagnostic 或 smoke metadata，是为了记录工程路径、artifact writer 和后续候选筛查边界。这类 metadata 不属于 Stage 5A/5B 主实验证据，不得进入主结果表、统计检验或课程报告结论。本文正文和附录使用它们时，仅用于说明证据标签和排除规则。

A.2 预测归档与统计检验

预测归档位于 `paper_package/predictions_archive_20260508`。该归档包含 27 个 Stage 5A `predictions_test.csv` 文件，覆盖 9 个模型行和 3 个训练种子 42, 2025, 3407，其 manifest 记录均为 `archive_hash_match`。这些预测文件是 paired bootstrap 与 McNemar 检验的输入来源，使统计比较可以按照 `split_id`、`train_seed` 和 `sample_id` 对同一样本进行配对。

统计检验包位于 `paper_package/statistical_tests_20260508`。该目录包含 `paired_bootstrap_accuracy_deltas.csv`、`mcnemar_tests.csv`、`significance_tests.json`、`statistical_tests_summary.md` 以及统计检验 manifest。统计检验摘要明确说明，这些 artifacts 基于 Stage 5A archived predictions 生成，没有训练模型、没有运行 tiny subset、没有重建或覆盖 Stage 5A/5B 主表，也没有使用 Stage 6B `SMOKE TEST` 或 `DIAGNOSTIC` 输出。

A.3 证据标签

为避免主实验、受控延迟测量和工程诊断相互混淆，本文采用 evidence label 约束证据使用范围。表 A.1 汇总了课程报告中使用的主要标签及其边界。

其中，`PROJECT_SUPPORTED` 与 `CONTROLLED_LATENCY` 可支撑正文中的主表、统计检验和受控延迟讨论；`SMOKE TEST` 与 `DIAGNOSTIC` 只能用于工程检查或未来诊断说明，不

表 A.1 证据标签与可用范围

证据标签	含义	课程报告使用范围
PROJECT_SUPPORTED	Stage 5A/5B 完整固定协议证据	可用于主表、low-SNR 表、模型矩阵、predictions archive 和 paired statistical tests。
CONTROLLED_LATENCY	受控 CUDA forward latency 测量	仅用于参数量与 CUDA forward latency 范围内的复杂度讨论。
SMOKE TEST	mock 或 synthetic code-path 检查	仅用于工程路径说明，不得作为性能证据。
DIAGNOSTIC	mock、subset 或调试筛查	仅用于后续诊断边界说明，不得进入主表或统计检验。

能支撑实验发现。

A.4 本地与服务器环境

实验环境与同步状态记录见 docs/paper/EXPERIMENT_ENVIRONMENT_AND_SYNC_STATUS_20260508.md。本地环境与服务器环境的角色不同，表 A.2 给出与课程报告复现边界相关的主要信息。

表 A.2 本地与服务器环境摘要

项目	本地环境	服务器环境
操作系统/路径	Windows 11; E:/ML_HomeWork/.../radioml-amc-stage1	Linux; /hy-tmp/radioml-amc-stage1
Python	3.13.7	3.11.12
PyTorch	2.11.0+cpu	2.9.1+cu128
CUDA	不可用	可用
GPU 角色	无本地 CUDA GPU 证据 报告写作、manifest 检查、CSV 只读核验	NVIDIA GeForce RTX 4070 后续经授权的 GPU 实验执行

因此，本地环境适合课程报告写作、证据包检查和统计 artifact 审阅，不应用于 GPU full training。若后续需要继续实验，应在服务器环境中按新的协议明确授权后执行，并使用新的输出根目录。

A.5 同步状态与剩余缺口

当前本地已经同步 paper_package/server_sync_20260508、paper_package/predictions_archive_20260508 和 paper_package/statistical_tests_20260508。这些材料足以

支撑课程报告正文中的主结果写作、配对统计解释和证据边界说明。

同步状态仍存在若干限制。服务器端存在 27 个 Stage 5A `best_model.pt` 权重，但本地 Stage 5A 结果树和 paper package 中没有完整 27 个权重文件。因此，本地证据包不能被描述为完整 checkpoint archive。若后续需要模型加载、推理复跑或 checkpoint-level reproducibility，应将服务器端权重同步到独立 archive/package 路径并进行 hash 检查，不应默认覆盖本地 `results/` 或 Stage 5A/5B 根目录。

运行时证据也不是完整部署证据。当前聚合材料不支持 CPU latency、FLOPs/-MACs 或 STFT preprocessing-inclusive latency 结论；`complexity_latency_table.csv` 仅支持 CONTROLLED_LATENCY 范围内的 CUDA forward-pass 讨论。

A.6 排除规则

Stage 6B smoke 或 diagnostic 输出不得进入 Stage 5A/5B 主表、low-SNR 表、paired bootstrap、McNemar 检验、摘要结论或总结性实验结论。若未来执行 tiny subset diagnostic，也必须使用独立输出目录、独立模型标识和 DIAGNOSTIC evidence label，并明确其不能替代当前 Stage 5A/5B 主证据。

本附录只整理 evidence package、manifest、环境和同步边界，不新增实验结果。任何后续候选方案在完成新的完整协议前，都只能作为工程诊断或未来工作线索记录，不能写作当前课程报告的主结果。


A.7 补充图表清单与诊断性可视化

表 A.3 汇总本文新增图表文件、主要证据源、证据标签和正文引用位置。该清单用于复查图表是否均可回溯到已有 artifact，而不是来自新增训练或 Stage 6B diagnostic 输出。

表 A.3 新增图表清单、证据源与正文引用位置

文件	主要证据源	证据标签	引用位置
<code>fig01_protocol_pipeline.tex</code>	Protocol/manifests/statistical package	PROJECT_SUPPORTED	第 1 章
<code>fig02_model_taxonomy.tex</code>	<code>main_table_metrics.csv</code>	PROJECT_SUPPORTED	第 3 章
<code>fig03_fusion_architecture.tex</code>	model source files	PROJECT_SUPPORTED	第 3 章
<code>fig04_accuracy_by_snr_group.pdf/png</code>	<code>main_table_metrics.csv</code>	PROJECT_SUPPORTED	第 4 章
<code>fig05_low_snr_per_snr_curve.pdf/png</code>	<code>low_snr_table.csv</code>	PROJECT_SUPPORTED	第 4 章


文件	主要证据源	证据标签	引用位置
fig06_bootstrap_delta_forest.pdf/png	paired_bootstrap_accuracy_deltas.csv	PROJECT_SUPPORTED	第 4 章
fig07_accuracy_latency_params_bubble.pdf/png	main_table_metrics.csv; complexity_latency_table.csv	CONTROLLED_LATENCY	第 4 章
fig08_low_snr_confusion_panels.pdf/png	confusion_low_snr.csv	PROJECT_SUPPORTED	附录 A
fig09_mclnns_seed_anomaly.pdf/png	mclnns metrics_test.json	PROJECT_SUPPORTED	附录 A
fig10_evidence_boundary.tex	REPORT_EVIDENCE_MAP.md	Mixed labels	附录 A
fig11_full_snr_accuracy_macro_f1.pdf/png	metrics_per_snr.csv	PROJECT_SUPPORTED	第 4 章
fig12_model_class_accuracy_heatmap.pdf/png	metrics_per_class.csv	PROJECT_SUPPORTED	第 4 章
fig13_low_snr_class_recall_delta.pdf/png	confusion_low_snr.csv	PROJECT_SUPPORTED	第 4 章
fig14_paired_disagreement_by_snr.pdf/png	predictions_test.csv	PROJECT_SUPPORTED	第 4 章
fig15_seed_stability_all_models.pdf/png	metrics_test.json	PROJECT_SUPPORTED	第 4 章
fig16_overall_confusion_panels.pdf/png	confusion_overall.csv	PROJECT_SUPPORTED	附录 A



Data source: confusion_low_snr.csv for seeds 42, 2025, and 3407.


图 A.1 代表模型在 low-SNR scope 下的行归一化混淆矩阵，三训练种子聚合。Data source: confusion_low_snr.csv for seeds 42, 2025, and 3407.

Overall normalized confusion matrices (aggregated across seeds)



Data source: confusion_overall.csv for seeds 42, 2025, and 3407.

图 A.2 代表模型在 overall scope 下的行归一化混淆矩阵,三训练种子聚合。Data source: confusion_overall.csv for seeds 42, 2025, and 3407.



Data source: mclldnn/seed_*/metrics_test.json. Seeds 2025 and 3407 are retained negative evidence.

图 A.3 MCLDNN 在三个训练种子上的 overall accuracy 与 macro-F1。Data source: mclldnn/seed_*/metrics_test.json; seeds 2025 and 3407 are retained negative evidence.




图 A.4 本文证据标签与排除规则示意图。Data source: REPORT_EVIDENCE_MAP.md, paper package manifests, and environment audit.